



MAESTRÍA EN EXPLOTACIÓN DE DATOS Y GESTIÓN DEL CONOCIMIENTO

Plan de Trabajo Final

Detección y segmentación de silo-bolsas mediante la aplicación de técnicas de aprendizaje profundo en imágenes satelitales Sentinel-2 para el departamento de Marcos Juárez ubicado en la zona núcleo de Argentina

Alumno: Federico Richard

Tutor: Gonzalo Sad

Resumen

El monitoreo de granos almacenados en silo bolsas, una tecnología clave e innovadora que revoluciono la forma de producir en el sector agrícola que resguarda una porción significativa de la producción agrícola argentina (estimada en un 40%), es fundamental para la toma de decisiones en la cadena agroindustrial. Sin embargo, los métodos actuales de estimación carecen de la escalabilidad y eficiencia necesarias para un monitoreo exhaustivo a nivel nacional. Este trabajo tiene como objetivo general desarrollar y validar un modelo de inteligencia artificial, basado en Redes Neuronales Convolucionales (CNN), para la detección y/o segmentación automática de silo bolsas utilizando imágenes satelitales multiespectrales (RGB+NIR) de la misión Sentinel-2 (10m de resolución) en la zona núcleo de Argentina sobre el departamento de Marcos Juárez, provincia de Córdoba.

La metodología propuesta incluye la creación de un dataset específico (Verdad de terreno - Ground Truth) mediante el etiquetado de silo bolsas sobre imágenes Sentinel-2 L2A (bandas RGB y NIR) del departamento de Marcos Juárez (Córdoba), abarcando el período 2021-2025. Se evaluarán y adaptarán arquitecturas de Deep Learning (DL, como U-Net (para segmentación pixel-wise) y YOLO (para detección de objetos), optimizándolas para manejar la entrada multiespectral de 4 canales, de ser posible, y enfrentar los desafíos de trabajar con una resolución espacial de 10 metros, se espera que la inclusión de la banda Infrarrojo Cercano (NIR) mejore la discriminación de los objetos. Esta solución permitirá generar estimaciones objetivas y actualizadas del grano almacenado, ofreciendo una herramienta escalable y de bajo costo para optimizar la logística, aumentar la transparencia del mercado y apoyar la toma de decisiones de actores públicos y privados del sector.

Motivación e importancia del tema de estudio

El monitoreo en el sector agropecuario mediante teledetección (RS – Remote Sensing) se ha vuelto fundamental en los últimos años debido a la creciente necesidad de optimizar la producción de alimentos y gestionar los recursos de manera eficiente. La aplicación de este tipo de tecnologías recibió el nombre de Agricultura de precisión (AP), un término que viene tomando un espacio cada vez más grande y representativo en el sector. La AP es un enfoque basado en observar, medir y responder a la variabilidad espacial y temporal dentro y entre campos de cultivo. Mediante el uso de tecnologías avanzadas, permite tomar decisiones y ejecutar acciones fundamentadas en datos

precisos. Ejemplos incluyen la aplicación diferenciada de herbicidas según ambientes específicos y la fertilización variable. Como de medir y observar se trata, el uso de sensores remotos como Drones o imágenes satelitales representan una de las principales tecnologías utilizadas por defecto en la AP. Las imágenes satelitales, como por ejemplo las provistas por la misión Sentinel-2, conocida constelación europea diseñada para generar datos de lectura del comportamiento del uso del suelo en el tiempo, ofrecen una cobertura global frecuente y datos multiespectrales valiosos (incluyendo RGB O rango visible y NIR o infrarrojo cercano) con una resolución espacial adecuada (10 metros) para diversas aplicaciones agrícolas (Víctor et al., 2025; Zhang et al., 2016). El desafío está en generar valor agregado de estas tecnologías, es decir, un dato por sí solo no aporta información valiosa, una imagen satelital por sí sola no es capaz de generar AP, para eso es necesario generar procesos sobre estas en orden de extraer información que nos permita actuar sobre el terreno. En ejemplo, la extracción de información específica, como la ubicación y cantidad de estructuras de almacenamiento temporal como los silos bolsas, sigue siendo un desafío y en este trabajo nos dispondremos a abordar este problema específico entre muchos otros que pueden ser abarcados por la AP.

El silo-bolsa es una tecnología plástica de forma oblonga y compuesto por polietileno de baja densidad para almacenar forraje y granos secos de manera temporal (DiccionarioAgro TeseoPress, 2024). Su origen se remonta a Alemania en los años 60 para forraje, popularizándose en Argentina en los años 90. Investigaciones del INTA en Manfredi y Balcarce a finales de los 90 tecnificaron las bolsas plásticas, convirtiéndolas en dispositivos herméticos aptos también para granos secos como soja, maíz y trigo (DiccionarioAgro TeseoPress, 2024). Esto transformó el silo bolsa de una tecnología de conservación para ganado a una solución logística y herramienta financiera para los agricultores (Expoagro, 2025). Permite a los productores almacenar su cosecha de 6 meses hasta 2 años (INTA, n.d.), posibilitando estrategias comerciales en momentos de menor oferta o mayor demanda.

Se estima que, en promedio, cerca del 40% de la producción agrícola argentina se almacena en silo bolsa (Gobierno de Argentina, 2023a). No obstante, este valor fluctúa constantemente debido a factores económicos (precios, retenciones), necesidades de los productores (capital de trabajo, insumos) y logística, lo que dificulta tener una estimación precisa del grano almacenado. Esta información es crucial para empresas de acopio y exportación, compañías de seguro, Mismos

productores o empresas para validar cosecha y seguridad de su producción y también para entidades gubernamentales.

Los avances recientes en Inteligencia Artificial, específicamente en Deep Learning (DL) y Visión por Computadora (Computer Vision - CV), han demostrado capacidades extraordinarias para el análisis automático de imágenes, incluyendo la detección y segmentación de objetos (Ball et al., 2017; Zhang et al., 2016). El agro no ha sido la excepción y en los últimos años la explotación de técnicas de detección automática para la producción no han hecho nada más que aumentar y su proyección en los próximos años es continuar con esta tendencia alcista. Un claro ejemplo ajeno al objetivo de este trabajo pero muy relacionado, es la utilización de una técnica muy popular en la AP que son las aplicaciones selectivas que tratan del uso de sensores/camaras en los botallones de las pulverizadoras de productos fitosanitarios para detectar malezas mediante técnicas de DL para, únicamente, aplicar sobre la maleza y así ahorrando productos (CREA, 2023), técnicas como estas generan un valor tangible para los productores agropecuarios permitiendo, en ciertos casos, llegar a generar ahorros de producto de hasta un 80%. Entonces aplicar estas técnicas a imágenes satelitales para detectar silos y bolsas representa una oportunidad significativa para seguir explotando estas técnicas en el sector agropecuario y continuar con la tendencia de adopción. Este trabajo se motiva por la necesidad de automatizar y escalar el monitoreo de silos y bolsas, aprovechando la disponibilidad de datos Sentinel-2 gratuitos y el poder de los modelos DL modernos.

Los beneficios esperados de una solución automatizada incluyen: 1) Mayor eficiencia y reducción de costos en comparación con el monitoreo manual actualmente utilizada por compañías del rubro; 2) Capacidad para cubrir grandes extensiones geográficas de manera consistente, logrando una escalabilidad, sostenibilidad y transparencia de los datos; 3) Generación de datos objetivos y actualizados sobre la distribución y cantidad de almacenamiento temporal, útiles para actores públicos y privados del sector agroindustrial; y 4) Establecer una base metodológica aplicable a la detección de otros objetos de interés agrícola mediante RS y DL, abriendo nuevas posibilidades a solución de problemas asociados al uso de estas tecnologías en el sector agrícola aportando a la evolución y adopción tecnológica en búsqueda de un desarrollo de la producción más sostenible.

Requerimientos y desafíos

La detección de objetos en imágenes satelitales mediante DL es un campo activo de investigación (Ball et al., 2017; Zhang et al., 2016). Problemas similares, como la detección de edificios,

vehículos, caminos, se han abordado utilizando diversas arquitecturas DL, principalmente las Redes Neuronales Convolucionales (CNN). Arquitecturas como U-Net se usan para segmentación semántica (Víctor et al., 2025; Ball et al., 2017), mientras que R-CNN, SSD y especialmente YOLO se emplean para detección de objetos con las denominadas bounding boxes o áreas de interés (Ball et al., 2017). Trabajos previos han demostrado la viabilidad de detectar objetos relativamente pequeños o específicos en imágenes RS, como barcos, aviones, o pivotes de riego (Ball et al., 2017). El trabajo de Barbiani y Bustamante (2022) abordó específicamente la detección de pivotes y silo bolsas usando YOLOv5 sobre imágenes de Google Earth y Sentinel, demostrando la factibilidad del enfoque.

Hoy existen diversas formas de registrar la presencia/ausencia de Silos bolsa, como plataformas web, sensores IoT, o registros/encuestas web. Sin embargo, todas estas técnicas son costosas o poco escalables para un monitoreo exhaustivo y frecuente a nivel nacional. En este trabajo se busca abordar este problema utilizando imágenes satelitales Sentinel-2 del proveedor europeo Copernicus (Copernicus, n.d.). La combinación de estos datos satelitales (10 m de resolución, revisita temporal cada 5 días y acceso gratuito) con técnicas de aprendizaje profundo permitirá automatizar una tarea que hoy requiere mucho tiempo y recursos, transformándola en un sistema potencialmente sencillo, rápido y certero.

La utilidad concreta de la solución propuesta es proporcionar una herramienta automatizada que pueda procesar imágenes Sentinel-2 (idealmente de forma secuencial cada semana o cada vez que se obtenga acceso a una nueva imagen) para generar mapas o reportes sobre la ubicación, cantidad y dimensión de silo bolsas detectadas en la zona productiva de Argentina comprendida principalmente por la región sur (Buenos Aires y la Pampa), centro (Córdoba, Santa Fe, Entre Ríos y Corrientes) y NOA-Noroeste Argentino (Santiago del Estero, Chaco, Tucumán y Salta). Esto permitiría, por ejemplo, a organismos gubernamentales o empresas del sector, tener estimaciones actualizadas del grano almacenado temporalmente, monitorear tendencias, optimizar logística o identificar áreas con alta actividad.

El aporte principal de este trabajo radica en la aplicación y adaptación específica de técnicas de DL de última generación (posiblemente arquitecturas de segmentación como U-Net o detección como YOLO) al problema concreto de la detección y segmentación de silo bolsas en imágenes Sentinel-2 multiespectrales (RGB+NIR). Esto implica abordar desafíos como: 1) La creación y

curación/filtrado de un dataset específico (con anotaciones pixel-wise o bounding boxes); 2) La adaptación de la arquitectura de red para manejar la entrada multiespectral (4 canales), de ser posible; 3) La optimización del modelo para detectar/segmentar objetos alargados y de tamaño variable a resolución de 10m; y 4) La evaluación rigurosa del rendimiento. Se contribuirá con conocimiento aplicado sobre la viabilidad, precisión y limitaciones de usar DL para este tipo de monitoreo agrícola específico.

Problemas no resueltos

El problema puntual que se quiere resolver es la digitalización automática de silos bolsa, entendiéndose como detección y medición (segmentación) de los mismos, partiendo de imágenes satelitales Sentinel-2. Aunque existen métodos generales de detección/segmentación en RS (Zhang et al., 2016; Ball et al., 2017) y un trabajo previo en detección de silo bolsas (Barbiani & Bustamante, 2022), persisten desafíos específicos no resueltos para lograr una solución robusta y escalable:

- Optimización para Sentinel-2 (10m): Los modelos deben adaptarse a esta resolución espacial, donde los silos bolsas pueden ser objetos relativamente pequeños (pocos píxeles de ancho) y variables en longitud, maximizando la detectabilidad y la precisión de la segmentación.
- Robustez y Generalización: Los modelos deben ser robustos a variaciones en la apariencia de los silos bolsas (color, tamaño, orientación, sombra, entorno) y generalizar bien a diferentes regiones geográficas y condiciones ambientales dentro de la zona núcleo (Zhang et al., 2016; Ball et al., 2017).
- Disponibilidad de Datos Etiquetados (Pixel-wise): La creación de datasets grandes y diversos con anotaciones precisas a nivel de píxel (máscaras de segmentación), específicamente para silos bolsas en Sentinel-2, es un cuello de botella aún mayor que para bounding boxes, fundamental para entrenar modelos de segmentación (Ball et al., 2017).
- Manejo de Nubes y Artefactos: Las imágenes satelitales ópticas a menudo están afectadas por nubes, sombras o bruma, requiriendo estrategias efectivas de preprocesamiento o modelado (Víctor et al., 2025; Ball et al., 2017).
- Segmentación vs. Detección: Mientras la detección localiza (bounding box), la segmentación delimita la forma exacta (máscara), lo que es más útil para estimar dimensiones. Lograr una segmentación precisa en 10m es un reto adicional comparado con la simple detección.

La importancia y significancia del problema radican en el rol central de los silos bolsas en la cadena de valor agrícola argentina. La falta de un monitoreo eficiente impide tener una visión clara del volumen de granos almacenado, afectando estimaciones de producción, logística, transparencia del mercado, además para los dueños de campo resulta una herramienta importante de monitoreo y control de su explotación. Aunque existen métodos de monitoreo con sensores o drones para supervisar la integridad física de la bolsa y la condición de la mercadería (Gobierno de Argentina, 2023b), la utilización de satélites permitiría escalar este servicio a más superficie a un costo más bajo y con una revisita frecuente gracias a la utilización de fuente de datos como los satélites Sentinel 2.

Solución propuesta

La solución concreta propuesta consiste en desarrollar e implementar un sistema basado en Deep Learning (DL) para la detección y segmentación automática de silo bolsas en imágenes satelitales Sentinel-2 utilizando las bandas RGB y NIR. Se seleccionará y adaptará una arquitectura de red neuronal convolucional (CNN) adecuada para segmentación semántica (pixel-wise) o detección de objetos, como U-Net, Mask R-CNN o variantes de YOLO (Fernández Marcos, 2023; Barbiani & Bustamante, 2022; Ball et al., 2017).

Esta solución resuelve el problema planteado al automatizar la identificación y delimitación de silo bolsas. El sistema seguirá los siguientes pasos:

- Descarga de imágenes desde AWS S3: Acceso a datos Sentinel-2 L2A alojados en plataformas como AWS Open Data Registry (AWS Open Data Registry, n.d.).
- Generación de mosaicos y Recorte: Combinación de las bandas relevantes R-Roja (Banda B4), G-Verde (Banda B3), B-Azul(Banda B2), NIR (Banda B8) (GISGEO. (N.D.) y recorte de las imágenes para cubrir el área de interés (zona núcleo de Argentina, departamento Marcos Juárez, Córdoba).
- Filtrado: Preprocesamiento para eliminar o enmascarar áreas no relevantes como nubes, sombras, zonas urbanas, cuerpos de agua.
- Etiquetado: Creación de un dataset mediante anotación manual (máscaras de segmentación o bounding boxes) de silo bolsas en un conjunto representativo de imágenes preprocesadas.

- Entrenamiento: Utilización del dataset etiquetado (aplicando data augmentation o técnicas de convolución) para entrenar la arquitectura DL seleccionada (adaptada para 4 canales de entrada inicialmente) con técnicas de optimización.
- Validación e Inferencia: Evaluación del modelo en un set de datos independiente (probablemente del año 2025) que jamás hayan sido imágenes de entrada para el entrenamiento del modelo para calcular la asertividad del modelo.

Se espera que la inclusión de la banda NIR buscará mejorar la discriminación entre silo bolsas y vegetación/suelo o cualquier otro objeto ajeno al silo bolsa. Se emplearán técnicas de aumento de datos (geométricas y fotométricas) para mejorar la robustez (Barbiani & Bustamante, 2022; Ball et al., 2017), se conoce de antemano la limitación de algunos modelos de adaptar imágenes que poseen más de 3 dimensiones, por lo que será un desafío entender si la utilización de esta banda extra-NIR realmente hace la diferencia o presenta un nivel más de complejidad que no aporta valor significativo a la diferenciación.

Las limitaciones de la solución propuesta incluirán:

- Escalabilidad y Cómputo: Procesar grandes áreas (país entero) requeriría una infraestructura computacional significativa debido al volumen de datos (1GB/imagen aprox.) (Barbiani & Bustamante, 2022). El estudio se limitará a la zona núcleo, más específicamente al departamento de Marcos Juárez provincia de Córdoba.
- Variabilidad Temporal/Atmosférica: Cambios en colorimetría por humedad, presencia residual de nubes/bruma pueden afectar la detección (Víctor et al., 2025), esto puede verse además muy marcado en distintos años en una misma época ya que las imágenes también se ven variadas por el tipo de año climático, podemos notar grandes cambios entre años muy llovedores vs los años con sequía. En este trabajo se buscará entrenar el modelo utilizando varios años del 2021 al 2025
- Resolución (10m): Puede limitar la detección/segmentación precisa de silo bolsas muy pequeñas (e.g., < 20 píxeles), agrupadas o parcialmente visibles. Un silo bolsa típico (60m x 3-5m) ocuparía aprox. 6x1 píxeles, dificultando la captura del ancho, pero no el largo. Esto de todas formas es esperanzador ya que se pueden llegar a estimar algunos factores de medición ya que los silos bolsa presentan medidas estándares de aproximadamente 75 metros de largo y 2,70 metros de diámetro (Filgueira E. 2013)

- Dependencia de Datos: El rendimiento dependerá fuertemente de la calidad y representatividad del dataset etiquetado (Ball et al., 2017).
- Confusión: Posible confusión con objetos alargados y reflectantes similares como bordes de ríos, caminos, galpones, etc.
- Sitio específico: Posible sesgo a únicamente detectar correctamente los silos bolsas al área el cual fue entrenado el modelo.

A partir de estas limitaciones, el trabajo podría ampliarse en el futuro mediante:

- Fusión con Sentinel-1 (Radar) o similares: Para operación independiente de nubes (Víctor et al., 2025).
- Análisis Temporal: Monitorear cambios y mejorar fiabilidad, extender el entrenamiento a mas años para abarcar más cambios temporales.
- Resolución Superior: Aplicar a imágenes comerciales.
- Foco: se podrá expandir a utilización de imágenes satelitales de otras regiones que también pueden llegar a variar. Esto probablemente requiera un reentrenamiento del modelo

Grado de innovación de la propuesta tecnológica

La propuesta tecnológica presenta un grado de innovación relevante al aplicar y adaptar sistemáticamente técnicas de Deep Learning de vanguardia a un problema específico y de alto impacto en el sector agrícola argentino, utilizando datos satelitales públicos.

Las características innovadoras clave son:

- Enfoque Específico en Silo Bolsas con Sentinel-2 (RGB+NIR): Aunque existen aplicaciones de DL en RS agrícola (Víctor et al., 2025), este trabajo se centra específicamente en la detección y/o segmentación de silo bolsas, optimizando el uso de las bandas RGB+NIR de Sentinel-2, cuya combinación para este objeto particular no está extensamente explorada en la literatura publicada, generando una oportunidad de ser un punto de partida de desarrollo de una idea innovadora que pueda mejorarse a partir de esta investigación.
- Dataset Curado y Metodología Abierta: La creación de un dataset bien documentado (potencialmente público) y una metodología reproducible para Sentinel-2 aborda una

limitación clave en el campo (Ball et al., 2017) y fomenta la investigación y comparación futuras además de hacerlo reproducible para mejoras.

- Adaptación de Arquitecturas Modernas de DL: Se evaluarán y adaptarán arquitecturas recientes (U-Net, YOLOv5/v7/v8/v11, Mask R-CNN) para manejar la entrada de 4 canales (en lo posible) a la detección de las características espaciales de los silos bolsas (objetos alargados, variables) en la resolución de 10m, buscando optimizar la precisión y eficiencia (Barbiani & Bustamante, 2022; Fernández Marcos, 2023; Iglovikov et al., 2017).
- Análisis Cuantitativo del Aporte del NIR: Se evaluará explícitamente el valor añadido de la banda NIR para discriminar silo bolsas de su entorno, proporcionando evidencia cuantitativa.

Contrastando con propuestas previas:

- Métodos Tradicionales de RS: Supera las limitaciones de métodos basados en índices o clasificadores pixel-a-pixel al capturar contexto espacial y aprender características complejas directamente de los datos, en otras palabras, la utilización de técnicas de DL permitiría diferenciar los silos bolsas de otras estructuras similares que las técnicas tradicionales no permiten diferenciar no encontrado solo variables en el color sino en su ubicación y forma.
- Monitoreo con Drones/Sensores: Aunque precisos, estos métodos son costosos y no escalables para grandes áreas (Gobierno de Argentina, 2023b). La propuesta satelital ofrece cobertura amplia y revisita frecuente a bajo costo o casi nulo. La innovación de la CV ya se aplica en agricultura (e.g., detección de malezas (Aapresid, 2023)), y este trabajo extiende esa tendencia al monitoreo de almacenamiento.
- Trabajo de Barbiani y Bustamante (2022): Se diferencia al enfocarse exclusivamente en Sentinel-2, analizar el rol del NIR, potencialmente usar arquitecturas más recientes y buscar la segmentación (medición) además de la detección además enfocado únicamente en Silos bolsa.
- Trabajos Genéricos de Detección/Segmentación en RS: Se distingue por la especificidad del objeto (silo bolsa), su contexto agrícola, y la adaptación a la resolución y bandas de Sentinel-2.

La innovación principal reside en la adaptación rigurosa y evaluación de herramientas DL avanzadas para automatizar y escalar el monitoreo de un elemento clave de la logística agrícola argentina, utilizando datos satelitales de libre disponibilidad.

Objetivos

Objetivo general:

Desarrollar y validar un modelo de inteligencia artificial basado en Redes Neuronales Convolucionales (CNN) que, a partir de imágenes satelitales multiespectrales (RGB + NIR) del satélite europeo Sentinel-2 y capas de índices derivados, permita identificar, medir y estimar la distribución espacial (detección y/o segmentación) de silo bolsas en la zona núcleo de Argentina más específicamente sobre el departamento de Marcos Juárez Córdoba Argentina, durante el período Abril-Agosto entre los años 2021 y 2025, con el fin de aportar herramientas de monitoreo para la toma de decisiones en la cadena agroindustrial.

Objetivos específicos:

- Construir una base de datos sólida con imágenes Sentinel-2 L2A georreferenciadas, preprocesadas (mosaicos, recortes por área de interés, segmentación en parches) y filtradas (nubes, áreas no agrícolas) para la zona núcleo de Argentina en el período Abril-Agosto entre los años 2021 y 2025.
- Crear un dataset etiquetado (Ground Truth) mediante la anotación semi automática de Áreas de Interés (AOI) correspondientes a silo bolsas (bounding boxes para detección y/o máscaras pixel-wise para segmentación) en un conjunto representativo de parches de imagen, aplicando técnicas de aumento de datos o data aumentación.
- Evaluar y seleccionar distintas arquitecturas de redes neuronales convolucionales adecuadas para la detección (e.g., YOLOv5/v7/v8/v11) y/o segmentación (e.g., U-Net, Mask R-CNN) de silo bolsas en imágenes Sentinel-2 de 4 canales (RGB+NIR).
- Entrenar y optimizar el modelo seleccionado utilizando el dataset creado, empleando técnicas de ajuste de hiperparámetros evaluando el aporte de la banda NIR.
- Generar mapas de predicción y métricas de validación (e.g., Precision, Recall, F1-Score, mAP, IoU) que permitan evaluar la precisión espacial y estadística del método propuesto sobre un conjunto de datos de prueba independiente (posiblemente imágenes del 2025).

Transferencia de los resultados obtenidos.

Los resultados y la metodología desarrollados en este trabajo tendrían un significativo potencial de transferencia a diversas aplicaciones prácticas y ámbitos de investigación.

Fuera del ámbito específico de la solución propuesta (el modelo entrenado y el flujo de trabajo), las aplicaciones prácticas directas podrían beneficiar a:

- Empresas del Sector Agroindustrial (Multinacionales, Acopios, Logística, Consultoras, Aseguradoras): Para obtener estimaciones de stocks regionales, optimizar la planificación logística (rutas de transporte, capacidad de almacenamiento), analizar la competencia, desarrollar nuevos productos de seguro basados en inventarios, o brindar servicios de asesoramiento con datos actualizados.
- Productores o dueños de campo: Para monitoreo y seguimiento de su producción cuantificar entradas, liquidaciones y consumos en todas las explotaciones
- Investigadores y ONGs: Para realizar estudios sobre seguridad alimentaria, cuantificar el impacto ambiental del almacenamiento temporal, o efectuar análisis económicos del sector agrícola basados en datos objetivos de inventario.
- Organismos Gubernamentales (ARCA, Secretarías de Agricultura): Para integrar en sistemas GIS existentes, realizando estimaciones de producción a nivel regional, o monitoreando el uso de recursos y la dinámica del almacenamiento.

La transferencia a un ámbito más amplio, extendiendo la metodología, sería posible mediante:

- Detección/Segmentación de Otros Objetos Agrícolas: Adaptando el flujo de trabajo (preprocesamiento Sentinel-2, creación de dataset, entrenamiento CNN) para detectar/segmentar otros elementos como diferentes tipos de estructuras de riego, áreas de alimentación de ganado (feedlots), sectores avícolas, o incluso patrones espaciales de daño en cultivos o cualquier otro objeto siempre que sean distinguibles a 10m de resolución.
- Aplicación en Otras Regiones Globales: El modelo podría aplicarse a otras zonas agrícolas del mundo (e.g., Brasil, EE.UU., Ucrania) donde se utilicen silo bolsas y se disponga de imágenes Sentinel-2. Sería recomendable un re-entrenamiento fino (fine-tuning) con datos locales para optimizar el rendimiento y adaptarse a posibles variaciones en el entorno o tipos de bolsas.

- **Uso con Otros Sensores Satelitales:** La metodología podría adaptarse para imágenes Landsat (similar resolución espectral, pero 30m espacial) o satélites comerciales de mayor resolución (e.g., PlanetScope a 3-5m), ajustando el preprocesamiento, el tamaño de los parches y reentrenando el modelo. La fusión con datos de radar (Sentinel-1), al ser insensible a nubes, representa una extensión valiosa para asegurar monitoreo continuo (Víctor et al., 2025).

La transferencia efectiva requerirá la publicación de la metodología, la disponibilización (si es posible) del dataset y/o modelos entrenados, una documentación clara de las capacidades y limitaciones, y potencialmente el desarrollo de interfaces o APIs para facilitar su integración en otros sistemas, esto último no será abarcado en este trabajo.

Trabajos relacionados

Problema central (Detección/Segmentación de Silo Bolsas):

El trabajo más directamente relacionado es el de Barbiani y Bustamante (2022) según lo que se pudo averiguar, quienes desarrollaron un detector de pivotes de riego y silo bolsas utilizando YOLOv5. Utilizaron imágenes de Google Earth y Sentinel, creando un dataset mediante etiquetado manual y aumento de datos (incluyendo sintéticos). Su prototipo incluyó una API Flask. Ventajas: Demostraron la viabilidad de usar YOLOv5 para la detección. Desventajas/Diferencias: Usaron fuentes mixtas de imágenes, no se enfocaron exclusivamente en Sentinel-2, no analizaron sistemáticamente el NIR, y se centraron en detección (bounding box) más que en segmentación precisa. La propuesta de este trabajo se centrará exclusivamente en Sentinel-2 L2A (RGB+NIR), creará un dataset específico con anotaciones para segmentación (o detección precisa), evaluará explícitamente el valor del NIR, explorará arquitecturas adecuadas para segmentación/detección utilizando modelos más modernos (U-Net, YOLO, etc.) y buscará mayor robustez en el contexto Sentinel.

Problemas relacionados (Detección/Segmentación de Objetos en RS):

Fernández Marcos (2023) comparó YOLO v3, v5, v7, v8 para detectar objetos (piscinas, paneles solares) en imágenes satelitales, favoreciendo YOLOv7 para detección. Tapia Catacora (2023) utilizó U-Net para segmentar deforestación en imágenes Landsat-8, logrando alta precisión (98.6%) y demostrando la efectividad de U-Net para segmentación pixel-wise en RS. Iglovikov et al. (2017) adaptaron U-Net para segmentación multispectral, manejando múltiples canales y

efectos de borde. Muñoz et al. (2007) detectaron incendios sub-píxel en baja resolución. Ventajas: Establecen metodologías para aplicar DL (detección y segmentación) en RS, comparan arquitecturas (YOLO vs U-Net) y abordan desafíos multiespectrales/resolución. Desventajas/Diferencias: No se enfocan en silo bolsas; resoluciones y objetos varían. La propuesta de este trabajo aplicará principios de DL al caso específico de silo bolsas en Sentinel-2, evaluando arquitecturas tanto de detección (YOLO) como de segmentación (U-Net, informado por Tapia Catacora, 2023), adaptando la entrada RGB+NIR (Iglavik et al., 2017).

Identificaron previamente el problema (Contexto General DL en RS/Agricultura):

Ball et al. (2017) y Zhang et al. (2016) realizaron surveys sobre DL en RS, identificando tendencias y desafíos (datos limitados, interpretabilidad). Víctor et al. (2025) revisaron DL para agricultura con imágenes satelitales, notando brechas en áreas más allá de uso y cobertura del suelo por falta de datasets. Ventajas: Proveen marco contextual, identifican desafíos (datos, Ball et al., 2017) y validan relevancia de DL en RS para agricultura de precisión AP. Desventajas/Diferencias: Generales, no específicos a silo bolsas. La propuesta de este trabajo aplica DL a un problema agrícola específico y aborda el desafío de crear datos para segmentación/detección de esta infraestructura.

Misma metodología (Segmentación/Detección con DL en RS):

Además de los trabajos mencionados, otros han empleado arquitecturas CNN para tareas similares. Tapia Catacora (2023) es un ejemplo relevante de uso de U-Net para segmentación en Landsat. Para detección, Barbiani y Bustamante (2022) y Fernández Marcos (2023) son referencias clave con YOLO. Otros trabajos citados por Ball et al. (2017) usan FCNs, R-CNNs para segmentación/detección de edificios, caminos, etc. Ventajas: Demuestran aplicabilidad general de CNNs (U-Net, YOLO, etc.) en RS. Desventajas/Diferencias: Objetos, resoluciones y arquitecturas específicas varían. La propuesta de este trabajo seleccionará y adaptará una metodología CNN (probablemente U-Net o YOLO) específicamente para las características de silo bolsas y datos Sentinel-2 (10m, 4 canales), enfocándose en la creación de un dataset adecuado y la evaluación del NIR.

Metodología

- Tipo de estudio: Investigación aplicada de tipo cuantitativo, utilizando técnicas de Aprendizaje Automático (Machine Learning), específicamente Deep Learning para Detección de Objetos y/o Segmentación Semántica, para resolver un problema práctico en el ámbito agrícola.
- Emplazamiento: El trabajo se realizará computacionalmente. El área geográfica de estudio para la adquisición de imágenes Sentinel-2 se centrará en la zona núcleo de Argentina (Específicamente en el Departamento Marcos Juárez, Córdoba) durante las temporadas relevantes para el almacenamiento de granos denominados “grueso” en silo bolsas, es decir, post cosecha de maíz, soja y Girasol en el periodo invernal o de barbecho (abril-agosto de 2021 a 2025). El desarrollo y entrenamiento del modelo se realizará utilizando recursos informáticos de uso personal limitados sin uso de GPU.
- Población, criterios de inclusión/exclusión, selección: La población son todas las imágenes Sentinel-2 L2A disponibles sobre el área de estudio en el período seleccionado. Criterios de inclusión: Imágenes con bajo porcentaje de cobertura nubosa ($< 10\text{-}20\%$) sobre las zonas agrícolas de interés. Criterios de exclusión: Imágenes con alta nubosidad, sombras extensas, zonas altamente pobladas, descartando la mayor porción posible de superficies ajenas o que no sean suelo agrícola. Selección: Se descargarán, filtrarán y post procesaran las imágenes que cumplan los criterios de inclusión para formar la base del dataset.
- Variables:
 - Variables de Entrada (Predictoras): Valores de reflectancia de superficie de las bandas Sentinel-2 B2 (Azul), B3 (Verde), B4 (Rojo) y B8 (Infrarrojo Cercano - NIR) de 10m de resolución. Los datos se organizarán en parches de imagen (e.g., 256x256 o 640x640 píxeles), representando porciones más pequeñas y manejables para evitar sobrecarga de la red.
 - Variable de Salida (Objetivo): Dependiendo del enfoque se buscarán ambas salidas, detección o segmentación, donde el primero únicamente detecta ubicación y el segundo no solo lo detecta, sino que mide sus dimensiones:
 - Detección: Conjunto de detecciones (coordenadas de bounding box, clase='silo bolsa', porcentaje de confianza).
 - Segmentación: Máscara binaria (mapa de píxeles) del mismo tamaño que el parche de entrada, donde cada píxel se clasifica como 'silo bolsa' o 'fondo'.
- Métodos y técnicas de recogida de datos:

- Imágenes Satelitales: Adquisición de datos Sentinel-2 L2A (reflectancia de superficie) a través de plataformas como Copernicus Data Space Ecosystem, AWS Open Data Registry (AWS Open Data Registry, n.d.), Google Earth Engine.
- Etiquetas (Ground Truth): Creación semi automática de etiquetas mediante software GIS (e.g., QGIS) o herramientas de anotación específicas (e.g., LabelMe, CVAT). Se generaran índices de exposición de colores blandos vs. Resto de colores para reclasificarlos , filtrarlos para dar con una capa base de inicio donde se detectaran el grueso de silos bolsa sumado a otras variables similares como bordes de campo, caminos , etc que deberán ser limpiados manualmente, finalmente se identificarán visualmente las silo bolsas y se generarán las AOI (polígonos/máscaras para segmentación o rectángulos para detección), guardando en formato estándar (e.g., GeoJSON, Shapefile, COCO, YOLO).
- Análisis de datos:
 - Preprocesamiento: Generación de mosaicos sin nubes, normalización de valores de píxel, apilamiento de bandas, generación de parches (e.g., 256x256 o 640x640 píxeles).
 - Aumento de Datos: Aplicación de transformaciones geométricas (rotación, volteo, escalado) y fotométricas (brillo, contraste, ajustes de color) a los parches de entrenamiento (Barbiani & Bustamante, 2022; Ball et al., 2017), en este paso será prudente probar técnicas de convolucionado para aumentar el número de pixeles para evitar errores de bajo número de pixeles.
 - Entrenamiento del Modelo: Uso de un framework de DL (e.g., PyTorch, TensorFlow/Keras). Implementación de la arquitectura seleccionada (e.g., U-Net, YOLO). Función de pérdida apropiada (e.g., Dice Loss/Cross-Entropy para segmentación, YOLO loss para detección). Monitorización en validación para ajuste de hiperparámetros y control de overfitting.
 - Evaluación del Modelo: Cálculo de métricas sobre el conjunto de prueba: Para segmentación (Precision, Recall, F1-Score pixel-wise); Para detección (Precision, Recall, F1-Score, mAP@0.5, IoU para boxes). Análisis de matriz de confusión. Comparación RGB vs RGB+NIR (Tapia Catacora, 2023; Barbiani & Bustamante, 2022; Fernández Marcos, 2023).

- Desde una perspectiva puramente ética, el desarrollo de un tipo de herramienta que pueda generar una ubicación y dimensionamiento preciso de este tipo de información únicamente para algunas empresas, puede representar una ventaja competitiva frente a otro tipo de compañías con menos acceso a la información, generando una inequidad, por lo tanto en este trabajo no se buscara publicar ningún tipo de información personal si seleccionada sino que es con un fin netamente académico y con un foco muy acotado, deja abierta a posibilidades de crecimiento para otros autores que deberán seguir el mismo foco que se persigue en este proyecto de tesis. Esta información podría ser utilizado con fines pocos éticos para estimar stock o revelar información que pueda ser utilizado para fines de lucro propios de cada organización, además teniendo en cuenta de que los resultados de este trabajo pueden no ser 100% precisos en un comienzo dando inclusive información que no puede ser considerada 100% como fidedigna para tomar acciones de fiscalización.
- Aspectos legales: Desde un inicio se plantea el uso de información completamente de acceso, descarga y uso libre y gratuita que como un primer inicio marca un punto de partida dentro del acceso legal a la información, de todas formas, existen limitaciones en términos de manipulación y generación de información. Según la Ley 25.326 de protección de datos personales de la república Argentina protege a las personas de la privacidad y secreto comercial de su explotación por lo que este trabajo debe respetar con todo el poder de la ley no exponer ni publicar ningún valor asociado directamente al campo, dueño y cantidad producida sin recibir previamente su consentimiento, por lo que a modo netamente de investigación se trataran resultados con estadísticas globales y en el caso de apuntar a casos específicos no se publicara ni ubicación geográfica precisa ni se expondrá información que pueda poner en violación dicha ley.
- Limitaciones del estudio: Precisión limitada por resolución 10m, disponibilidad de imágenes en diferentes fechas, calidad/tamaño del dataset manual, generalización a otras regiones.

Plan de Trabajo

Fase 1: Investigación y Planificación (1 Mes)

- T1.1: Revisión Bibliográfica y Prueba de concepto (Semana 1 - Semana 3, 3 semanas)
 - Búsqueda de trabajos similares, presentación de idea con director de tesis, primeras pruebas de concepto.

- T1.2: Definición Final del Alcance y Metodología (Semana 3 - Semana 4, 1 semana)
 - Ajustar objetivos, seleccionar herramientas, definir métricas, refinar área de estudio y foco.
- T1.3: Escritura Plan de Trabajo Final (Semana 4 - Semana 4, 1 semana)
 - Redactar y refinar este documento.

Fase 2: Adquisición y Preparación Datos (2 Meses)

- T2.1: Definición Área y Período de Estudio (Mes 2 Semana 1 - Mes 2 Semana 1, 1 semana)
 - Posterior a aprobación de plan de trabajo final: Seleccionar zona núcleo (departamento de Marcos Juárez) y período Abril-Agosto 2021 a 2025.
- T2.2: Adquisición de Imágenes Sentinel-2 (Mes 2 Semana 1 - Mes 2 Semana 3, 3 semanas)
 - Descargar/acceder a imágenes Sentinel L2A requeridas.
- T2.3: Preprocesamiento de Imágenes (Mes 2 Semana 3 - Mes 3 Semana 1, 2 semanas)
 - Aplicar máscaras de nubes, apilar bandas (RGB+NIR), normalizar, generar parches.
- T2.4: Etiquetado Manual (Dataset Inicial) (Mes 3 Semana 1 - Mes 3 Semana 4, 4 semanas)
 - Anotar silo bolsas (máscaras/boxes) en subconjunto representativo.
- T2.5: Implementación Aumento de Datos (Mes 3 Semana 4 - Mes 4 Semana 1, 1 semana)
 - Desarrollar/adaptar scripts para aplicar data augmentation.
- T2.6: Generación Dataset Final (Mes 4 Semana 1 - Mes 4 Semana 1, 1 semana)
 - Aplicar aumento, dividir en Train/Validation/Test sets, verificar formatos.

Fase 3: Desarrollo y Entrenamiento (3 Meses)

- T3.1: Selección e Implementación Modelo DL (Mes 4 Semana 2 - Mes 4 Semana 3, 2 semanas)
 - Elegir arquitectura (U-Net/YOLO/etc.), adaptar código para 4 canales (de ser posible).
- T3.2: Configuración Entorno Entrenamiento (Mes 4 Semana 3 - Mes 4 Semana 4, 1 semana)
 - Preparar entorno, instalar librerías.
- T3.3: Entrenamiento Inicial (Baseline) (Mes 5 Semana 1 - Mes 5 Semana 4, 4 semanas)

- Entrenar modelo (RGB+NIR) con hiperparámetros iniciales, monitorizar validación.
- T3.4: Ajuste de Hiperparámetros (Mes 6 Semana 1 - Mes 6 Semana 3, 3 semanas)
 - Experimentar con learning rate, batch size, etc., para mejorar rendimiento.
- T3.5: Entrenamiento Comparativo (RGB) (Mes 6 Semana 4 - Mes 7 Semana 1, 2 semanas)
 - Entrenar modelo solo con RGB usando hiperparámetros optimizados.
- T3.6: Entrenamiento Final (RGB+NIR) (Mes 7 Semana 2 - Mes 7 Semana 2, 1 semana)
 - Reentrenar modelo RGB+NIR final con configuración óptima.

Fase 4: Evaluación y Análisis (1 Mes)

- T4.1: Evaluación Cuantitativa (Mes 7 Semana 3 - Mes 7 Semana 4, 2 semanas)
 - Ejecutar modelos en Test set. Calcular métricas (IoU, mAP, Precision, Recall, etc.).
- T4.2: Análisis Comparativo (Mes 8 Semana 1 - Mes 8 Semana 2, 2 semanas)
 - Comparar rendimiento RGB vs RGB+NIR. Analizar errores.
- T4.3: Análisis Cualitativo (Mes 8 Semana 2 - Mes 8 Semana 3, 1 semana)
 - Visualizar resultados, identificar casos difíciles vs sencillos.

Fase 5: Escritura y Defensa TFM (2 Meses)

- T5.1: Redacción Borrador Tesis (Mes 8 Semana 3 - Mes 9 Semana 4, 6 semanas)
 - Escribir secciones del documento final.
- T5.2: Revisión y Corrección (Mes 10 Semana 1 - Mes 10 Semana 2, 2 semanas)
 - Revisar con tutores, incorporar feedback.
- T5.3: Entrega Versión Final Tesis (Mes 10 Semana 3 - Mes 10 Semana 3, 1 semana)
 - Entregar documento final.
- T5.4: Preparación Defensa (Mes 10 Semana 3 - Mes 10 Semana 4, 1 semana)
 - Preparar presentación oral.
- T5.5: Defensa Tesis (Mes 10 Semana 4 - Mes 10 Semana 4, 1 día)
 - Presentar y defender el trabajo final.

Referencias

Aapresid. (2023). Aplicaciones selectivas: indagamos quiénes adoptaron. Aapresid Blog. <https://www.aapresid.org.ar/blog/aplicaciones-selectivas-indagamos-quienes-adoptaron>

AWS Open Data Registry. (s.f.). Sentinel-2. Recuperado el 26 de octubre de 2025, de <https://registry.opendata.aws/sentinel-2/>

Ball, J. E., Anderson, D. T., & Chan, C. S. (2017). Comprehensive survey of deep learning in remote sensing: theories, tools, and challenges for the community. *Journal of Applied Remote Sensing*, 11(4), 042609. <https://doi.org/10.1117/1.JRS.11.042609>

Barbiani, G., & Bustamante, L. (2022). Detector de Pivotes de Riego y Silo bolsas en Imágenes Satelitales para aplicaciones agrícolas [Proyecto Integrador, Ingeniería en Computación]. Universidad Nacional de Córdoba.

Copernicus. (s.f.). Sentinel-2 Data Collection. Copernicus Data Space Ecosystem. Recuperado el 26 de octubre de 2025, de <https://dataspace.copernicus.eu/data-collections/copernicus-sentinel-data/sentinel-2>

CREA. (2023). Aplicaciones dirigidas: estado actual y futuro. Contenidos CREA. <https://www.contenidoscrea.org.ar/agricultura/aplicaciones-dirigidas-estado-actual-y-futuro-n5326635>

Expoagro. (2025). Silobolsa: el invento argentino que soluciona problemas globales. Expoagro Digital. <https://www.expoagro.com.ar/silobolsa-el-invento-argentino-que-soluciona-problemas-globales/>

Fernández Marcos, S. (2023). Sistema de reconocimiento de patrones en imágenes satelitales para la detección de objetos [Trabajo de Fin de Máster, Universidad de Salamanca].

Filgueira, E. (2013). Silo Bolsa. C3T-UTN. <https://c3t-utn.ar/wp-content/uploads/2013/07/Silo-Bolsa.pdf>

GISGeography. (s.f.). Sentinel-2 bands and combinations. Recuperado el 26 de octubre de 2025, de <https://gisgeography.com/sentinel-2-bands-combinations/>

Gobierno de Argentina. (2025a). Más del 40% de la producción nacional se conserva en silobolsas. Argentina.gob.ar. <https://www.argentina.gob.ar/noticias/mas-del-40-de-la-produccion-nacional-se-conserva-en-silobolsas>

Gobierno de Argentina. (2025b). Monitoreo inteligente para preservar la calidad de los granos. Argentina.gob.ar. <https://www.argentina.gob.ar/noticias/monitoreo-inteligente-para-preservar-la-calidad-de-los-granos>

Iglovikov, V., Mushinskiy, S., & Osin, V. (2017). Satellite Imagery Feature Detection using Deep Convolutional Neural Network: A Kaggle Competition. arXiv. <https://arxiv.org/abs/1706.06169>

INTA. (s.f.). Almacenamiento de granos en bolsas plásticas. Agroconsultas Online. Recuperado el 26 de octubre de 2025, de https://aws.agroconsultasonline.com/comentario.html/script-tmp-inta_almacen_granos14.pdf?op=d&comentario_id=8673&orden=1

Muñoz, C., Acevedo, P., Salvo, S., Fagalde, G., & Vargas, F. (2007). Detección de incendios forestales utilizando imágenes NOAA/16-LAC en la Región de La Araucanía, Chile. BOSQUE, 28(2), 119-128. <http://dx.doi.org/10.4067/S0717-92002007000200003>

Muzlera, J. (2024). Silo bolsa (Argentina, 1991-2023). En J. Muzlera & A. Salomón (Eds.), Diccionario del agro iberoamericano (5.^a ed. ampliada). Alejandra Laura Salomón. <https://www.teseopress.com/diccionarioagro/chapter/silo-bolsa-argentina-1991-2023/>

Tapia Catacora, P. C. (2023). Detección de deforestación de bosques en imágenes satelitales con redes neuronales convolucionales [Tesis Doctoral, Universidad Nacional del Altiplano]. Repositorio Institucional UNA-PUNO. <http://repositorio.unap.edu.pe/handle/UNAP/19875>

Victor, B., Nibali, A., & He, Z. (2025). A systematic review of the use of Deep Learning in Satellite Imagery for Agriculture. arXiv. <https://arxiv.org/abs/2210.01272>

Zhang, L., Zhang, L., & Du, B. (2016). Deep Learning for Remote Sensing Data: A technical tutorial on the state of the art. IEEE Geoscience and Remote Sensing Magazine, 4(2), 22-40. <https://doi.org/10.1109/MGRS.2016.2540798>