

MAESTRÍA EN EXPLOTACIÓN DE DATOS Y GESTIÓN DEL CONOCIMIENTO

Plan de Trabajo Final

—

Detección de silo-bolsas mediante técnicas de aprendizaje profundo en imágenes satelitales Sentinel-2 para el departamento de Marcos Juárez, zona núcleo de Argentina

—

Alumno: Federico Richard

Tutor: Gonzalo Sad

Resumen

El monitoreo de granos almacenados en silo-bolsas (una tecnología que resguarda cerca del 40 % de la producción agrícola argentina) es fundamental para la toma de decisiones en la cadena agroindustrial. Sin embargo, no existe un mecanismo escalable, frecuente y de bajo costo para estimar de manera objetiva su distribución. Este trabajo desarrolla y valida un detector de silo-bolsas en imágenes satelitales Sentinel-2 (RGB, 10 m de resolución) para el departamento de Marcos Juárez, en la zona núcleo de Argentina, durante el período junio–agosto de 2020 a 2025.

El aporte central es metodológico. Más que comparar arquitecturas o diferentes bandas espectrales, el trabajo examina empíricamente en qué medida la calidad de las etiquetas o anotaciones de entrenamiento (Ground truth) condiciona el desempeño del modelo: etiquetas curadas manualmente frente a etiquetas ruidosas autogeneradas mediante un índice espectral. Para ello se implementa un pipeline modular de procesamiento, un método de etiquetado semiautomático (índice espectral INBNV) con curación manual utilizando sistemas de información geográfica GIS, y una progresión controlada de cuatro versiones de un modelo de redes neuronales Faster R-CNN con ResNet50-FPN entrenados para tal fin, utilizando recursos de baja infraestructura (CPU). La banda del infrarrojo cercano (NIR) no se utiliza como entrada del modelo (que es únicamente RGB), sino exclusivamente para generar las etiquetas de manera automática.

El resultado principal es un hallazgo de eficiencia de datos: un conjunto pequeño y limpio (de pocas imágenes) iguala o supera a uno sustancialmente mayor pero ruidoso (sin curar ni corregir). La solución ofrece una herramienta escalable y de bajo costo para apoyar la toma de decisiones de actores públicos y privados, y aporta evidencia, sobre un caso real, de que invertir el presupuesto de anotación en calidad puede rendir más que invertirlo en cantidad.

Abreviaturas y palabras clave

Palabras clave

- Agricultura de precisión
- Aprendizaje profundo (Deep Learning, DL)
- Calidad de etiquetas
- Detección de objetos
- Silo-bolsas
- Teledetección (Remote Sensing, RS)
- Sistemas de Información Geográfica (SIG / GIS)
- Imágenes satelitales
- Sentinel-2

Abreviaturas

- DL: Deep Learning (Aprendizaje profundo)

- RS: Remote Sensing (Teledetección)
- SIG / GIS: Sistemas de Información Geográfica / Geographic Information Systems
- NIR: Near Infrared (Infrarrojo cercano)
- RGB: Red, Green, Blue
- INBNV: Índice espectral propuesto (Índice Normalizado basado en Visible y NIR)
- Faster R-CNN: Faster Region-based Convolutional Neural Network
- CNN: Convolutional Neural Network
- FPN: Feature Pyramid Network
- IoU: Intersection over Union
- AP: Average Precision
- GT: Ground Truth (Verdad de terreno)
- CPU: Central Processing Unit
- AWS: Amazon Web Services
- MGRS: Military Grid Reference System
- SCL: Scene Classification Layer
- GSD: Ground Sample Distance

Motivación e importancia del tema de estudio

El monitoreo en el sector agropecuario mediante teledetección (Remote Sensing, RS) se ha vuelto fundamental debido a la creciente necesidad de optimizar la producción de alimentos y gestionar los recursos de manera eficiente. La aplicación de estas tecnologías se denomina Agricultura de Precisión: observar, medir y responder frente a la variabilidad inter e intracampo mediante el uso de tecnologías para optimizar decisiones basadas en datos. Dado que se trata de medir y observar, el uso de sensores remotos (Como drones o imágenes satelitales) es una de las principales tecnologías de la Agricultura de Precisión. Las imágenes Sentinel-2, del proveedor europeo Copernicus (Copernicus, s.f.) ofrecen cobertura global frecuente y datos multispectrales valiosos con una resolución espacial adecuada (10 m) para aplicaciones agrícolas (Victor et al., 2025; Zhang et al., 2016). El desafío reside en extraer valor de estos datos: la extracción de información específica, como la ubicación y cantidad de silo-bolsas, sigue siendo un problema poco explorado.

El silo-bolsa es una estructura plástica oblonga, de polietileno de baja densidad, para el almacenamiento hermético y temporal de granos secos y forraje (Muzlera, 2024). Originado en Alemania en los años 60, se popularizó en Argentina en los 90, y el desarrollo del INTA lo transformó en un dispositivo apto para soja, maíz y trigo (Muzlera, 2024; Expoagro, 2025). Permite almacenar la cosecha entre 6 meses y 2 años (INTA, s.f.), habilitando estrategias comerciales como la venta futura o fuera de temporada, así como herramientas de autofinanciación. Cerca del 40 % de la producción agrícola argentina se almacena en silo-bolsas (Gobierno de Argentina, 2025a), pero ese valor fluctúa por factores económicos, necesidades de los productores y logística, lo que dificulta una estimación precisa del grano almacenado en frecuencias

acotadas de tiempo (por ejemplo, semanales). Esta información es crucial para grandes empresas agrícolas, acopios, exportadoras, aseguradoras, productores y organismos públicos.

Los avances en Deep Learning (DL) y Visión por Computadora han demostrado capacidades extraordinarias para el análisis automático de imágenes (Ball et al., 2017; Zhang et al., 2016). Un claro ejemplo, ajeno al objetivo de este trabajo, pero muy relacionado, es la utilización de aplicaciones selectivas con sensores en los botallones de las pulverizadoras para detectar malezas mediante DL, aplicando producto únicamente sobre la maleza y ahorrando insumos (CREA, 2023). Aplicar estas técnicas a imágenes satelitales para detectar silo-bolsas representa una oportunidad de automatizar y escalar un monitoreo hoy costoso. Los beneficios esperados incluyen: mayor eficiencia y menor costo frente al monitoreo manual; cobertura consistente de grandes extensiones; datos objetivos y actualizados sobre la distribución del almacenamiento; y una base metodológica aplicable a la detección de otros objetos agrícolas.

Requerimientos y desafíos

La detección de objetos en imágenes satelitales mediante DL es un campo activo (Ball et al., 2017; Zhang et al., 2016). Los detectores modernos se agrupan en dos familias según cómo localizan los objetos (Zou et al., 2023). Los detectores de una etapa (por ejemplo, modelos como YOLO) predicen la clase y la posición del objeto en una única pasada sobre la imagen, lo que los hace muy rápidos (aptos para tiempo real). Los detectores de dos etapas (la familia R-CNN) trabajan en dos pasos: primero proponen regiones candidatas donde podría haber un objeto y luego, sobre cada una, clasifican y ajustan la caja con detalle; este paso adicional los vuelve más lentos, pero más precisos en la localización (Zou et al., 2023). Dado que en este trabajo no se requiere procesamiento en tiempo real, sino la localización precisa de objetos pequeños y alargados utilizando imágenes de 10 m de resolución, con una frecuencia semanal, mensual o por temporada, se adopta un detector de dos etapas como las redes neuronales convolucionales basadas en regiones (R-CNN). La combinación Faster R-CNN con ResNet50-FPN constituye una línea de base robusta, y es la arquitectura adoptada en este trabajo. El antecedente más directo, Barbiani y Bustamante (2022), abordó la detección de pivotes y silo-bolsas con YOLOv5 (un detector de una etapa) sobre fuentes mixtas, sin enfocarse exclusivamente en Sentinel-2 ni analizar la calidad de las etiquetas.

El cuello de botella de estos enfoques rara vez es el modelo: es el dato etiquetado. Entrenar un detector supervisado exige un conjunto de verdad de terreno donde cada silo-bolsa esté delimitada por un analista. Construir ese conjunto, sobre objetos pequeños y poco contrastados a 10 m, es lento, costoso y propenso a errores (Ball et al., 2017). De allí surge la pregunta central sobre la estrategia metodológica que estructura el tema de este trabajo: ante un presupuesto de etiquetado limitado, ¿conviene invertir en muchas etiquetas autogeneradas (y por consiguiente ruidosas o con errores) o en pocas etiquetas curadas con alta calidad?

La utilidad concreta es proporcionar una herramienta automatizada que procese imágenes Sentinel-2 para generar reportes sobre la ubicación y cantidad de silo-bolsas en la zona productiva de Argentina, concentrando el foco de estudio en el departamento de Marcos Juárez provincia de Córdoba como alcance inicial. El aporte principal radica en: un método reproducible de etiquetado semiautomático que

reduce el costo de anotación; evidencia cuantitativa, sobre un caso real, del efecto de la calidad de las etiquetas; un pipeline modular para la detección de objetos pequeños en imágenes satelitales Sentinel-2; y la adaptación de un detector de dos etapas a la geometría alargada de los silo-bolsas a 10 m de resolución.

Problemas no resueltos

El problema puntual a resolver es la digitalización automática (detección y localización) de silo-bolsas a partir de imágenes Sentinel-2. Aunque existen métodos generales (Zhang et al., 2016; Ball et al., 2017) y un antecedente puntual (Barbiani y Bustamante, 2022), persisten desafíos específicos:

- **Disponibilidad y calidad de etiquetas.** La creación de datasets de silo-bolsas para Sentinel-2 es un cuello de botella fundamental: no existen datasets públicos, y el GT debe construirse desde cero. Más aún, poco se ha estudiado el efecto de la calidad de ese GT sobre el desempeño del modelo, cuestión central de este trabajo (Frénay y Verleysen, 2014; Northcutt et al., 2021).
- **Optimización para Sentinel-2 (10 m).** Los silo-bolsas son objetos pequeños desde la perspectiva satelital en términos de satélites de resolución media como Sentinel 2A (pocos píxeles de ancho) y marcadamente alargados. A esta resolución, una proporción de las bolsas más pequeñas resulta sub-resolución y, por lo tanto, indetectable para cualquier modelo, lo que fija un techo de exhaustividad impuesto por la física del sensor.
- **Robustez y generalización.** Los modelos deben ser robustos a variaciones de apariencia (color, sombra, entorno) entre años secos y húmedos, y generalizar a años no vistos (Zhang et al., 2016; Ball et al., 2017).
- **Manejo de nubes y artefactos.** Las imágenes ópticas requieren un preprocesamiento efectivo de nubes y sombras (Victor et al., 2025; Ball et al., 2017).

La importancia del problema radica en el rol central de los silo-bolsas. La falta de un monitoreo eficiente afecta las estimaciones de producción, la logística, la transparencia del mercado y el control fiscal. Aunque existen métodos con sensores o drones para supervisar la integridad de la bolsa (Gobierno de Argentina, 2025b), el uso de satélites permite escalar el servicio a un costo más bajo y con una revisita frecuente.

Solución propuesta

La solución consiste en desarrollar e implementar un sistema basado en Deep Learning para la detección automática de silo-bolsas en imágenes Sentinel-2. Se adopta la arquitectura Faster R-CNN con ResNet50-FPN (He et al., 2016; Lin et al., 2017; Ren et al., 2015), por su robustez y simpleza en términos computacionales, en localización de objetos. La entrada del modelo es de tres canales (RGB). La banda del infrarrojo cercano (NIR) no se utiliza como entrada, sino exclusivamente para generar las etiquetas mediante un índice espectral, según se explica más abajo.

Dada la geometría pequeña y alargada de los silo-bolsas, se personalizan las cajas de anclaje del detector: escalas reducidas (16, 32, 64, 128 y 256 píxeles) y relaciones de aspecto variadas, de modo de cubrir tanto las bolsas vistas a lo largo como a lo ancho.

El sistema sigue estos pasos, organizados como un pipeline modular:

1. **Descarga de imágenes.** Acceso a datos Sentinel-2 L2A desde el repositorio público de AWS (AWS Open Data Registry, s.f.), restringido a las teselas MGRS que cubren el área de estudio (Las mismas llevan el índice MGRS: 20HNH / 20HNJ) y a las bandas B02, B03, B04 (RGB) y B08 (NIR) a 10 m, más la capa de clasificación de escena (SCL) a 20 m, esta última utilizada como máscara para la detección de nubes.
2. **Composición, mosaico y recorte.** Apilado de bandas, enmascaramiento de nubes a partir de la SCL, mosaico por escena y recorte a la zona agrícola del departamento Marcos Juárez mediante una capa vectorial, descartando superficies no productivas. Como resultado de esta etapa queda una capa completamente limpia con la zona agrícola exclusivamente (sin caminos, cascos, ciudades, lagos, etc.) y sin presencia de nubes.
3. **Teselado.** División en parches de 1024×1024 píxeles con solapamiento (para evitar zonas de no lectura por corte), preservando la georreferenciación para reconstruir la posición de las detecciones.
4. **Etiquetado semiautomático (índice INBNV).** Sobre cada parche se calcula el índice INBNV, definido como $INBNV = ((Verde + Rojo) - NIR) / ((Verde + Rojo) + NIR)$, que realza las superficies brillantes y poco vegetadas (como el plástico de los silo-bolsas) frente al resto de la escena. Por umbralización (percentil 99,8) se obtiene una capa de polígonos candidatos. Esta capa contiene una proporción elevada de falsos positivos (del orden del 50 %), porque el índice también responde a bordes de lotes, caminos y techos. Lejos de ser un defecto, esto define la tarea de curación.
5. **Curación manual en GIS.** Se extrae una capa de candidatos (mediante segmentación de localización geográfica y tiempo) utilizada como base de entrenamiento donde se corrige manualmente (eliminar falsos positivos, ajustar polígonos válidos, agregar las bolsas no detectadas por el índice). Esto representará una capa más reducida pero curada para el entrenamiento de uno de los modelos.
6. **Diseño experimental (en versionados).** Se define una progresión de cuatro versiones que mantienen fija la arquitectura y varían de manera controlada el conjunto de entrenamiento: V2 (etiquetas ruidosas, ~600 imágenes, línea de base); V3 (ruidosas, ~600, muestreo aleatorio y aumento de datos); V4 (ruidosas, ~10.000, muestreo estratificado); y V5 (curadas manualmente, 216, muestreo estratificado balanceado por estrato año-mes con control de distancia entre teselas). La comparación clave es V4 frente a V5: misma arquitectura, diferencia esencial en la calidad de las etiquetas.
7. **Entrenamiento.** Entrenamiento en CPU (sin GPU) buscando escalabilidad y simpleza computacional.
8. **Evaluación.** Se evalúa sobre un conjunto de prueba (Reserva) con verdad de terreno curada (no con la capa ruidosa del índice originadas con INBNV), excluyendo las imágenes vistas en

entrenamiento. Se computan Precisión, Recall, F1 y AP (con umbral de IoU de 0,15, por el tamaño reducido de los objetos), con un umbral de confianza de 0,5 como punto de corte.

Limitaciones de la solución:

- **Resolución (10 m):** Puede limitar la detección precisa de silo-bolsas muy pequeñas (e.g., < 20 píxeles), agrupadas o parcialmente visibles. Un silo-bolsa típico (60m x 3-5m) ocuparía aprox. 6x1 píxeles, dificultando la captura del ancho, pero no el largo. Esto de todas formas es esperanzador ya que se pueden llegar a estimar algunos factores de medición ya que los silo-bolsas presentan medidas estándares de aproximadamente 75 metros de largo y 2,70 metros de diámetro (Filgueira, 2013)
- **Cómputo:** el entrenamiento en CPU condicionó el tamaño del modelo y los tiempos; cubrir áreas mayores requeriría más infraestructura.
- **Variabilidad temporal/atmosférica:** la apariencia cambia entre años secos y húmedos; se entrena con varios años (2020 a 2025) para abarcar esa variabilidad. Además, la superficie cambia intra año de acuerdo al cambio en la superficie (cultivo vs rastrojo)
- **Confusión:** Posible confusión con objetos alargados y reflectantes similares como bordes de ríos, caminos, galpones, etc.
- **Sitio específico:** Posible sesgo a únicamente detectar correctamente los silo-bolsas al área y años del cual fue entrenado el modelo.

Ampliaciones futuras: incorporación explícita del NIR como cuarto canal de entrada (evaluando si aporta frente a RGB); segmentación para estimar dimensiones y volúmenes; fusión con radar (Sentinel-1) para operación independiente de nubes; mayor resolución (imágenes comerciales como drones o satélites de mayor resolución); y generalización a otras regiones con fine tuning.

Grado de innovación de la propuesta tecnológica

La propuesta presenta un grado de innovación relevante al situar en el centro del análisis una pregunta metodológica de interés general, el efecto de la calidad de las etiquetas, sobre un problema específico y de alto impacto, con datos satelitales públicos. Las características innovadoras clave son:

- **Enfoque en la calidad del dato (paradigma centrado en los datos).** En lugar de variar la arquitectura, se varía sistemáticamente la calidad del conjunto de entrenamiento para medir su efecto. El hallazgo hipotético, que un conjunto pequeño y limpio iguala o supera a uno sustancialmente mayor pero ruidoso, es un resultado de eficiencia de datos que trasciende el caso de los silo-bolsas e interpela a cualquier proyecto de aprendizaje supervisado con etiquetado costoso (Frénay y Verleysen, 2014; Northcutt et al., 2021), con un foco especial en imágenes satelitales de resolución media.
- **Etiquetado semiautomático mediante índice espectral (INBNV).** El uso del NIR para generar una capa base de candidatos reduce sustancialmente el costo de anotación y constituye una contribución reproducible para la construcción de verdad de terreno en teledetección.

- **Dataset Curado y Metodología Abierta.** La creación de un dataset bien documentado (potencialmente público) y una metodología reproducible para Sentinel-2 aborda una limitación clave en el campo (Ball et al., 2017) y fomenta la investigación y comparación futuras además de hacerlo reproducible para mejoras.
- **Adaptación de un detector de dos etapas (R-CNN) a objetos pequeños y alargados.** La personalización de las cajas de anclaje (escalas reducidas y relaciones de aspecto extremas) es necesaria para la detectabilidad a 10 m de resolución.

Contrastando con propuestas previas:

- **Métodos Tradicionales de RS:** Supera las limitaciones de métodos basados en índices o clasificadores pixel-a-pixel al capturar contexto espacial y aprender características complejas directamente de los datos, en otras palabras, la utilización de técnicas de DL permitiría diferenciar los silo-bolsas de otras estructuras similares que las técnicas tradicionales no permiten diferenciar no encontrado solo variables en el color sino en su ubicación y forma.
- **Monitoreo con Drones/Sensores:** Aunque precisos, estos métodos son costosos y no escalables para grandes áreas (Gobierno de Argentina, 2025b). La propuesta satelital ofrece cobertura amplia y revisita frecuente a bajo costo o casi nulo. La innovación de la CV ya se aplica en agricultura (e.g., detección de malezas (Aapresid, 2023)), y este trabajo extiende esa tendencia al monitoreo de almacenamiento.
- **Trabajo de Barbiani y Bustamante (2022):** Se diferencia al enfocarse exclusivamente en Sentinel-2, analizar el rol del NIR, potencialmente usar arquitecturas más recientes y buscar la segmentación (medición) además de la detección sumado a que este trabajo estará enfocado únicamente en silo-bolsas.
- **Trabajos Genéricos de Detección/Segmentación en RS:** Se distingue por la especificidad del objeto (silo-bolsas), su contexto agrícola, y la adaptación a la baja-media resolución y bandas espectrales de Sentinel-2.

La innovación principal reside en la adaptación rigurosa y evaluación de herramientas DL avanzadas para automatizar y escalar el monitoreo de un elemento clave de la logística agrícola argentina, utilizando datos satelitales de libre disponibilidad.

Objetivos

Objetivo general:

Desarrollar y validar un modelo de detección de objetos basado en redes neuronales convolucionales que, a partir de imágenes satelitales Sentinel-2 (RGB) del departamento de Marcos Juárez (Córdoba, Argentina), permita localizar silo-bolsas durante el período junio–agosto de 2020 a 2025, y evaluar cuantitativamente en qué medida la calidad de la verdad de terreno (etiquetas curadas manualmente frente a etiquetas ruidosas autogeneradas) condiciona el desempeño del modelo, con el fin de aportar herramientas de monitoreo para la toma de decisiones en la cadena agroindustrial.

Objetivos específicos:

- Construir una base de datos de imágenes Sentinel-2 L2A georreferenciadas, preprocesadas (composición de bandas, enmascaramiento de nubes, mosaico, recorte a la zona agrícola y teselado en parches) y filtradas, para el período junio–agosto de 2020 a 2025.
- Diseñar e implementar un método de generación semiautomática de etiquetas mediante el índice espectral INBNV, y un flujo de curación manual en GIS que corrija los falsos positivos resultantes.
- Definir una progresión experimental de modelos que, manteniendo constante la arquitectura, permita aislar el efecto de la calidad y la cantidad de las etiquetas, así como de la estrategia de muestreo.
- Entrenar y optimizar un detector Faster R-CNN con ResNet50-FPN, adaptando las cajas de anclaje a la geometría alargada y pequeña de los silo-bolsas, bajo restricciones de cómputo en CPU.
- Evaluar y comparar las versiones sobre un conjunto de prueba independiente con verdad de terreno curada, mediante métricas de detección (Precisión, Recall, F1, AP e IoU), y analizar el hallazgo de eficiencia de datos resultante, incluyendo una validación temporal preliminar sobre un año no visto (2026).

Transferencia de los resultados obtenidos.

Los resultados y la metodología desarrollados en este trabajo tendrían un significativo potencial de transferencia a diversas aplicaciones prácticas y ámbitos de investigación.

Fuera del ámbito específico de la solución propuesta (el modelo entrenado y el flujo de trabajo), las aplicaciones prácticas directas podrían beneficiar a:

- Empresas del Sector Agroindustrial (Multinacionales, Acopios, Logística, Consultoras, Aseguradoras): Para obtener estimaciones de stocks regionales, optimizar la planificación logística (rutas de transporte, capacidad de almacenamiento), analizar la competencia, desarrollar nuevos productos de seguro basados en inventarios, o brindar servicios de asesoramiento con datos actualizados.
- Productores o dueños de campo: Para monitoreo y seguimiento de su producción cuantificar entradas, liquidaciones y consumos en todas las explotaciones
- Investigadores y ONGs: Para realizar estudios sobre seguridad alimentaria, cuantificar el impacto ambiental del almacenamiento temporal, o efectuar análisis económicos del sector agrícola basados en datos objetivos de inventario.
- Organismos Gubernamentales (ARCA, Secretarías de Agricultura): Para integrar en sistemas GIS existentes, complementando la fiscalización, realizando estimaciones de producción no declarada a nivel regional, o monitoreando el uso de recursos y la dinámica del almacenamiento.

La transferencia a un ámbito más amplio, extendiendo la metodología, sería posible mediante:

- Detección de Otros Objetos Agrícolas: Adaptando el flujo de trabajo (preprocesamiento Sentinel-2, creación de dataset, entrenamiento CNN) para detectar otros elementos como diferentes tipos de estructuras de riego, áreas de alimentación de ganado (feedlots), sectores avícolas, o incluso patrones

espaciales de daño en cultivos o cualquier otro objeto siempre que sean distinguibles a más de 10m de resolución.

- Aplicación en Otras Regiones Globales: El modelo podría aplicarse a otras zonas agrícolas del mundo (e.g., Brasil, EE.UU., Ucrania) donde se utilicen silo-bolsas y se disponga de imágenes Sentinel-2. Sería recomendable un reentrenamiento fino (fine-tuning) con datos locales para optimizar el rendimiento y adaptarse a posibles variaciones en el entorno o tipos de bolsas.
- Uso con Otros Sensores Satelitales: La metodología podría adaptarse para imágenes Landsat (similar resolución espectral, pero 30m espacial) o satélites comerciales de mayor resolución (e.g., PlanetScope a 3-5m), ajustando el preprocesamiento, el tamaño de los parches y reentrenando el modelo. La fusión con datos de radar (Sentinel-1), al ser insensible a nubes, representa una extensión valiosa para asegurar monitoreo continuo (Victor et al., 2025).

La transferencia efectiva requerirá la publicación de la metodología, la disponibilización (si es posible) del dataset y/o modelos entrenados, una documentación clara de las capacidades y limitaciones, y potencialmente el desarrollo de interfaces o APIs para facilitar su integración en otros sistemas, esto último no será abarcado en este trabajo.

Trabajos relacionados

Problema central (Detección/Segmentación de silo-bolsas):

El antecedente más directo es Barbiani y Bustamante (2022), que desarrollaron un detector de pivotes y silo-bolsas con YOLOv5 sobre imágenes de Google Earth y Sentinel, con dataset etiquetado manualmente y aumento de datos. Se diferencia de este trabajo en que usaron fuentes mixtas, no se enfocaron exclusivamente en Sentinel-2 y no analizaron la calidad de las etiquetas. La presente propuesta se centra en Sentinel-2 L2A, emplea un detector de dos etapas (Faster R-CNN) y sitúa en el centro la comparación entre verdad de terreno limpia y ruidosa.

Problemas relacionados (Detección/Segmentación de Objetos en RS):

Fernández Marcos (2023) comparó variantes de YOLO para detección de objetos en imágenes satelitales; Tapia Catacora (2023) aplicó U-Net a la segmentación de deforestación en Landsat-8; Iglovikov et al. (2017) adaptaron U-Net a entradas multiespectrales. Muñoz et al. (2007) detectaron incendios sub-píxel en baja resolución. Ventajas: Establecen metodologías para aplicar DL (detección y segmentación) en RS. Estos trabajos establecen metodologías de referencia sobre objetos, resoluciones y sensores distintos.

Identificaron previamente el problema (Contexto General DL en RS/Agricultura):

Ball et al. (2017) y Zhang et al. (2016) realizaron surveys sobre DL en RS, identificando tendencias y desafíos (datos limitados, interpretabilidad). Victor et al. (2025) revisaron DL para agricultura con imágenes satelitales, notando brechas en áreas más allá de uso y cobertura del suelo por falta de datasets. Ventajas: Proveen marco contextual, identifican desafíos (datos, Ball et al., 2017) y validan relevancia de DL en RS para agricultura de precisión. Desventajas/Diferencias: Generales, no específicos a silo-bolsas.

La propuesta de este trabajo aplica DL a un problema agrícola específico y aborda el desafío de crear datos para segmentación/detección de esta infraestructura.

Misma metodología (Segmentación/Detección con DL en RS):

Faster R-CNN (Ren et al., 2015), ResNet (He et al., 2016) y FPN (Lin et al., 2017) constituyen la base de la arquitectura adoptada. En cuanto al eje de calidad de etiquetas, Frénay y Verleysen (2014) revisan la clasificación con ruido de etiqueta; Northcutt et al. (2021) evidencian errores en benchmarks de referencia; y Rolnick et al. (2017) muestran que las redes pueden ser robustas a ruido masivo cuando el conjunto es grande. Esta tensión (cantidad con ruido frente a calidad curada) es la que el trabajo examina empíricamente.

Metodología

Tipo de estudio: investigación aplicada de tipo cuantitativo, que emplea Deep Learning para detección de objetos con el fin de resolver un problema práctico del ámbito agrícola.

Emplazamiento: El trabajo se realizará computacionalmente. El área geográfica de estudio para la adquisición de imágenes Sentinel-2 se centrará en la zona núcleo de Argentina (Específicamente en el Departamento Marcos Juárez, Córdoba) durante las temporadas relevantes para el almacenamiento de granos denominados “grueso” en silo-bolsas, es decir, post cosecha de maíz, soja y Girasol en el periodo invernal o de barbecho (junio-agosto de 2020 a 2025). El desarrollo y entrenamiento del modelo se realizará utilizando recursos informáticos de uso personal limitados sin uso de GPU.

Población y selección: la población son todas las imágenes Sentinel-2 L2A disponibles sobre el área en el período indicado.

- **Criterios de inclusión:** imágenes con baja cobertura nubosa sobre las zonas agrícolas.
- **Criterios de exclusión:** alta nubosidad, sombras extensas y superficies no agrícolas. Se descargan, filtran y preprocesan las imágenes que cumplen los criterios para formar el dataset.

Variables:

- De entrada (predictoras): valores de reflectancia de las bandas B02 (Azul), B03 (Verde) y B04 (Rojo) a 10 m, organizadas en parches. La entrada del modelo es RGB (3 canales).
- Banda auxiliar para etiquetado (no de entrada): B08 (NIR o infrarrojo cercano), utilizada únicamente para calcular el índice INBNV con el que se genera la capa de etiquetas iniciales.
- De salida (objetivo): conjunto de detecciones (coordenadas de caja delimitadora, clase «silo-bolsa», puntaje de confianza).

Métodos de recogida de datos: adquisición de Sentinel-2 L2A desde AWS Open Data Registry (s.f.); generación semiautomática de etiquetas mediante el índice INBNV (capa de candidatos por umbralización del NIR combinada con el visible), seguida de curación manual en GIS (eliminación de falsos positivos, ajuste y agregado de bolsas), guardando en formato vectorial (shapefile/GeoJSON).

Análisis de datos: preprocesamiento (mosaicos sin nubes, apilado de bandas, normalización, generación de parches); entrenamiento con PyTorch/torchvision (Paszke et al., 2019) del Faster R-CNN ResNet50-FPN. evaluación mediante Precisión, Recall, F1 y AP, siguiendo las definiciones estándar de detección de objetos (Everingham et al., 2010; Padilla et al., 2020) sobre el conjunto de prueba, con IoU de 0,15 y umbral de confianza de 0,5. La comparación central es entre versiones entrenadas con etiquetas limpias y ruidosas; se complementa con un análisis de sensibilidad al umbral y una validación temporal preliminar sobre 2026.

Ética: el desarrollo de una herramienta que precise la ubicación y el dimensionamiento de silo-bolsas, disponible solo para algunos actores, podría generar inequidad informativa. Por ello, este trabajo, de carácter netamente académico y de alcance acotado, no publica información asociada a un campo, propietario o cantidad producida, y trata los resultados de manera estadística y global. Al no ser los resultados completamente exactos, su uso para fiscalización individual sería metodológicamente inapropiado, lo que refuerza la pertinencia de un uso agregado. En coherencia con la Ley 25.326 de Protección de Datos Personales de la República Argentina, no se expone ubicación geográfica precisa ni dato alguno vinculable a una persona determinada sin su consentimiento.

Limitaciones del estudio: precisión limitada por la resolución de 10 m (con un techo de detectabilidad para las bolsas sub-resolución); disponibilidad de imágenes según fechas y nubosidad; dependencia de la calidad y el tamaño del conjunto curado; posible sesgo de sitio en la generalización a otras regiones.

Plan de Trabajo

Fase 1: Investigación y Planificación (1 Mes)

- T1.1: Revisión Bibliográfica y Pruebas Iniciales (Semana 1 - Semana 2, 2 semanas)
 - Búsqueda de trabajos similares, revisión bibliográfica, presentación de la idea al director de tesis y ejecución de las primeras pruebas de concepto.
- T1.2: Definición Final del Alcance (Semana 3 - Semana 3, 1 semana)
 - Definición precisa del alcance del proyecto, estableciendo el foco de la detección exclusivamente sobre imágenes Sentinel-2 RGB.
- T1.3: Escritura Plan de Trabajo Final (Semana 4 - Semana 4, 1 semana)
 - Redacción del plan de trabajo final y refinamiento del documento con los objetivos planteados.

Fase 2: Adquisición y Preprocesamiento de Datos (2 Meses)

- T2.1: Descarga de Imágenes (Mes 2 Semana 1 - Mes 2 Semana 2, 2 semanas)
 - Descarga y acceso a las imágenes Sentinel-2 L2A correspondientes al período de invierno (junio–agosto) de los años 2020 a 2025.
- T2.2: Procesamiento Base y Teselado (Mes 2 Semana 3 - Mes 3 Semana 1, 3 semanas)
 - Composición de bandas, aplicación del enmascaramiento de nubes, creación del mosaico, recorte específico a la zona agrícola de interés y teselado de las imágenes.
- T2.3: Cálculo de Índices y Candidatos (Mes 3 Semana 2 - Mes 3 Semana 4, 3 semanas)

- Cálculo del índice INBNV sobre el conjunto procesado y generación de la capa inicial de polígonos candidatos.

Fase 3: Construcción de la Verdad de Terreno [Esfuerzo Principal] (2 Meses)

- T3.1: Diseño del Muestreo (Mes 4 Semana 1 - Mes 4 Semana 1, 1 semana)
 - Definición del muestreo estratificado balanceado y separación de un conjunto de reserva aislado para evaluación final.
- T3.2: Curación Manual Parcial (Mes 4 Semana 2 - Mes 5 Semana 4, 8 semanas)
 - Inicio y finalización de la curación manual en GIS de la capa de polígonos candidata.

Fase 4: Entrenamiento de las Versiones (2 Meses)

- T4.1: Configuración del Entorno (Mes 6 Semana 1 - Mes 6 Semana 1, 1 semana)
 - Preparación del entorno de entrenamiento en CPU, adaptando la arquitectura común para todas las versiones.
- T4.2: Entrenamiento de Modelos Iniciales (Mes 6 Semana 2 - Mes 6 Semana 4, 3 semanas)
 - Entrenamiento de las versiones V2 y V3 variando el origen, tamaño y el esquema de muestreo del conjunto de datos.
- T4.3: Entrenamiento de Modelos Avanzados (Mes 7 Semana 1 - Mes 7 Semana 4, 4 semanas)
 - Entrenamiento de las versiones V4 y V5 ajustando los últimos parámetros de muestreo sobre la arquitectura base en CPU.

Fase 5: Evaluación y Análisis (1 Mes)

- T5.1: Evaluación Comparativa y Post-procesamiento (Mes 8 Semana 1 - Mes 8 Semana 2, 2 semanas)
 - Ejecutar la evaluación comparativa de las versiones sobre el conjunto de prueba con la verdad de terreno curada.
- T5.2: Validación Temporal (Mes 8 Semana 2 - Mes 8 Semana 4, 2 semanas)
 - Ejecución de una validación temporal preliminar proyectando los modelos entrenados sobre imágenes de la campaña 2026.

Fase 6: Escritura y Defensa TFM (2 Meses)

- T6.1: Redacción Borrador de Tesis (Mes 9 Semana 1 - Mes 10 Semana 1, 5 semanas)
 - Redacción estructurada de todos los capítulos y secciones del documento final de tesis.
- T6.2: Revisión y Feedback (Mes 10 Semana 2 - Mes 10 Semana 2, 1 semana)
 - Revisión del borrador completo con el director, incorporación de correcciones y ajustes finales.
- T6.3: Entrega Versión Final (Mes 10 Semana 3 - Mes 10 Semana 3, 1 semana)
 - Formateo definitivo y entrega formal del documento final de la tesis.
- T6.4: Preparación y Defensa (Mes 10 Semana 4 - Mes 10 Semana 4, 1 semana)
 - Preparación del soporte visual (presentación oral) y defensa oficial del trabajo final.

Referencias

Aapresid. (2023). Aplicaciones selectivas: indagamos quiénes adoptaron. Aapresid Blog. <https://www.aapresid.org.ar/blog/aplicaciones-selectivas-indagamos-quienes-adoptaron>

AWS Open Data Registry. (s.f.). Sentinel-2. Recuperado el 26 de octubre de 2025, de <https://registry.opendata.aws/sentinel-2/>

Ball, J. E., Anderson, D. T., & Chan, C. S. (2017). Comprehensive survey of deep learning in remote sensing: theories, tools, and challenges for the community. *Journal of Applied Remote Sensing*, 11(4), 042609. <https://doi.org/10.1117/1.JRS.11.042609>

Barbiani, G., & Bustamante, L. (2022). Detector de Pivotes de Riego y Silobolsas en Imágenes Satelitales para aplicaciones agrícolas [Proyecto Integrador, Ingeniería en Computación]. Universidad Nacional de Córdoba.

Copernicus. (s.f.). Sentinel-2 Data Collection. Copernicus Data Space Ecosystem. Recuperado el 26 de octubre de 2025, de <https://dataspace.copernicus.eu/data-collections/copernicus-sentinel-2/data/sentinel-2>

CREA. (2023). Aplicaciones dirigidas: estado actual y futuro. Contenidos CREA. <https://www.contenidoscrea.org.ar/agricultura/aplicaciones-dirigidas-estado-actual-y-futuro-n5326635>

Everingham, M., Van Gool, L., Williams, C. K. I., Winn, J., & Zisserman, A. (2010). The PASCAL Visual Object Classes (VOC) challenge. *International Journal of Computer Vision*, 88(2), 303–338. <https://doi.org/10.1007/s11263-009-0275-4>

Expoagro. (2025). Silobolsa: el invento argentino que soluciona problemas globales. Expoagro Digital. <https://www.expoagro.com.ar/silobolsa-el-invento-argentino-que-soluciona-problemas-globales/>

Fernández Marcos, S. (2023). Sistema de reconocimiento de patrones en imágenes satelitales para la detección de objetos [Trabajo de Fin de Máster, Universidad de Salamanca].

Filgueira, E. (2013). Silo Bolsa. C3T-UTN. <https://c3t-utn.ar/wp-content/uploads/2013/07/Silo-Bolsa.pdf>

Frénay, B., & Verleysen, M. (2014). Classification in the presence of label noise: A survey. *IEEE Transactions on Neural Networks and Learning Systems*, 25(5), 845–869. <https://doi.org/10.1109/TNNLS.2013.2292894>

Gobierno de Argentina. (2025a). Más del 40% de la producción nacional se conserva en silobolsas. [Argentina.gob.ar. https://www.argentina.gob.ar/noticias/mas-del-40-de-la-produccion-nacional-se-conserva-en-silobolsas](https://www.argentina.gob.ar/noticias/mas-del-40-de-la-produccion-nacional-se-conserva-en-silobolsas)

Gobierno de Argentina. (2025b). Monitoreo inteligente para preservar la calidad de los granos. [Argentina.gob.ar. https://www.argentina.gob.ar/noticias/monitoreo-inteligente-para-preservar-la-calidad-de-los-granos](https://www.argentina.gob.ar/noticias/monitoreo-inteligente-para-preservar-la-calidad-de-los-granos)

He, K., Zhang, X., Ren, S., & Sun, J. (2016). Deep residual learning for image recognition. *Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition (CVPR)*, 770–778. <https://doi.org/10.1109/CVPR.2016.90>

Iglovikov, V., Mushinskiy, S., & Osin, V. (2017). Satellite Imagery Feature Detection using Deep Convolutional Neural Network: A Kaggle Competition. arXiv. <https://arxiv.org/abs/1706.06169>

INTA. (s.f.). Almacenamiento de granos en bolsas plásticas. Agroconsultas Online. Recuperado el 26 de octubre de 2025, de https://aws.agroconsultasonline.com/comentario.html/script-tmp-inta_almacen_granos14.pdf?op=d&comentario_id=8673&orden=1

Lin, T.-Y., Dollár, P., Girshick, R., He, K., Hariharan, B., & Belongie, S. (2017). Feature pyramid networks for object detection. Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition (CVPR), 2117–2125. <https://doi.org/10.1109/CVPR.2017.106>

Muñoz, C., Acevedo, P., Salvo, S., Fagalde, G., & Vargas, F. (2007). Detección de incendios forestales utilizando imágenes NOAA/16-LAC en la Región de La Araucanía, Chile. BOSQUE, 28(2), 119–128. <http://dx.doi.org/10.4067/S0717-92002007000200003>

Muzlera, J. (2024). Silo bolsa (Argentina, 1991-2023). En J. Muzlera & A. Salomón (Eds.), Diccionario del agro iberoamericano (5.ª ed. ampliada). Alejandra Laura Salomón. <https://www.teseopress.com/diccionarioagro/chapter/silo-bolsa-argentina-1991-2023/>

Northcutt, C. G., Athalye, A., & Mueller, J. (2021). Pervasive label errors in test sets destabilize machine learning benchmarks. Proceedings of the 35th Conference on Neural Information Processing Systems (NeurIPS), Datasets and Benchmarks Track. <https://arxiv.org/abs/2103.14749>

Padilla, R., Netto, S. L., & da Silva, E. A. B. (2020). A survey on performance metrics for object-detection algorithms. 2020 International Conference on Systems, Signals and Image Processing (IWSSIP), 237–242. <https://doi.org/10.1109/IWSSIP48289.2020.9145130>

Paszke, A., Gross, S., Massa, F., Lerer, A., Bradbury, J., Chanan, G., ... Chintala, S. (2019). PyTorch: An imperative style, high-performance deep learning library. Advances in Neural Information Processing Systems (NeurIPS), 32, 8024–8035.

Ren, S., He, K., Girshick, R., & Sun, J. (2015). Faster R-CNN: Towards real-time object detection with region proposal networks. Advances in Neural Information Processing Systems (NeurIPS), 28, 91–99. <https://arxiv.org/abs/1506.01497>

Rolnick, D., Veit, A., Belongie, S., & Shavit, N. (2017). Deep learning is robust to massive label noise. arXiv. <https://arxiv.org/abs/1705.10694>

Tapia Catacora, P. C. (2023). Detección de deforestación de bosques en imágenes satelitales con redes neuronales convolucionales [Tesis Doctoral, Universidad Nacional del Altiplano]. Repositorio Institucional UNA-PUNO. <http://repositorio.unap.edu.pe/handle/UNAP/19875>

Victor, B., Nibali, A., & He, Z. (2025). A systematic review of the use of Deep Learning in Satellite Imagery for Agriculture. arXiv. <https://arxiv.org/abs/2210.01272>

Zhang, L., Zhang, L., & Du, B. (2016). Deep Learning for Remote Sensing Data: A technical tutorial on the state of the art. IEEE Geoscience and Remote Sensing Magazine, 4(2), 22–40. <https://doi.org/10.1109/MGRS.2016.2540798>

Zou, Z., Chen, K., Shi, Z., Guo, Y., & Ye, J. (2023). Object detection in 20 years: A survey. *Proceedings of the IEEE*, 111(3), 257–276. <https://doi.org/10.1109/JPROC.2023.3238524>