

Insertar logo de la Universidad Austral

UNIVERSIDAD AUSTRAL

Maestría en Explotación de Datos y Gestión del Conocimiento

Detección de silo-bolsas mediante técnicas de aprendizaje profundo en imágenes satelitales Sentinel-2 para el departamento de Marcos Juárez, zona núcleo de Argentina

[FEDE: confirmar el título registrado; el plan incluía “y segmentación”]

Trabajo Final de Maestría

Autor: Federico Richard

Director: Gonzalo Sad

[FEDE: mes y año de presentación]

Rosario, Argentina

NOTA AL AUTOR — ELIMINAR ANTES DE ENTREGAR.

Este es un borrador base, pensado como andamiaje para que se complete y edite. Decisiones de marco asumidas: (1) el eje del trabajo es la comparación entre verdad de terreno limpia y ruidosa (versiones V2–V5), con un detector Faster R-CNN y entrada RGB; el infrarrojo cercano se emplea únicamente para generar las etiquetas mediante el índice INBNV. (2) El alcance efectivo es la detección (cajas delimitadoras), no la segmentación pixel a pixel. (3) La validación temporal sobre imágenes de 2026 se encuentra en curso. Se deben revisar y reemplazar todos los marcadores resaltados en amarillo con el formato [FEDE: ...]. Formato requerido por el instructivo: Times New Roman o Arial, 11 pt en el texto, interlineado 1,5, alineación justificada y citas en sistema APA; verificar tamaños de título exigidos.

Resumen

El almacenamiento de granos en silo-bolsas concentra cerca del 40 % de la producción agrícola argentina, pero no existe un mecanismo escalable, frecuente y de bajo costo para estimar su distribución a partir de datos objetivos. Este trabajo desarrolla y valida un detector de silo-bolsas en imágenes satelitales Sentinel-2 (RGB, 10 m de resolución) para el departamento de Marcos Juárez, en la zona núcleo de Argentina, durante el período junio–agosto de 2020 a 2025. El aporte central es metodológico: se examina empíricamente en qué medida la calidad de la verdad de terreno —etiquetas curadas manualmente frente a etiquetas ruidosas autogeneradas mediante un índice espectral (INBNV)— condiciona el desempeño del modelo.

Se implementó un pipeline modular de procesamiento de imágenes y un método de etiquetado semiautomático con curación manual en QGIS, y se diseñó una progresión controlada de cuatro versiones de un detector Faster R-CNN con backbone ResNet50-FPN y cajas de anclaje adaptadas a la geometría alargada de los silo-bolsas, entrenadas en CPU. La evaluación sobre un conjunto de prueba con verdad de terreno curada muestra que la versión entrenada con 216 imágenes limpias iguala o supera a la entrenada con cerca de 10.000 imágenes ruidosas —alcanzando el mejor F1 (0,755) y el mejor Recall (0,845), con la menor cantidad de errores— utilizando aproximadamente el 2 % de los datos. Más que una mejora marginal de exactitud, el resultado constituye un hallazgo de eficiencia de datos con implicancias que exceden el caso de estudio. El trabajo discute, asimismo, las consideraciones éticas y legales y la propuesta de valor de un sistema de observación de infraestructura agrícola basado en datos públicos.

Palabras clave: teledetección; Sentinel-2; aprendizaje profundo; detección de objetos; Faster R-CNN; silo-bolsas; calidad de etiquetas; agricultura de precisión.

Dedicatoria

[FEDE: dedicatoria — opcional. Espacio libre para escribir.]

Agradecimientos

[FEDE: agradecimientos — opcional. Al director Gonzalo Sad, a la Universidad Austral, a tu entorno laboral y personal, etc.]

Índice General

[FEDE: en Word, hacer clic derecho sobre el índice y elegir “Actualizar campo” para que se complete con los títulos y números de página.]

Índice de Cuadros

Cuadro 3.1. Diseño experimental de las versiones del modelo.

Cuadro 4.1. Desempeño comparativo de las versiones V2–V5 sobre el conjunto de prueba.

[FEDE: completar números de página, o generar automáticamente con epígrafes de Word.]

Índice de Figuras

Figura 3.1. Área de estudio: departamento de Marcos Juárez.

Figura 3.2. Flujo de preprocesamiento de imágenes Sentinel-2.

Figura 3.3. Generación semiautomática y curación de la verdad de terreno.

Figura 4.1. Ejemplos cualitativos de detección.

[FEDE: completar números de página al insertar las figuras definitivas.]

Abreviaturas

AOI	Área de Interés (Area of Interest).
AP	Average Precision (precisión promedio); métrica de detección.
CNN	Red Neuronal Convolucional (Convolutional Neural Network).
CV	Visión por Computadora (Computer Vision).
DL	Aprendizaje Profundo (Deep Learning).
FN	Falso Negativo.
FP	Falso Positivo.
FPN	Red Piramidal de Características (Feature Pyramid Network).
F1	Media armónica entre Precisión y Recall.
GT	Verdad de Terreno (Ground Truth).
INBNV	Índice espectral empleado para la generación semiautomática de etiquetas (véase Sección 3.5).
IoU	Intersección sobre Unión (Intersection over Union).
L2A	Nivel de procesamiento 2A de Sentinel-2 (reflectancia de superficie).
mAP	mean Average Precision.
MGRS	Sistema de referencia de cuadrícula militar (Military Grid Reference System).
NIR	Infrarrojo Cercano (Near Infrared).
R-CNN	Red Neuronal Convolucional basada en Regiones (Region-based CNN).
RGB	Rojo, Verde y Azul (canales del espectro visible).
RS	Teledetección o Sensado Remoto (Remote Sensing).
SCL	Capa de Clasificación de Escena de Sentinel-2 (Scene Classification Layer).
TP	Verdadero Positivo.

Capítulo 1. Introducción

El sector agroindustrial argentino constituye uno de los pilares de la economía nacional, y dentro de su cadena de valor el almacenamiento temporal de granos en silo-bolsas ocupa un lugar central. Se estima que cerca del 40 % de la producción agrícola del país se conserva en este tipo de estructuras (Gobierno de Argentina, 2025a), lo que las convierte en un elemento logístico y financiero clave para productores, acopios, aseguradoras, empresas exportadoras y organismos públicos. No obstante, no existe en la actualidad un mecanismo escalable, frecuente y de bajo costo que permita estimar de manera objetiva la distribución y la cantidad de silo-bolsas presentes en el territorio en un momento dado.

La teledetección satelital ofrece una vía prometedora para abordar este problema. La misión Sentinel-2 del programa europeo Copernicus provee imágenes multispectrales de acceso libre y gratuito, con una resolución espacial de 10 metros en las bandas del visible e infrarrojo cercano y una revisita de aproximadamente cinco días (Copernicus, s.f.). La combinación de estos datos con técnicas modernas de aprendizaje profundo (Deep Learning, DL) y visión por computadora habilita la automatización de tareas de monitoreo que hasta hace pocos años requerían inspección manual o relevamientos de campo costosos (Ball et al., 2017; Zhang et al., 2016).

Ahora bien, el cuello de botella de estos enfoques rara vez es el modelo: es el dato etiquetado. Entrenar un detector de objetos supervisado exige un conjunto de verdad de terreno (Ground Truth, GT) en el que cada silo-bolsa esté delimitado por un analista. La construcción de ese conjunto, sobre objetos pequeños y poco contrastados a 10 metros de resolución, es lenta, costosa y propensa a errores. Frente a ello surge una tensión metodológica de fondo, que es la que motiva este trabajo: *ante un presupuesto de etiquetado limitado, ¿conviene invertir el esfuerzo en muchas etiquetas generadas de forma automática —y por lo tanto ruidosas— o en pocas etiquetas curadas manualmente con alta calidad?*

1.1. Planteo del problema

La digitalización automática de silo-bolsas —entendida como su detección y localización a partir de imágenes Sentinel-2— enfrenta tres dificultades simultáneas. En primer lugar, la **resolución espacial** de 10 metros sitúa al silo-bolsa en el límite de lo detectable: una bolsa típica de unos 60–75 m de largo por 3–5 m de ancho ocupa apenas unos pocos píxeles de ancho (Filgueira, 2013). En segundo lugar, la **variabilidad** temporal y ambiental es alta: el aspecto de las bolsas y del entorno cambia entre años secos y húmedos, entre meses, y según la condición de la superficie. En tercer lugar, y de manera determinante, la **disponibilidad de etiquetas de calidad** es escasa: no existen datasets públicos de silo-bolsas en Sentinel-2, por lo que el GT debe construirse desde cero (Ball et al., 2017).

Para mitigar el costo de etiquetado, en este trabajo se desarrolla una estrategia de generación **semiautomática** de etiquetas a partir de un índice espectral (denominado INBNV), que produce una capa inicial de polígonos candidatos. Esa capa, sin embargo, contiene una proporción elevada de falsos positivos (del orden del 50 %), dado que el índice responde a la firma espectral de superficies brillantes y no exclusivamente a silo-bolsas. Surge entonces la pregunta central de investigación.

1.2. Pregunta de investigación e hipótesis

La pregunta que estructura la tesis es la siguiente: **¿produce un conjunto de entrenamiento pequeño con etiquetas curadas manualmente un modelo de detección de mejor desempeño que un conjunto mucho mayor con etiquetas ruidosas autogeneradas?** La hipótesis de trabajo sostiene que la calidad del GT prima sobre su cantidad: que un dataset reducido y limpio puede igualar o superar a uno considerablemente más grande pero ruidoso, y que ese resultado constituye un argumento de eficiencia de datos con implicancias que exceden el caso de los silo-bolsas.

Para poner a prueba esta hipótesis se diseñó una progresión controlada de cuatro versiones de modelo (V2 a V5), descrita en detalle en el Capítulo 3, que mantiene fija la arquitectura y varía de manera sistemática el origen, el tamaño y la estrategia de muestreo del conjunto de entrenamiento, de modo de aislar el efecto de la calidad de las etiquetas.

1.3. Objetivos

Objetivo general

Desarrollar y validar un modelo de detección de objetos basado en redes neuronales convolucionales que, a partir de imágenes satelitales Sentinel-2 (RGB) del departamento de Marcos Juárez (Córdoba, Argentina), permita localizar silo-bolsas, y evaluar cuantitativamente en qué medida la calidad de la verdad de terreno —etiquetas curadas manualmente frente a etiquetas ruidosas autogeneradas— condiciona el desempeño del modelo.

Objetivos específicos

1. Construir una base de datos de imágenes Sentinel-2 L2A georreferenciadas, preprocesadas (composición de bandas, enmascaramiento de nubes, mosaico, recorte a la zona agrícola y teselado en parches) y filtradas, para el período junio–agosto de los años 2020 a 2025.
2. Diseñar e implementar un método de generación *semiautomática* de etiquetas mediante un índice espectral (INBNV), y un flujo de curación manual en QGIS que corrija los falsos positivos resultantes.
3. Definir una progresión experimental de modelos (V2–V5) que, manteniendo constante la arquitectura, permita aislar el efecto de la calidad y la cantidad de las etiquetas, así como de la estrategia de muestreo.
4. Entrenar y optimizar un detector Faster R-CNN con backbone ResNet50-FPN, adaptando las cajas de anclaje (anchors) a la geometría alargada y pequeña de los silo-bolsas, bajo restricciones de cómputo en CPU.
5. Evaluar y comparar las versiones sobre un conjunto de prueba independiente con verdad de terreno curada, mediante métricas de detección (Precisión, Recall, F1, AP e IoU), y analizar el hallazgo de eficiencia de datos resultante.

1.4. Aportes del trabajo

Los principales aportes de esta tesis son: **(i)** un método reproducible de etiquetado semiautomático de silo-bolsas en Sentinel-2 basado en un índice espectral, que reduce sustancialmente el costo de anotación; **(ii)** evidencia cuantitativa, sobre un caso real, de que un conjunto pequeño y limpio (216 imágenes) iguala o supera a uno aproximadamente cincuenta veces mayor pero ruidoso (cerca de 10.000 imágenes), lo que se interpreta como un resultado de eficiencia de datos antes que como una mejora marginal de exactitud; **(iii)** un pipeline modular y resumible de procesamiento de imágenes Sentinel-2 orientado a la detección de objetos pequeños; y **(iv)** una discusión explícita de las implicancias éticas, legales y de transferencia de un sistema de observación de infraestructura agrícola a partir de datos públicos.

1.5. Alcance y limitaciones

El estudio se circunscribe geográficamente al departamento de Marcos Juárez, en la zona núcleo de Argentina, y temporalmente al período invernal de barbecho (junio–agosto) de 2020 a 2025, ventana en la que se concentra el almacenamiento posterior a la cosecha de granos gruesos. El desarrollo y el entrenamiento se realizaron con recursos de cómputo personales y **sin uso de GPU**, lo que condicionó el tamaño de los modelos y los tiempos de entrenamiento. El trabajo aborda la *detección* (localización mediante cajas delimitadoras) y no la segmentación pixel a pixel; *[FEDE: confirmar si el título registrado conserva la palabra “segmentación” o si se acuerda con el director acotar el alcance a detección.]* Las limitaciones específicas de resolución, generalización y disponibilidad de imágenes se retoman en el Capítulo 4.

1.6. Estructura del documento

El resto del trabajo se organiza de la siguiente manera. El **Capítulo 2** revisa el estado del arte en teledetección para agricultura, detección de objetos con DL y, en particular, la problemática del ruido en las etiquetas y el paradigma centrado en los datos. El **Capítulo 3** describe la solución implementada: el área de estudio, el pipeline de datos, el método de etiquetado semiautomático, el diseño experimental de las versiones V2–V5, la arquitectura del modelo y el protocolo de evaluación. El **Capítulo 4** presenta y discute los resultados, las lecciones aprendidas y las consideraciones éticas y legales. Finalmente, el **Capítulo 5** expone las conclusiones y las líneas de trabajo futuro.

Capítulo 2. Estado del arte

Este capítulo sitúa el trabajo en el cruce de tres campos: la teledetección aplicada a la agricultura de precisión, la detección de objetos en imágenes satelitales mediante aprendizaje profundo, y la línea de investigación —más reciente y central para esta tesis— que estudia el impacto de la calidad de las etiquetas en el desempeño de los modelos.

2.1. Teledetección y agricultura de precisión

La agricultura de precisión se define como un enfoque de gestión que observa, mide y responde a la variabilidad espacial y temporal dentro y entre lotes de cultivo. Entre sus tecnologías habilitantes, los sensores remotos —drones e imágenes satelitales— ocupan un lugar destacado, dado que permiten relevar grandes superficies de manera consistente y periódica (Victor et al., 2025; Zhang et al., 2016). Las imágenes Sentinel-2, por su cobertura global, su revisita frecuente y su carácter gratuito, se han consolidado como una fuente de referencia para aplicaciones agrícolas (GISGeography, s.f.).

Un dato satelital, sin embargo, no genera valor por sí solo: requiere procesos de extracción de información que lo conviertan en conocimiento accionable. La detección de estructuras de almacenamiento temporal, como los silo-bolsas, es un ejemplo de esa extracción de información específica, todavía poco explorada en la literatura publicada respecto de otras aplicaciones más establecidas, como el monitoreo de cobertura y uso del suelo (Victor et al., 2025).

2.2. El silo-bolsa como objeto de estudio

El silo-bolsa es una estructura plástica oblonga, compuesta por polietileno de baja densidad, utilizada para el almacenamiento hermético y temporal de granos secos y forraje (Muzlera, 2024). Originado en Alemania en la década de 1960 para forraje, se popularizó en Argentina en los años noventa, y el desarrollo tecnológico del INTA lo transformó en un dispositivo apto para granos secos como soja, maíz y trigo (Muzlera, 2024; Expoagro, 2025). Permite almacenar la cosecha entre seis meses y dos años (INTA, s.f.), habilitando estrategias comerciales en función de los precios. Su relevancia económica —cerca del 40 % de la producción nacional (Gobierno de Argentina, 2025a)— y la falta de información objetiva sobre su distribución justifican el interés por su monitoreo automatizado.

2.3. Detección de objetos en imágenes satelitales con aprendizaje profundo

Las redes neuronales convolucionales (CNN) revolucionaron la visión por computadora y, con ella, el análisis automático de imágenes de teledetección (Ball et al., 2017; Zhang et al., 2016). En detección de objetos coexisten dos grandes familias: los detectores de una etapa, como YOLO y SSD, que privilegian la velocidad, y los de dos etapas, como la familia R-CNN, que privilegian la precisión de localización. En esta segunda familia, Fast R-CNN (Girshick, 2015) y, sobre todo, Faster R-CNN (Ren et al., 2015) introdujeron la red de propuestas de regiones (Region Proposal Network), que integra la generación de candidatos dentro de la propia red y la vuelve entrenable de extremo a extremo.

El desempeño de estos detectores depende fuertemente del extractor de características o backbone. ResNet (He et al., 2016) habilitó el entrenamiento de redes muy profundas mediante conexiones residuales, y las redes piramidales de características (Feature Pyramid Network, FPN; Lin et al., 2017) mejoraron la detección de objetos a múltiples escalas combinando información de distintos niveles de resolución. La combinación Faster R-CNN con backbone ResNet50-FPN constituye hoy una línea de base robusta y ampliamente adoptada, y es la arquitectura seleccionada en este trabajo (véase el Capítulo 3).

2.3.1. Detección de objetos pequeños

La detección de objetos pequeños es un problema reconocidamente difícil: a baja resolución, los objetos aportan pocos píxeles y poco contexto, lo que degrada tanto la localización como la clasificación. En teledetección se han abordado con éxito casos de objetos reducidos o específicos —embarcaciones, aeronaves, pivotes de riego— mediante CNN (Ball et al., 2017). En el caso de los silo-bolsas, su geometría marcadamente alargada exige adaptar las cajas de anclaje del detector a relaciones de aspecto extremas, aspecto que se desarrolla en la metodología.

2.4. Trabajos previos sobre detección de silo-bolsas

El antecedente más directo es el trabajo de Barbiani y Bustamante (2022), quienes desarrollaron un detector de pivotes de riego y silo-bolsas basado en YOLOv5, utilizando imágenes de fuentes mixtas (Google Earth y Sentinel) y un dataset construido mediante etiquetado manual y aumento de datos, con un prototipo de API. Si bien demostraron la viabilidad del enfoque, su trabajo no se centró exclusivamente en Sentinel-2 ni analizó de manera sistemática la calidad de las etiquetas. El presente trabajo se diferencia al concentrarse en Sentinel-2 L2A, emplear un detector de dos etapas (Faster R-CNN) y —principalmente— al situar en el centro del análisis la comparación entre verdad de terreno limpia y ruidosa.

En problemas afines de teledetección, Fernández Marcos (2023) comparó variantes de YOLO para detección de objetos (piscinas, paneles solares) en imágenes satelitales; Tapia Catacora (2023) aplicó U-Net a la segmentación de deforestación en Landsat-8 con alta precisión; e Iglovikov et al. (2017) adaptaron U-Net a entradas multiespectrales en una competencia de Kaggle. Estos trabajos establecen metodologías y arquitecturas de referencia, aunque sobre objetos, resoluciones y sensores distintos a los de esta tesis.

2.5. Calidad de las etiquetas, ruido y aprendizaje centrado en los datos

La literatura clásica de aprendizaje automático asume conjuntos de entrenamiento correctamente etiquetados; en la práctica, las etiquetas suelen contener ruido, especialmente cuando se generan de manera automática o mediante supervisión débil (Frénay y Verleysen, 2014). El ruido de etiqueta puede degradar la generalización, sesgar las métricas y, en casos extremos, inducir el memorizado de errores por parte de la red.

Existe, no obstante, una tensión interesante en los hallazgos del campo. Por un lado, se ha mostrado que las redes profundas pueden ser sorprendentemente robustas a grandes volúmenes de ruido de etiqueta cuando el conjunto es masivo y el ruido es no sistemático (Rolnick et al., 2017). Por otro, trabajos sobre errores de etiqueta en benchmarks de referencia evidencian que incluso conjuntos consolidados contienen errores que afectan la evaluación y la comparación de modelos (Northcutt et al., 2021). Esta tensión —cantidad con ruido frente a calidad curada— es precisamente la que esta tesis examina empíricamente sobre un caso real.

El paradigma del aprendizaje *centrado en los datos* (data-centric) propone, frente a la mejora incremental de arquitecturas, concentrar el esfuerzo en la calidad, la consistencia y la representatividad del conjunto de entrenamiento. El método de etiquetado semiautomático y curación manual propuesto en este trabajo, así como el diseño experimental V2–V5, se inscriben en ese paradigma: en lugar de variar el modelo, se varía sistemáticamente la calidad del dato para medir su efecto.

2.6. Índices espectrales para la generación de etiquetas

Los índices espectrales combinan bandas para realzar características de interés; el más conocido es el NDVI, que explota el contraste entre el rojo y el infrarrojo cercano (NIR) para caracterizar la vegetación. En este trabajo se emplea un índice específico, INBNV, *[FEDE: confirmar la expansión exacta del acrónimo INBNV y, si corresponde, el antecedente bibliográfico que lo inspira.]* diseñado para realzar superficies brillantes y poco vegetadas —como el plástico blanco de los silo-bolsas— frente al resto de la escena. Su formulación y su uso para generar una capa inicial de polígonos candidatos se detallan en el Capítulo 3. La utilización del NIR en este trabajo se concentra, por lo tanto, en la *generación de las etiquetas* (no en la entrada del modelo, que es RGB), lo que constituye una decisión de diseño deliberada.

2.7. Síntesis y posicionamiento

En síntesis, si bien existen métodos generales de detección y segmentación en teledetección y un antecedente puntual sobre silo-bolsas, persiste un vacío en torno a dos cuestiones: la construcción eficiente de verdad de terreno para objetos pequeños en Sentinel-2 y la cuantificación rigurosa del efecto de la calidad de las etiquetas sobre el desempeño. Esta tesis se posiciona en ese vacío, aportando tanto un método de etiquetado semiautomático reproducible como evidencia empírica sobre la eficiencia de datos.

Capítulo 3. Solución e implementación

Este capítulo describe la solución desarrollada, desde la adquisición de las imágenes hasta el protocolo de evaluación. El sistema se estructura como un pipeline modular de notebooks numerados, lo que facilita su ejecución por etapas, su reanudación ante interrupciones y su reproducibilidad. Se presentan sucesivamente el área de estudio, el flujo de procesamiento de imágenes, el método de generación semiautomática de la verdad de terreno, el diseño experimental de las versiones del modelo, la arquitectura y el entrenamiento, y finalmente el protocolo de evaluación.

3.1. Tipo de estudio y entorno

Se trata de una investigación aplicada de tipo cuantitativo, que emplea técnicas de aprendizaje profundo para detección de objetos con el fin de resolver un problema práctico del ámbito agrícola. El desarrollo se realizó íntegramente por medios computacionales, con recursos personales y **sin disponibilidad de GPU**. Esta restricción condicionó decisiones de diseño relevantes, en particular el tamaño del modelo, el tamaño de lote y la incorporación de una lógica de reanudación desde puntos de control (checkpoints) para tolerar interrupciones durante entrenamientos prolongados. El stack tecnológico principal incluye Python, PyTorch y torchvision para el modelado, rasterio y GDAL para el manejo de imágenes, GeoPandas y QGIS para los datos vectoriales y la curación manual. *[FEDE: verificar versiones exactas de Python/PyTorch/torchvision/rasterio para consignarlas.]*

3.2. Área de estudio

El área de estudio es el departamento de Marcos Juárez, en el sudeste de la provincia de Córdoba, dentro de la denominada zona núcleo agrícola argentina. Se trata de una región de alta productividad de granos gruesos (soja y maíz), en la que el almacenamiento en silo-bolsas durante el período invernal de barbecho es una práctica extendida. El período de estudio comprende los meses de junio, julio y agosto de los años 2020 a 2025, ventana temporal que concentra el almacenamiento posterior a la cosecha.

FIGURA 3.1 — Insertar mapa de ubicación del departamento de Marcos Juárez en la zona núcleo (captura de QGIS con la capa agrícola).

Figura 3.1. Área de estudio: departamento de Marcos Juárez, provincia de Córdoba.

3.3. Adquisición de imágenes

Se utilizaron imágenes Sentinel-2 de nivel de procesamiento L2A (reflectancia de superficie), descargadas desde el repositorio público de datos abiertos de AWS (AWS Open Data Registry, s.f.). La descarga se restringió a las teselas MGRS que cubren el área de estudio y a los archivos estrictamente necesarios para el procesamiento: las bandas B02 (azul), B03 (verde), B04 (rojo) y B08 (infrarrojo cercano) a 10 m de resolución, y la capa de clasificación de escena (Scene Classification Layer, SCL) a 20 m, empleada para el enmascaramiento de nubes. *[FEDE: indicar las teselas MGRS efectivamente usadas (p. ej. 20HNH/20H NJ) y la cantidad total de escenas descargadas por año.]*

3.4. Preprocesamiento de imágenes

El preprocesamiento se organiza en una secuencia de etapas, cada una implementada como un notebook independiente:

6. **Composición de bandas y enmascaramiento de nubes.** Para cada escena se apilan las bandas en el orden rojo-verde-azul-NIR (B04, B03, B02, B08) y se construye una máscara de píxeles válidos a partir de la SCL, conservando las clases correspondientes a vegetación, suelo desnudo, agua y nieve/hielo, y descartando nubes y sombras. La SCL se remuestrea de 20 m a 10 m por vecino más cercano. Los píxeles no válidos se marcan como sin dato.
7. **Mosaico por escena.** Los fragmentos correspondientes a una misma fecha se combinan en un único mosaico mediante operaciones de merge, agrupando por identificador de escena (año, mes, día y secuencia).
8. **Recorte a la zona agrícola.** Cada mosaico se recorta utilizando una capa vectorial de zonas agrícolas del departamento, de modo de descartar superficies urbanas, cuerpos de agua y áreas no productivas, reduciendo el espacio de búsqueda y las fuentes de confusión.
9. **Teselado en parches.** Los mosaicos recortados se dividen en parches de 1024×1024 píxeles con un solapamiento del 20 %, descartando los parches con escasa información válida. Se preserva la georreferenciación de cada parche, lo que permite reconstruir la posición geográfica de las detecciones.

La nomenclatura de cada parche codifica su procedencia (año, mes, día, secuencia y posición de fila y columna en el mosaico), lo que garantiza su trazabilidad a lo largo de todo el pipeline.

FIGURA 3.2 — Insertar esquema del pipeline de preprocesamiento (descarga → composición → mosaico → recorte → teselado → índice).

Figura 3.2. Flujo de preprocesamiento de imágenes Sentinel-2.

3.5. Generación semiautomática de la verdad de terreno

La construcción del conjunto de verdad de terreno constituye una de las contribuciones centrales del trabajo. En lugar de etiquetar manualmente desde cero —tarea inviable a la escala requerida— se diseñó un procedimiento en dos fases: una generación automática de candidatos mediante un índice espectral, seguida de una curación manual.

3.5.1. Índice INBNV y obtención de polígonos candidatos

Sobre cada parche se calcula el índice INBNV, definido como

$$INBNV = ((Verde + Rojo) - NIR) / ((Verde + Rojo) + NIR)$$

El índice realza las superficies brillantes y poco vegetadas frente al resto de la escena. A partir del índice se genera una máscara binaria por umbralización: se conservan los píxeles cuyo valor supera el percentil 99,8 de la distribución de píxeles válidos, es decir, el 0,2 % más brillante. La máscara se depura eliminando los objetos menores a tres píxeles y aplicando una dilatación de un píxel, y finalmente se

vectoriza en polígonos. El resultado es una capa de polígonos candidatos a silo-bolsa para cada parche. [FEDE: confirmar el percentil (99,8) y los parámetros de tamaño mínimo (3 px) y buffer (1 px) si se ajustaron en alguna iteración.]

Esta capa automática presenta una proporción elevada de falsos positivos —del orden del 50 %—, dado que el índice también responde a bordes de lotes, caminos, techos y otras superficies reflectantes. Lejos de ser un defecto, esta característica define la tarea de curación: el índice aporta una capa base que concentra la atención del analista en las regiones de interés, transformando un problema de etiquetado desde cero en uno de corrección.

3.5.2. Curación manual en QGIS

La capa de candidatos se corrige manualmente en QGIS. Para cada parche, se cargan la imagen (con realce de contraste por media $\pm$ dos desviaciones estándar) y la capa de polígonos, y el analista elimina los falsos positivos, ajusta los polígonos válidos y agrega las silo-bolsas no detectadas por el índice. Se adoptan convenciones de visualización (capas de verdad de terreno en amarillo, predicciones en cian) y se resuelven situaciones particulares, como polígonos con identificador nulo o que exceden los límites del ráster, mediante recorte de coordenadas en el pipeline. El conjunto de imágenes en disco no se modifica en ningún momento: la gestión del dataset se realiza íntegramente mediante archivos de seguimiento (CSV) que registran el estado de cada parche y su asignación.

FIGURA 3.3 — Insertar comparación visual en QGIS: capa de candidatos del índice (con falsos positivos) vs. verdad de terreno curada.

Figura 3.3. Generación semiautomática y curación de la verdad de terreno.

3.6. Diseño experimental: las versiones V2–V5

Para responder a la pregunta de investigación se definió una progresión de cuatro versiones del modelo que mantienen fija la arquitectura y varían de manera controlada el conjunto de entrenamiento. El Cuadro 3.1 resume sus características.

Versión	Etiquetas (GT)	N.º imágenes	Muestreo	Observaciones
V2	Ruidoso (índice)	~600	—	Línea de base inicial.
V3	Ruidoso (índice)	~600	Aleatorio	Aumento de datos; muestreo aleatorio simple.
V4	Ruidoso (índice)	~10.000	Estratificado	Conjunto grande con etiquetas ruidosas.
V5	Curado (manual)	216	Estratificado balanceado	Conjunto pequeño y limpio; filtro de distancia entre teselas.

Cuadro 3.1. Diseño experimental de las versiones del modelo.

La comparación clave es la que enfrenta a V4 con V5. V4 emplea un conjunto grande (del orden de 10.000 parches) con etiquetas ruidosas autogeneradas, mientras que V5 emplea un conjunto pequeño (216 parches) con etiquetas curadas manualmente. Ambas utilizan muestreo estratificado, de modo que la diferencia de desempeño entre ambas puede atribuirse, en lo esencial, a la calidad de las etiquetas y no

a la composición del conjunto. Las versiones V2 y V3, anteriores, funcionan como puntos de referencia adicionales.

3.6.1. Muestreo estratificado y control de fuga espacial

Una versión preliminar (V3) utilizó muestreo aleatorio simple. Para evitar el sesgo temporal y garantizar la representatividad, en V4 y V5 se adoptó un muestreo estratificado por estrato año-mes (los meses de junio, julio y agosto de cada año entre 2020 y 2025, lo que define 18 estratos), con una semilla fija para asegurar la reproducibilidad. Adicionalmente, en V5 se incorporó un filtro de distancia mínima entre teselas seleccionadas, a fin de evitar la fuga de información derivada del solapamiento entre parches vecinos. El conjunto balanceado de V5 se construyó con 12 imágenes por estrato ($18 \times 12 = 216$).

3.6.2. Conjunto de reserva (holdout)

De las imágenes curadas manualmente se reservó un subconjunto (denominado Reserva), destinado exclusivamente a la evaluación, que no participó del entrenamiento de ninguna versión. La gestión de esta separación se realizó mediante una columna de asignación en el CSV de seguimiento, evitando duplicación de archivos en disco. *[FEDE: aclarar que la Reserva proviene de las primeras imágenes curadas (todas de 2020), lo que determina que el conjunto de prueba sea de ese año; ver discusión de esta limitación en el Capítulo 4.]*

3.7. Arquitectura del modelo

Se adoptó la arquitectura Faster R-CNN con backbone ResNet50-FPN (He et al., 2016; Lin et al., 2017; Ren et al., 2015), por su robustez y su buen desempeño en localización de objetos. La entrada del modelo es de tres canales (RGB); el infrarrojo cercano se reserva para la generación de las etiquetas, según se explicó. Dado el carácter pequeño y marcadamente alargado de los silo-bolsas, se personalizaron las cajas de anclaje del detector: se definieron escalas reducidas —(16), (32), (64), (128) y (256) píxeles— y relaciones de aspecto extremas —0,2; 0,5; 1,0; 2,0 y 5,0—, de modo de cubrir tanto las bolsas vistas a lo largo como a lo ancho. Esta adaptación es central para la detectabilidad a 10 m de resolución.

3.8. Entrenamiento

El conjunto de entrenamiento de V5 se construyó filtrando el CSV de seguimiento por las imágenes con estado finalizado y asignación de entrenamiento, lo que resultó en 183 imágenes de entrenamiento y 33 de validación (216 en total). *[FEDE: confirmar el split exacto 183/33 y, si corresponde, el criterio de partición.]*

El entrenamiento se realizó en CPU, con los siguientes parámetros principales: tamaño de lote igual a 2, tasa de aprendizaje inicial de 0,005, recorte de gradiente (gradient clipping) para estabilizar la optimización, y del orden de 40 épocas. *[FEDE: confirmar optimizador (p. ej. SGD con momentum), scheduler y número final de épocas.]* El tiempo de entrenamiento fue del orden de 35 a 40 minutos por época, lo que torna costosa cualquier interrupción. Por ello se implementó una lógica de reanudación desde checkpoint que guarda y restaura el estado completo de la optimización —época, pesos del

modelo, estado del optimizador y del scheduler—, lo que permitió retomar el entrenamiento tras un corte de energía sin pérdida de progreso.

Como verificación intermedia, se entrenó un checkpoint parcial con las imágenes curadas hasta ese momento (años 2020 a 2022), lo que permitió confirmar visualmente la mejora antes de comprometer el esfuerzo de anotación restante. Esta práctica de validación temprana resultó valiosa para gestionar el riesgo del proyecto.

3.9. Protocolo de evaluación

La evaluación se realizó sobre el conjunto de Reserva, con verdad de terreno curada manualmente —no con la capa ruidosa del índice—, de modo que las métricas reflejen el desempeño real frente a un patrón de referencia confiable. Para garantizar una comparación justa, se excluyeron mediante una lista negra (blacklist) los parches que hubieran sido vistos en el entrenamiento de alguna de las versiones, resultando en un conjunto de prueba de 27 imágenes. [FEDE: indicar el total de cajas de verdad de terreno en el conjunto de prueba (del orden de 586) y el año de las imágenes.]

Se computaron las métricas estándar de detección de objetos (Everingham et al., 2010; Padilla et al., 2020): *Precisión* (proporción de detecciones correctas), *Recall* o exhaustividad (proporción de silobolsas efectivamente detectadas), *F1* (media armónica de las dos anteriores) y *AP* (Average Precision). Una detección se considera verdadero positivo cuando su intersección sobre unión (IoU) con una caja de verdad de terreno supera un umbral determinado. Dado el tamaño reducido de los objetos —donde pequeños desplazamientos producen caídas grandes de IoU—, se adoptó un umbral de IoU de 0,15 para el cómputo de AP, y un umbral de confianza de 0,5 para el punto de operación reportado en Precisión, Recall y F1. [FEDE: justificar explícitamente el umbral de IoU = 0,15 (objetos pequeños a 10 m) frente al 0,5 habitual; es un punto que el jurado puede observar.]

Capítulo 4. Discusión, análisis y lecciones aprendidas

Este capítulo presenta los resultados cuantitativos de la comparación entre versiones, los interpreta a la luz de la pregunta de investigación, expone las lecciones aprendidas a lo largo del proyecto y desarrolla las consideraciones éticas, legales y de transferencia, así como las limitaciones del estudio.

4.1. Resultados cuantitativos

El Cuadro 4.1 reporta el desempeño de las cuatro versiones sobre el conjunto de prueba de Reserva, con verdad de terreno curada. Se informan Precisión, Recall, F1 y AP con umbral de IoU de 0,15, junto con el conteo de verdaderos positivos (TP), falsos positivos (FP) y falsos negativos (FN).

Modelo	Precisión	Recall	F1	AP@0.15	TP/FP/FN
V2 (ruidoso)	0,577	0,833	0,682	0,769	488/358/98
V3 (ruidoso, aleatorio)	0,700	0,761	0,729	0,690	446/191/140
V4 (ruidoso, 10k, estrat.)	0,661	0,828	0,735	0,774	485/249/101
V5 (limpio, 216, estrat.)	0,683	0,845	0,755	0,772	495/230/91

Cuadro 4.1. Desempeño comparativo de las versiones V2–V5 sobre el conjunto de prueba con verdad de terreno curada.

La versión V5 —entrenada con 216 imágenes curadas— obtiene el mejor F1 (0,755) y el mejor Recall (0,845) del conjunto, además del menor número de falsos positivos y falsos negativos. Resulta especialmente significativa la comparación con V4: V5 supera a V4 en Precisión, Recall, F1, verdaderos positivos, falsos positivos y falsos negativos, es decir, en todo el barrido del punto de operación, **utilizando aproximadamente el 2 % de los datos de entrenamiento de V4**. En la métrica AP@0.15, V4 y V5 quedan prácticamente empatadas (0,774 frente a 0,772), diferencia que se ubica dentro del margen de ruido.

4.2. Discusión: calidad de los datos frente a cantidad

El resultado central de este trabajo no es un salto abrupto de exactitud, sino un **hallazgo de eficiencia de datos**: un conjunto de entrenamiento pequeño y limpio iguala o supera a uno aproximadamente cincuenta veces mayor pero ruidoso. Este resultado es consistente con el paradigma centrado en los datos y con la literatura sobre ruido de etiqueta (Frénay y Verleysen, 2014; Northcutt et al., 2021), y aporta evidencia empírica, sobre un caso real de teledetección, de que invertir el presupuesto de anotación en calidad puede ser más rentable que invertirlo en cantidad.

Conviene precisar el alcance de la afirmación para no sobreinterpretarla. La ventaja de V5 se manifiesta de forma nítida en el punto de operación (F1 al umbral de confianza de 0,5), donde el barrido es completo, y no tanto en la métrica AP integrada, donde V4 y V5 empatan. En otras palabras, con datos limpios el modelo alcanza un mejor compromiso entre precisión y exhaustividad en el régimen de uso,

aun cuando el área bajo la curva sea comparable. Esta lectura matizada fortalece la honestidad del argumento de cara a la defensa.

4.3. Análisis cualitativo

El análisis visual de las predicciones permite caracterizar los aciertos y los errores. Los modelos detectan con solidez las silo-bolsas aisladas y bien contrastadas, y tienden a confundirse con objetos alargados y reflectantes del entorno —bordes de lotes, caminos, techos de galpones—, en línea con lo previsto. La curación del GT reduce este tipo de confusión, lo que se refleja en la menor cantidad de falsos positivos de V5. [FEDE: insertar 2–4 ejemplos visuales (parches con predicción vs. GT) ilustrando un acierto claro, un falso positivo típico y un caso difícil.]

FIGURA 4.1 — Insertar ejemplos cualitativos de detección (predicciones de V5 superpuestas a la verdad de terreno).

Figura 4.1. Ejemplos cualitativos de detección.

4.4. Lecciones aprendidas

El recorrido del proyecto dejó una serie de aprendizaje metodológicos que se consignan por su valor práctico:

- **Calidad por sobre cantidad.** La evidencia obtenida respalda priorizar la calidad del conjunto de entrenamiento; un dataset pequeño y bien curado puede ser más valioso que uno masivo y ruidoso.
- **El muestreo importa.** El reemplazo del muestreo aleatorio por uno estratificado por estrato año-mes, con control de distancia entre teselas para evitar fuga espacial, resultó decisivo para la representatividad del conjunto.
- **La fatiga de anotación es real.** Tras corregir un primer lote de imágenes, se reformuló el objetivo hacia un subconjunto estratificado balanceado de 216 imágenes, preservando el trabajo previo y reservando una porción para evaluación. Dimensionar correctamente el esfuerzo de anotación es una decisión de diseño, no un detalle operativo.
- **Validación temprana.** Entrenar un checkpoint parcial antes de completar la anotación permitió confirmar la mejora y gestionar el riesgo del proyecto.
- **Reproducibilidad y reanudación.** En entrenamientos prolongados en CPU, la lógica de reanudación desde checkpoint no es un lujo sino una necesidad; una semilla fija y un pipeline modular fueron claves para la reproducibilidad.
- **Los errores de filtrado tienen consecuencias.** Una cláusula de filtrado faltante incorporó accidentalmente imágenes de Reserva al entrenamiento; su detección y corrección a tiempo evitó contaminar la evaluación. La gestión del dataset mediante archivos de seguimiento, sin modificar el disco, facilitó la trazabilidad.

4.5. Consideraciones éticas, legales y de privacidad

La detección automatizada de infraestructura agrícola a partir de imágenes satelitales plantea consideraciones éticas que este trabajo asume de manera explícita, antes que eludir. La cuestión de fondo es que se observa actividad económica de actores —productores, campos— que no han prestado consentimiento para ese relevamiento.

Varios elementos acotan el alcance de esta tensión. En primer lugar, las imágenes Sentinel-2 son *públicas y de acceso libre*, y su resolución espacial de 10 metros es de carácter medio: no permite identificar personas ni realizar vigilancia individual fina. En segundo lugar, el objeto de detección es una *estructura de almacenamiento* —infraestructura agrícola— y no un individuo. En tercer lugar, el uso propuesto es de naturaleza *agregada y estadística* (estimar distribución y cantidad a escala regional), y no de fiscalización dirigida a casos particulares.

No obstante, persiste una tensión legítima entre el interés público de contar con información objetiva y la privacidad y el secreto comercial de los productores. Existe, además, un riesgo de inequidad: una herramienta de este tipo, en manos exclusivas de ciertos actores, podría conferir una ventaja informativa frente a otros con menor acceso. Por ello, en el marco de este trabajo, de carácter netamente académico y de alcance acotado, no se publica información asociada directamente a un campo, un propietario o una cantidad producida, y se tratan los resultados de manera estadística y global. En coherencia con la Ley 25.326 de Protección de Datos Personales de la República Argentina, no se expone ubicación geográfica precisa ni dato alguno que pueda vincularse a una persona determinada sin su consentimiento.

Cabe agregar una salvaguarda epistémica: dado que los resultados del modelo no son completamente exactos, su uso para acciones de fiscalización individual sería metodológicamente inapropiado, lo que refuerza la pertinencia de un uso estadístico y agregado.

4.6. Propuesta de valor y transferencia

El interés del trabajo se sostiene en dos planos. En el plano metodológico, el hallazgo de eficiencia de datos trasciende el caso de los silo-bolsas: interpela a cualquier proyecto de aprendizaje supervisado en el que el etiquetado sea costoso, sugiriendo que la inversión en calidad del dato puede rendir más que la inversión en volumen. En el plano aplicado, una herramienta de monitoreo de silo-bolsas de bajo costo, escalable y de revisita frecuente resulta de interés para diversos actores:

- **Organismos públicos y agropecuarios** (por ejemplo, secretarías de agricultura, organismos de recaudación y estadística, INTA): estimación del stock de granos almacenado temporalmente, insumo para estadísticas de producción y para el diseño de políticas.
- **Acopios, aseguradoras y empresas de logística**: monitoreo de inventario regional, gestión de riesgo y planificación logística (capacidad de almacenamiento, rutas de transporte).
- **Empresas del sector y operadores de mercado**: inteligencia de mercado y planificación basada en datos objetivos y actualizados.
- **Productores y dueños de campo**: monitoreo y seguimiento de su propia producción.

- **Investigación:** base metodológica para la detección de otros objetos agrícolas a 10 m de resolución y para el estudio del etiquetado débil en teledetección.

La transferencia efectiva requeriría la publicación de la metodología y, eventualmente, del dataset y de los modelos, junto con una documentación clara de capacidades y limitaciones. El desarrollo de interfaces o servicios de consulta excede el alcance de esta tesis.

4.7. Limitaciones del estudio

Se reconocen las siguientes limitaciones. **(i) Resolución.** La resolución de 10 m limita la detección de silo-bolsas muy pequeñas, agrupadas o parcialmente visibles. **(ii) Validación temporal.** El conjunto de prueba proviene íntegramente del año 2020 —por haberse reservado de las primeras imágenes curadas—, de modo que evalúa la generalización a teselas no vistas dentro de un año conocido, pero no la generalización a años distintos. Importa señalar que, aun así, V4 dispuso de mucha mayor exposición a 2020 durante el entrenamiento que V5 y, pese a ello, V5 obtiene mejor desempeño, lo que refuerza el argumento de calidad de etiquetas. La validación temporal sobre imágenes de 2026 —en curso— constituye la prueba definitiva en este sentido. *[FEDE: incorporar los resultados de la validación temporal 2026 cuando estén disponibles.]*

(iii) Dependencia del dato. El desempeño depende fuertemente de la calidad y representatividad del conjunto curado. **(iv) Confusión con objetos similares.** Persiste la posibilidad de confundir silo-bolsas con bordes de lotes, caminos o galpones. **(v) Especificidad de sitio.** El modelo, entrenado sobre Marcos Juárez, puede presentar sesgo hacia las condiciones de esa zona, lo que sugiere la necesidad de reentrenamiento fino para su aplicación en otras regiones.

Capítulo 5. Conclusiones y trabajos futuros

5.1. Conclusiones

Este trabajo desarrolló y validó un detector de silo-bolsas en imágenes Sentinel-2 para el departamento de Marcos Juárez, y —de manera central— examinó empíricamente el efecto de la calidad de la verdad de terreno sobre el desempeño del modelo. En relación con los objetivos planteados, se construyó una base de datos de imágenes Sentinel-2 preprocesadas para el período junio–agosto de 2020 a 2025; se diseñó e implementó un método de etiquetado semiautomático basado en un índice espectral, con curación manual en QGIS; se definió una progresión experimental controlada (V2–V5) que aísla el efecto de la calidad de las etiquetas; se entrenó un Faster R-CNN ResNet50-FPN con cajas de anclaje adaptadas a la geometría de los silo-bolsas, bajo restricciones de cómputo en CPU; y se evaluaron y compararon las versiones sobre un conjunto de prueba con verdad de terreno curada.

La conclusión principal es que **la calidad de la verdad de terreno prima sobre su cantidad**: la versión entrenada con 216 imágenes curadas igualó o superó a la entrenada con cerca de 10.000 imágenes ruidosas, alcanzando el mejor F1, el mejor Recall y la menor cantidad de errores, con apenas el 2 % de los datos. Este resultado, más que una mejora marginal de exactitud, constituye un argumento de eficiencia de datos con implicancias que exceden el caso de estudio, y respalda la adopción de un enfoque centrado en los datos para problemas de detección con etiquetado costoso.

Se concluye, asimismo, que la generación semiautomática de etiquetas mediante un índice espectral —seguida de curación manual— es una estrategia viable y reproducible para reducir el costo de anotación en la detección de objetos pequeños en teledetección, y que la adaptación de las cajas de anclaje a la geometría alargada de los silo-bolsas es necesaria para su detectabilidad a 10 m de resolución.

5.2. Trabajos futuros

A partir de lo anterior, se identifican las siguientes líneas de continuación:

- **Validación temporal.** Completar la evaluación sobre imágenes de un año no visto (2026) para medir la generalización temporal, prueba definitiva del enfoque.
- **Incorporación del NIR al modelo.** Evaluar de manera explícita y cuantitativa el aporte de una entrada de cuatro canales (RGB+NIR) frente a la entrada RGB, adaptando la arquitectura.
- **Fusión con datos de radar.** Integrar Sentinel-1, insensible a la nubosidad, para asegurar un monitoreo continuo independiente de las condiciones atmosféricas (Victor et al., 2025).
- **Segmentación y medición.** Extender de la detección a la segmentación para estimar dimensiones y, a partir de ellas, volúmenes de grano almacenado.
- **Generalización geográfica.** Aplicar y reentrenar el modelo en otras regiones agrícolas, con ajuste fino sobre datos locales.
- **Mayor resolución.** Explorar imágenes comerciales de mayor resolución para los casos donde 10 m resulte insuficiente.

- **Despliegue.** Desarrollar interfaces o servicios que faciliten la consulta de los resultados por parte de los distintos actores.

En conjunto, el trabajo aporta tanto una herramienta concreta para un problema relevante de la agroindustria argentina como una evidencia metodológica —la eficiencia de datos— de interés general para la comunidad de aprendizaje automático.

Bibliografía

- Aapresid. (2023). Aplicaciones selectivas: indagamos quiénes adoptaron. Aapresid Blog. <https://www.aapresid.org.ar/blog/aplicaciones-selectivas-indagamos-quienes-adoptaron>
- AWS Open Data Registry. (s.f.). Sentinel-2. Recuperado de <https://registry.opendata.aws/sentinel-2/>
- Ball, J. E., Anderson, D. T., & Chan, C. S. (2017). Comprehensive survey of deep learning in remote sensing: theories, tools, and challenges for the community. *Journal of Applied Remote Sensing*, 11(4), 042609. <https://doi.org/10.1117/1.JRS.11.042609>
- Barbiani, G., & Bustamante, L. (2022). Detector de pivotes de riego y silo bolsas en imágenes satelitales para aplicaciones agrícolas [Proyecto Integrador, Universidad Nacional de Córdoba].
- Copernicus. (s.f.). Sentinel-2 Data Collection. Copernicus Data Space Ecosystem. Recuperado de <https://dataspace.copernicus.eu/data-collections/copernicus-sentinel-data/sentinel-2>
- CREA. (2023). Aplicaciones dirigidas: estado actual y futuro. Contenidos CREA. <https://www.contenidoscrea.org.ar/agricultura/aplicaciones-dirigidas-estado-actual-y-futuro-n5326635>
- Everingham, M., Van Gool, L., Williams, C. K. I., Winn, J., & Zisserman, A. (2010). The Pascal Visual Object Classes (VOC) Challenge. *International Journal of Computer Vision*, 88(2), 303-338. <https://doi.org/10.1007/s11263-009-0275-4>
- Expoagro. (2025). Silobolsa: el invento argentino que soluciona problemas globales. Expoagro Digital. <https://www.expoagro.com.ar/silobolsa-el-invento-argentino-que-soluciona-problemas-globales/>
- Fernández Marcos, S. (2023). Sistema de reconocimiento de patrones en imágenes satelitales para la detección de objetos [Trabajo de Fin de Máster, Universidad de Salamanca].
- Filgueira, E. (2013). Silo bolsa. C3T-UTN. <https://c3t-utn.ar/wp-content/uploads/2013/07/Silo-Bolsa.pdf>
- Frénay, B., & Verleysen, M. (2014). Classification in the presence of label noise: A survey. *IEEE Transactions on Neural Networks and Learning Systems*, 25(5), 845-869. <https://doi.org/10.1109/TNNLS.2013.2292894>
- Girshick, R. (2015). Fast R-CNN. *Proceedings of the IEEE International Conference on Computer Vision (ICCV)*, 1440-1448.

- GISGeography. (s.f.). Sentinel-2 bands and combinations. Recuperado de <https://gisgeography.com/sentinel-2-bands-combinations/>
- Gobierno de Argentina. (2025a). Más del 40 % de la producción nacional se conserva en silobolsas. Argentina.gob.ar. <https://www.argentina.gob.ar/noticias/mas-del-40-de-la-produccion-nacional-se-conserva-en-silobolsas>
- Gobierno de Argentina. (2025b). Monitoreo inteligente para preservar la calidad de los granos. Argentina.gob.ar. <https://www.argentina.gob.ar/noticias/monitoreo-inteligente-para-preservar-la-calidad-de-los-granos>
- He, K., Zhang, X., Ren, S., & Sun, J. (2016). Deep residual learning for image recognition. Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition (CVPR), 770-778.
- Iglovikov, V., Mushinskiy, S., & Osin, V. (2017). Satellite imagery feature detection using deep convolutional neural network: A Kaggle competition. arXiv. <https://arxiv.org/abs/1706.06169>
- INTA. (s.f.). Almacenamiento de granos en bolsas plásticas. Agroconsultas Online.
- Lin, T.-Y., Dollár, P., Girshick, R., He, K., Hariharan, B., & Belongie, S. (2017). Feature pyramid networks for object detection. Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition (CVPR), 2117-2125.
- Lin, T.-Y., Maire, M., Belongie, S., Hays, J., Perona, P., Ramanan, D., Dollár, P., & Zitnick, C. L. (2014). Microsoft COCO: Common objects in context. European Conference on Computer Vision (ECCV), 740-755.
- Muñoz, C., Acevedo, P., Salvo, S., Fagalde, G., & Vargas, F. (2007). Detección de incendios forestales utilizando imágenes NOAA/16-LAC en la Región de La Araucanía, Chile. BOSQUE, 28(2), 119-128. <http://dx.doi.org/10.4067/S0717-92002007000200003>
- Muzlera, J. (2024). Silo bolsa (Argentina, 1991-2023). En J. Muzlera & A. Salomón (Eds.), Diccionario del agro iberoamericano (5.^a ed. ampliada). <https://www.teseopress.com/diccionarioagro/chapter/silo-bolsa-argentina-1991-2023/>
- Northcutt, C. G., Athalye, A., & Mueller, J. (2021). Pervasive label errors in test sets destabilize machine learning benchmarks. Proceedings of the Neural Information Processing Systems Track on Datasets and Benchmarks (NeurIPS).
- Padilla, R., Netto, S. L., & da Silva, E. A. B. (2020). A survey on performance metrics for object-detection algorithms. International Conference on Systems, Signals and Image Processing (IWSSIP).
- Paszke, A., Gross, S., Massa, F., Lerer, A., Bradbury, J., Chanan, G., ... Chintala, S. (2019). PyTorch: An imperative style, high-performance deep learning library. Advances in Neural Information Processing Systems, 32.

- Ren, S., He, K., Girshick, R., & Sun, J. (2015). Faster R-CNN: Towards real-time object detection with region proposal networks. *Advances in Neural Information Processing Systems*, 28.
- Rolnick, D., Veit, A., Belongie, S., & Shavit, N. (2017). Deep learning is robust to massive label noise. *arXiv*. <https://arxiv.org/abs/1705.10694>
- Tapia Catacora, P. C. (2023). Detección de deforestación de bosques en imágenes satelitales con redes neuronales convolucionales [Tesis Doctoral, Universidad Nacional del Altiplano].
- Victor, B., Nibali, A., & He, Z. (2025). A systematic review of the use of deep learning in satellite imagery for agriculture. *arXiv*. <https://arxiv.org/abs/2210.01272>
- Zhang, L., Zhang, L., & Du, B. (2016). Deep learning for remote sensing data: A technical tutorial on the state of the art. *IEEE Geoscience and Remote Sensing Magazine*, 4(2), 22-40. <https://doi.org/10.1109/MGRS.2016.2540798>

Apéndices

Apéndice A. Estructura del pipeline de procesamiento

El procesamiento se organizó como una secuencia de notebooks numerados, modulares y reanudables. Los notebooks 01 a 06 cubren la adquisición y el preprocesamiento de las imágenes (descarga, composición de bandas, mosaico, recorte a la zona agrícola, teselado y cálculo del índice INBNV con generación de polígonos candidatos); los notebooks subsiguientes abarcan el entrenamiento de las versiones del modelo y la evaluación comparativa. Los datos de origen no se modifican; las salidas se versionan y la gestión del dataset se realiza mediante archivos de seguimiento (CSV). *[FEDE: incluir aquí, si se desea, un diagrama del pipeline y/o una tabla con el nombre y la función de cada notebook.]*

Apéndice B. Configuración de entrenamiento

Arquitectura: Faster R-CNN con backbone ResNet50-FPN. Anclas (escalas): (16), (32), (64), (128) y (256) píxeles. Relaciones de aspecto: 0,2; 0,5; 1,0; 2,0 y 5,0. Entrada: RGB (3 canales). Semilla: 456. Tamaño de lote: 2. Tasa de aprendizaje inicial: 0,005. Recorte de gradiente activado. Épocas: del orden de 40. Entorno: CPU. Reanudación desde checkpoint con estado completo (época, modelo, optimizador, scheduler). *[FEDE: confirmar/ampliar optimizador, scheduler, función de pérdida y transformaciones de datos.]*

Apéndice C. Detalle del muestreo estratificado

El muestreo estratificado se definió sobre 18 estratos (meses de junio, julio y agosto de los años 2020 a 2025). El conjunto balanceado de la versión V5 se construyó con 12 imágenes por estrato ($18 \times 12 = 216$), con semilla fija y filtro de distancia mínima entre teselas para evitar fuga espacial. *[FEDE: incluir, si se desea, la tabla de cantidades por estrato y el valor del filtro de distancia.]*