UNIVERSIDAD AUSTRAL

Maestría en Explotación de Datos y Gestión del Conocimiento

Detección de silo-bolsas mediante técnicas de aprendizaje profundo en imágenes satelitales Sentinel-2 para el departamento de Marcos Juárez, zona núcleo de Argentina

Trabajo Final de Maestría

Autor: Federico Richard

Director: Gonzalo Sad

Octubre de 2026

Rosario, Argentina

Resumen

El almacenamiento de granos en silo-bolsas concentra cerca del 40 % de la producción agrícola argentina, pero no existe un mecanismo escalable, frecuente y de bajo costo para estimar su distribución a partir de datos objetivos. Este trabajo desarrolla y valida un detector de silo-bolsas en imágenes satelitales Sentinel-2 (RGB, 10 m de resolución) para el departamento de Marcos Juárez, en la zona núcleo de Argentina, durante el período junio-agosto de 2020 a 2025. El aporte central es metodológico: se examina empíricamente en qué medida la calidad de la verdad de terreno, etiquetas curadas manualmente frente a etiquetas ruidosas autogeneradas mediante un índice espectral de elaboración propia (INBNV), condiciona el desempeño del modelo.

Se implementó un pipeline modular de procesamiento de imágenes y un método de etiquetado semiautomático con curación manual en QGIS, y se diseñó una progresión de cuatro versiones de un detector Faster R-CNN con backbone ResNet50-FPN y cajas de anclaje adaptadas a la geometría alargada de los silo-bolsas, entrenadas en CPU. La evaluación sobre un conjunto de prueba con verdad de terreno curada muestra que la versión entrenada con 216 imágenes limpias iguala o supera a la entrenada con cerca de 10.000 imágenes ruidosas, alcanzando el mejor F1 (0,845), la mejor precisión (0,864) y la menor cantidad de falsos positivos, utilizando aproximadamente el 2 % de los datos. Más que una mejora marginal de exactitud, el resultado constituye un hallazgo de eficiencia de datos con implicancias que exceden el caso de estudio. Una validación temporal sobre 29 teselas de 2026, un año no visto durante el entrenamiento, es consistente con este comportamiento: la versión curada obtiene el mejor desempeño global (F1 de 0,801), lo que sugiere que la ventaja no obedece a un sobreajuste al período de entrenamiento.

Palabras clave: teledetección; Sentinel-2; aprendizaje profundo; detección de objetos; Faster R-CNN; silo-bolsas; calidad de etiquetas; agricultura de precisión.

Dedicatoria

A mí mismo, por la terquedad de perseguir este sueño desde 2020 una y otra vez y por los kilómetros recorridos para alcanzarlo.

Agradecimientos

En primer lugar, quiero agradecerme a mí mismo por el esfuerzo sostenido a lo largo de estos años. Por no haber bajado los brazos ante ese anhelo, que desde 2020 parecía un sueño sonso y repetitivo, de convertirme en especialista en ciencia de datos. Por haberme animado a enfrentar un problema que me venía persiguiendo desde entonces, demostrando empíricamente que era factible resolverlo, y por sentarme a trabajar hasta darle un cierre definitivo. Esta tesis marca el final de una gran etapa y el comienzo de otra, y corona el enorme esfuerzo físico y mental que implicaron los constantes viajes a Rosario, tanto desde Buenos Aires como desde Córdoba.

A mi pareja, Josefina Serra, gracias infinitas por bancarme de manera incondicional. Gracias por tu paciencia, por comprender y respetar mis tiempos, y por ser el pilar emocional que me permitió llevar adelante y sostener todo este proceso desde el comienzo hasta el final.

A mi director, Gonzalo Sad y a la Universidad Austral, por su dedicación y su acompañamiento. Su orientación fue clave para darle forma a este trabajo.

A mis compañeros del "Grupo 1" de la maestría: Federico Grijalba, Lautaro Ruiz y Paola Szekieta. Gracias por el trabajo en equipo, las horas de estudio compartidas y por haber hecho que este exigente camino fuera mucho más ameno, sin ellos hoy no estaría acá.

Por último, a Syngenta, por confiar en mí y apostar por mi desarrollo profesional, brindándome el respaldo y el apoyo económico fundamental para que esta meta académica fuera posible.

Índice General

Resumen II
Dedicatoria III
Agradecimientos IV
Índice General V
Índice de Cuadros VII
Índice de Figuras VIII
Abreviaturas IX
Capítulo 1. Introducción 1
1.1. Planteo del problema 1
1.2. Pregunta de investigación e hipótesis 2
1.3. Objetivos 2
Objetivo general 2
Objetivos específicos 2
1.4. Aportes del trabajo 3
1.5. Alcance y limitaciones 3
1.6. Estructura del documento 4
Capítulo 2. Estado del arte 5
2.1. Teledetección y agricultura de precisión 5
2.1.1. La misión Sentinel-2 y el nivel de procesamiento L2A 5
2.2. El silo-bolsa como objeto de estudio 7
2.3. Detección de objetos en imágenes satelitales con aprendizaje profundo 8
2.3.1. Detección de objetos pequeños 8
2.3.2. Transferencia de aprendizaje y preentrenamiento 8
2.4. Trabajos previos sobre detección de silo-bolsas 9
2.5. Calidad de las etiquetas, ruido y aprendizaje centrado en los datos 10
2.6. Índices espectrales para la generación de etiquetas 10
2.7. Síntesis y posicionamiento 11
Capítulo 3. Solución e implementación 12
3.1. Tipo de estudio y entorno 12
3.2. Área de estudio 12
3.3. Adquisición de imágenes 13
3.4. Preprocesamiento de imágenes 14
3.5. Generación semiautomática de la verdad de terreno 16
3.5.1. Índice INBNV y obtención de polígonos candidatos 17
3.5.2. Curación manual en QGIS 19
3.6. Diseño experimental: las versiones V2-V5 23
3.6.1. Muestreo estratificado y control de fuga espacial 24
3.6.2. Conjunto de reserva (holdout) 24

3.7. Arquitectura del modelo 25
3.8. Entrenamiento 25
3.9. Protocolo de evaluación 27
Capítulo 4. Discusión, análisis y lecciones aprendidas 29
4.1. Resultados cuantitativos 29
4.2. Consideraciones metodológicas de la evaluación: deduplicación y umbral de confianza 29
4.2.1. Detecciones duplicadas 30
4.2.2 Umbral de confianza 32
4.2.3 Significancia estadística 32
4.3. Anatomía de los errores: recall equivalente y límite de detectabilidad por resolución 33
4.4. Discusión: calidad de los datos frente a cantidad 36
4.5. Análisis cualitativo 37
4.6. Validación temporal sobre imágenes de 2026 38
4.7. Lecciones aprendidas 41
4.8. Consideraciones éticas, legales y de privacidad 42
4.9. Propuesta de valor y transferencia 43
4.10. Limitaciones del estudio 43
Capítulo 5. Conclusiones y trabajos futuros 46
5.1. Conclusiones 46
5.2. Trabajos futuros 46
Bibliografía 49
Apéndices 53
Apéndice A. Estructura del pipeline de procesamiento 53
Apéndice B. Configuración de entrenamiento 54
B.1 Configuración común a todas las versiones. 54
B.2 Régimen de entrenamiento por versión 54
B.3 Composición de los conjuntos 54
B.4 Entorno de software 54
Apéndice C. Detalle del muestreo estratificado 55
Apéndice D. Escala radiométrica y análisis de sensibilidad 55
Apéndice E. Validación temporal: conjunto completo de teselas 56

Índice de Cuadros

Cuadro 2.1. Bandas de Sentinel-2 L2A empleadas en este trabajo.

Cuadro 3.1. Diseño experimental de las versiones del modelo.

Cuadro 4.1. Desempeño comparativo de las versiones V2-V5 sobre el conjunto de prueba (2020).

Cuadro 4.2. Significancia estadística de las diferencias entre versiones (2020).

Cuadro 4.3. Verdaderos positivos por versión según el umbral de confianza (2020).

Cuadro 4.4. Ejemplo ilustrativo del techo de detectabilidad y del rol de los falsos positivos.

Cuadro 4.5. Validación temporal sobre imágenes de 2026.

Cuadro 4.6. Significancia estadística de las diferencias entre versiones (2026).

Cuadro A.1. Notebooks del pipeline: nombre, etapa y función

Cuadro B.1. Configuración de entrenamiento por versión.

Cuadro D.1. Percentiles de la banda B04 por año.

Cuadro D.2. Sensibilidad de V4 y V5 al desplazamiento radiométrico.

Índice de Figuras

Figura 2.1. Bandas de Sentinel-2 y sus resoluciones espaciales.

Figura 2.2. El silo-bolsa en tres escalas de observación.

Figura 3.1. Área de estudio: departamento de Marcos Juárez.

Figura 3.2. Ciclo productivo de los cultivos estivales y ventana de observación.

Figura 3.3. Teselas MGRS de Sentinel-2 que cubren el área de estudio.

Figura 3.4. Flujo de preprocesamiento de imágenes Sentinel-2.

Figura 3.5. Ejemplo real de las etapas del preprocesamiento.

Figura 3.6. Generación de candidatos mediante el índice INBNV.

Figura 3.7. Silo-bolsas verdaderas y confusores frecuentes del índice INBNV.

Figura 3.8. Correcciones introducidas por la curación manual.

Figura 3.9. Generación semiautomática y curación de la verdad de terreno.

Figura 4.1. Efecto de la deduplicación por NMS sobre las predicciones de V5.

Figura 4.2. Análisis de sensibilidad al umbral y curvas de precisión-recall.

Figura 4.3. Detectabilidad por versión sobre una tesela representativa (2020).

Figura 4.4. Curvas de entrenamiento de V4 y V5.

Figura 4.5. Comparación cualitativa de detecciones (V4 frente a V5).

Figura 4.6. Detecciones de V4 y V5 sobre la validación temporal de 2026.

Figura E.1. Conjunto de validación temporal sobre imágenes de 2026.

Abreviaturas

AOI	Área de Interés (Area of Interest).
AP	Average precision (precisión promedio); métrica de detección.
CNN	Red Neuronal Convolucional (Convolutional Neural Network).
CV	Visión por Computadora (Computer Vision).
DL	Aprendizaje Profundo (Deep Learning).
F1	Media armónica entre precisión y recall.
FN	Falso Negativo.
FP	Falso Positivo.
FPN	Red Piramidal de Características (Feature Pyramid Network).
GT	Verdad de Terreno (Ground Truth).
INBNV	Índice Normalizado de Blancos No Vegetados; índice espectral propuesto en este trabajo para la generación semiautomática de etiquetas (véase Sección 3.5).
IoU	Intersección sobre Unión (Intersection over Union).
L2A	Nivel de procesamiento 2A de Sentinel-2 (reflectancia de superficie).
mAP	mean Average Precision.
MGRS	Sistema de referencia de cuadrícula militar (Military Grid Reference System).
NDVI	Índice de Vegetación de Diferencia Normalizada
NMS	Supresión de no máximos (Non-Maximum Suppression); descarta detecciones redundantes superpuestas.
NIR	Infrarrojo Cercano (Near Infrared).
R-CNN	Red Neuronal Convolucional basada en Regiones (Region-based CNN).
RGB	Rojo, Verde y Azul (canales del espectro visible).
RS	Teledetección o Sensado Remoto (Remote Sensing).
SCL	Capa de Clasificación de Escena de Sentinel-2 (Scene Classification Layer).
TP	Verdadero Positivo.

Capítulo 1. Introducción

El sector agroindustrial argentino constituye uno de los pilares de la economía nacional, y dentro de su cadena de valor, el almacenamiento temporal de granos en silo-bolsas, ocupa un lugar central. Se estima que cerca del 40 % de la producción agrícola del país se conserva en este tipo de estructuras (Gobierno de Argentina, 2025a), lo que las convierte en un elemento logístico y financiero clave para productores, acopios, aseguradoras, empresas exportadoras, financieras y organismos públicos. Sin embargo, no existe en la actualidad un mecanismo escalable, frecuente y de bajo costo que permita estimar de manera objetiva la distribución, la temporalidad y la cantidad de silo-bolsas presentes en el territorio en un momento dado.

La teledetección satelital ofrece una vía prometedora para abordar este problema. La misión Sentinel-2 del programa europeo Copernicus provee imágenes multiespectrales de acceso libre y gratuito, con una resolución espacial de 10 metros en las bandas del espectro visible y del infrarrojo cercano y una revisita de aproximadamente cinco días (Copernicus, s.f.), con un alcance global. La combinación de estos datos con técnicas modernas de aprendizaje profundo (Deep Learning, DL) y visión por computadora habilita la automatización de tareas de monitoreo que hasta hace pocos años requerían inspección manual o relevamientos de campo costosos (Ball et al., 2017; Zhang et al., 2016).

Ahora bien, el cuello de botella de estos enfoques rara vez es el modelo: es el dato etiquetado. Entrenar un detector de objetos supervisado exige un conjunto de verdad de terreno (Ground Truth, GT) en el que cada silo-bolsa esté delimitado por un analista. La construcción de ese conjunto, sobre objetos pequeños y poco contrastados a 10 metros de resolución, es lenta, costosa y propensa a errores. Frente a ello surge una tensión metodológica de fondo, que es la que motiva este trabajo: ante un presupuesto de etiquetado limitado, ¿conviene invertir el esfuerzo en muchas etiquetas generadas de forma automática (y por lo tanto ruidosas) o en pocas etiquetas curadas manualmente con alta calidad?

1.1. Planteo del problema

La digitalización automática de silo-bolsas, entendida como su detección y localización a partir de imágenes Sentinel-2, enfrenta tres dificultades simultáneas. En primer lugar, la **resolución espacial** de 10 metros sitúa al silo-bolsa en el límite de lo detectable: una bolsa típica de unos 60-75 m de largo por 3-5 m de ancho ocupa apenas unos pocos píxeles de ancho (Filgueira, 2013). En segundo lugar, la **variabilidad** temporal y ambiental es alta: si bien el silo-bolsa presenta un aspecto relativamente constante (una lona plástica predominantemente blanca), su entorno cambia entre años secos y húmedos, entre meses y según la condición de la superficie (suelo desnudo, rastrojo o cultivo circundante), y su propio estado también varía: bolsas completas o parcialmente consumidas, aisladas o agrupadas en acopios según el momento del ciclo agrícola. En tercer lugar, y de manera determinante,

la **disponibilidad de etiquetas de calidad** es escasa: no existen datasets públicos de silo-bolsas en Sentinel-2, por lo que el GT debe construirse desde cero (Ball et al., 2017).

Para mitigar el costo de etiquetado, en este trabajo se desarrolla una estrategia de generación **semiautomática** de etiquetas a partir de un índice espectral (denominado INBNV), que produce una capa inicial de polígonos candidatos. Esa capa, sin embargo, contiene una proporción elevada de falsos positivos (alrededor del 60 %; Sección 3.5.1), dado que el índice responde a la firma espectral de superficies brillantes y no exclusivamente a silo-bolsas. Surge entonces la pregunta central de investigación.

1.2. Pregunta de investigación e hipótesis

La pregunta que estructura el trabajo final de maestría es la siguiente: **¿produce un conjunto de entrenamiento pequeño con etiquetas curadas manualmente un modelo de detección de mejor desempeño que un conjunto mucho mayor con etiquetas ruidosas autogeneradas?** La hipótesis de trabajo sostiene que la calidad del GT prima sobre su cantidad: que un dataset reducido y limpio puede igualar o superar a uno considerablemente más grande pero ruidoso, y que ese resultado constituye un argumento de eficiencia de datos con implicancias que exceden el caso de los silo-bolsas; por otro lado, un dataset grande (pero ruidoso) puede aportar más contexto de situación a la detección, como distintos fondos, bordes, orientaciones, tonalidades, etc. En términos coloquiales, la hipótesis pone a prueba el principio de "garbage in, garbage out": la calidad de los datos de entrada condiciona la del resultado.

Para poner a prueba esta hipótesis se diseñó una progresión de cuatro versiones de modelo (V2 a V5, siendo V1 una primera prueba de concepto que no entra en la discusión de este trabajo), descripta en detalle en el Capítulo 3, que mantiene fija la arquitectura y varía de manera sistemática el origen, el tamaño y la estrategia de muestreo del conjunto de entrenamiento, con el foco puesto en el efecto de la calidad de las etiquetas.

1.3. Objetivos

Objetivo general

Desarrollar y validar un modelo de detección de objetos basado en redes neuronales convolucionales que, a partir de imágenes satelitales Sentinel-2 (RGB) del departamento de Marcos Juárez (Córdoba, Argentina), permita localizar silo-bolsas, y evaluar cuantitativamente en qué medida la calidad de la verdad de terreno (etiquetas curadas manualmente frente a etiquetas ruidosas autogeneradas) condiciona el desempeño del modelo.

Objetivos específicos

1. Construir una base de datos de imágenes Sentinel-2 L2A georreferenciadas, preprocesadas (composición de bandas, enmascaramiento de nubes, mosaico, recorte a la zona agrícola y

teselado en parches) y generación de UID (Unique Identifier) basado en nomenclatura trazable de teselas, para el período junio-agosto de los años 2020 a 2025 para el área de estudio.

2. Diseñar e implementar un método de generación semiautomática de etiquetas mediante un índice espectral (INBNV), y un flujo de curación manual en QGIS que corrija los falsos positivos resultantes y agregue los no detectados inicialmente por el índice.
3. Definir una progresión experimental de modelos (V2-V5) que, manteniendo constante la arquitectura, permita estudiar el efecto de la calidad y la cantidad de las etiquetas, así como de la estrategia de muestreo.
4. Entrenar y optimizar un detector Faster R-CNN con backbone ResNet50-FPN, adaptando las cajas de anclaje (anchors) a la geometría alargada y pequeña de los silo-bolsas, bajo restricciones de cómputo en CPU.
5. Evaluar y comparar las versiones sobre un conjunto de prueba independiente con verdad de terreno curada, mediante métricas de detección (precisión, recall, F1, AP e IoU), y analizar el hallazgo de eficiencia de datos resultante.
6. Evaluar y comparar las versiones sobre un conjunto de un año no evaluado y completamente nuevo para el modelo, para este caso el año 2026 durante los periodos junio-agosto.

1.4. Aportes del trabajo

Los principales aportes de esta tesis son: **(i)** un índice espectral de elaboración propia (INBNV) y un método reproducible de etiquetado semiautomático basado en él, que convierte el etiquetado desde cero en una tarea de verificación y corrección; **(ii)** evidencia cuantitativa, sobre un caso real, de que un conjunto pequeño y curado (216 imágenes) iguala o supera a uno cerca de cincuenta veces mayor pero ruidoso (alrededor de 10.000 imágenes), resultado que se interpreta en términos de eficiencia de datos; **(iii)** un pipeline modular, de bajo costo, reproducible y reanudable de adquisición y procesamiento de imágenes Sentinel-2, orientado a la detección de objetos pequeños; **(iv)** una discusión explícita de las implicancias éticas, legales y de transferencia de un sistema de observación de infraestructura agrícola basado en datos públicos; y **(v)** un modelo entrenado de detección de silo-bolsas, cuya capacidad de generalización se verificó sobre imágenes de un año no visto durante el entrenamiento (2026).

1.5. Alcance y limitaciones

El estudio se circunscribe geográficamente al departamento de Marcos Juárez, en la zona núcleo de Argentina, y temporalmente al período invernal de barbecho (junio-agosto) de 2020 a 2025, ventana en la que se concentra el almacenamiento de grano favorecido por la temporada de cosecha de granos de período estival (maíz, soja, girasol). El desarrollo y el entrenamiento se realizaron con recursos de cómputo personales y sin uso de GPU, lo que condicionó el tamaño de los modelos y los tiempos de entrenamiento. El trabajo aborda la detección (localización mediante cajas delimitadoras) y no la

segmentación pixel a pixel (queda abierto a trabajos futuros); Las limitaciones específicas de resolución, generalización y disponibilidad de imágenes se retoman en el Capítulo 4.

Asimismo, la resolución espacial del sensor (10 m/píxel en las bandas ópticas de Sentinel-2) resulta marginal respecto del ancho físico de un silo-bolsa (~3 m), lo que plantea el desafío de detectar estructuras de escala sub-píxel y puede afectar el desempeño del modelo.

1.6. Estructura del documento

El resto del trabajo se organiza de la siguiente manera. El **Capítulo 2** revisa el estado del arte en teledetección para agricultura, detección de objetos con DL y, en particular, la problemática del ruido en las etiquetas y el paradigma centrado en los datos. El **Capítulo 3** describe la solución implementada: el área de estudio, el pipeline de datos, el método de etiquetado semiautomático, el diseño experimental de las versiones V2-V5, la arquitectura del modelo y el protocolo de evaluación. El **Capítulo 4** presenta y discute los resultados, las lecciones aprendidas y las consideraciones éticas y legales. Finalmente, el **Capítulo 5** expone las conclusiones y las líneas de trabajo futuro.

Capítulo 2. Estado del arte

Este capítulo sitúa el trabajo en el cruce de tres campos: la teledetección aplicada a la agricultura de precisión, la detección de objetos en imágenes satelitales mediante aprendizaje profundo, y la línea de investigación, más reciente y central para esta tesis, que estudia el impacto de la calidad de las etiquetas en el desempeño de los modelos.

2.1. Teledetección y agricultura de precisión

La agricultura de precisión se define como un enfoque de gestión que observa, mide y responde a la variabilidad espacial y temporal dentro y entre lotes de cultivo (International Society of Precision Agriculture [ISPA], 2018), con el fin de tomar mejores decisiones basadas en información. Entre sus tecnologías habilitantes, los sensores remotos (drones e imágenes satelitales como principales) ocupan un lugar destacado, dado que permiten relevar grandes superficies de manera consistente y periódica (Victor et al., 2024; Zhang et al., 2016). Las imágenes Sentinel-2, por su cobertura global, su revisita frecuente y su carácter gratuito, se han consolidado como una fuente de referencia para aplicaciones agrícolas (GISGeography, s.f.), siendo estas centro de estudio de miles de trabajos relacionados a la agricultura de precisión.

Un dato satelital, sin embargo, no genera valor por sí solo: requiere procesos de extracción de información que lo conviertan en conocimiento accionable. La detección de estructuras de almacenamiento temporal, como los silo-bolsas, es un ejemplo de esa extracción de información específica, todavía poco explorada en la literatura publicada respecto de otras aplicaciones más establecidas, como el monitoreo de cobertura y uso del suelo (Victor et al., 2024), la identificación de cultivos, la detección de puntos de calor para la identificación de incendios (Muñoz et al., 2007), entre muchas otras.

2.1.1. La misión Sentinel-2 y el nivel de procesamiento L2A

Sentinel-2 es una misión del programa europeo Copernicus, operada por la Agencia Espacial Europea (ESA, por sus siglas en inglés), compuesta por dos satélites gemelos que en conjunto revisitan cada punto del planeta con una frecuencia del orden de cinco días (Drusch et al., 2012; Copernicus, s.f.). Su instrumento multiespectral captura trece bandas que abarcan del visible al infrarrojo de onda corta, con resoluciones espaciales de 10, 20 y 60 metros según la banda (Figura 2.1); los datos son de acceso libre y gratuito, condición que habilita la escalabilidad y el bajo costo perseguidos en este trabajo.

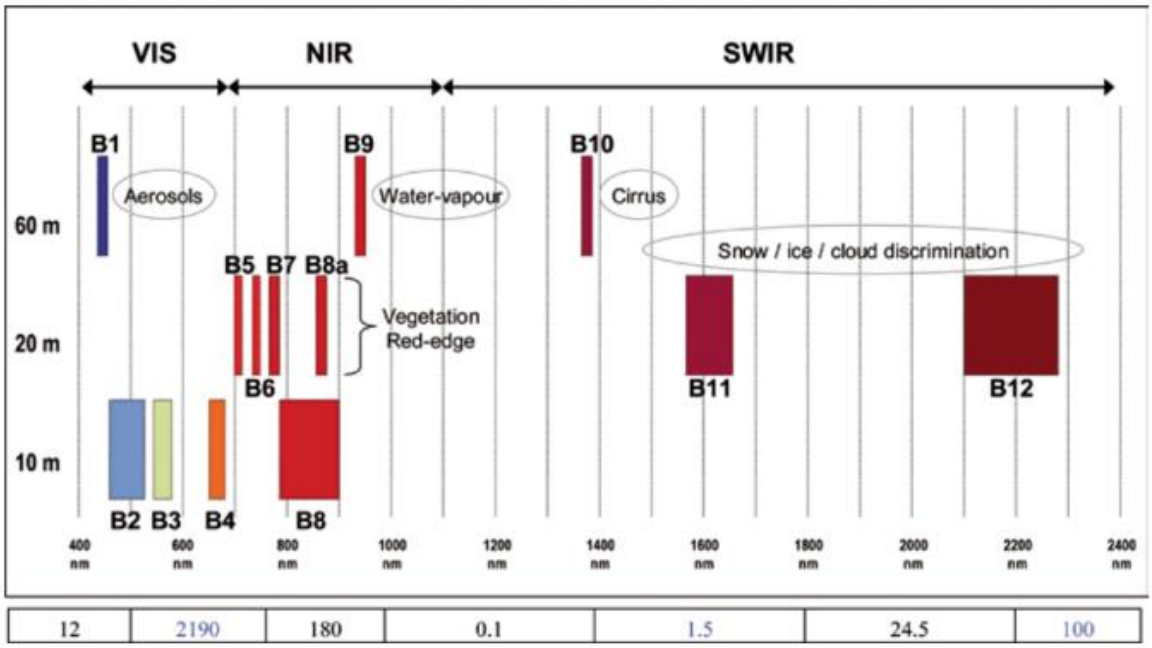


Figura 2.1. lista de bandas Sentinel 2A según numero de banda, rango del espectro electromagneico en nanómetros (nm) y sus resoluciones espaciales. Fuente: https://www.cursosteledeteccion.com/combinacion-de-bandas-en-imagenes-sentinel2/

Los productos se distribuyen en distintos niveles de procesamiento. El nivel L1C entrega reflectancia en el tope de la atmósfera, mientras que el nivel L2A (el empleado en este trabajo) incorpora la corrección atmosférica y entrega reflectancia de superficie, junto con una capa de clasificación de escena (SCL) que categoriza cada píxel (nube, sombra, vegetación, agua, entre otros) y que aquí se utiliza para el enmascaramiento de nubes. Trabajar directamente sobre L2A evita implementar una corrección atmosférica propia y mejora la comparabilidad radiométrica entre fechas y ubicaciones. Cada banda se distribuye como un archivo ráster (estructura de datos que representa un espacio dividido en una rejilla de celdas cuadradas o rectangulares llamadas píxeles) independiente, por lo que la composición en imágenes multibanda constituye el primer paso del preprocesamiento (véase la Sección 3.4). El Cuadro 2.1 resume las bandas empleadas y su rol.

Banda	Denominación	Long. de onda central (aprox.)	Resolución por pixel	Rol en este trabajo
B02	Azul	490 nm	10 m	Entrada del modelo (RGB)
B03	Verde	560 nm	10 m	Entrada del modelo (RGB) y cálculo del INBNV
B04	Rojo	665 nm	10 m	Entrada del modelo (RGB) y cálculo del INBNV
B08	Infrarrojo cercano (NIR)	842 nm	10 m	Exclusivamente generación de etiquetas (INBNV)
SCL	Capa de clasificación de escena	-	20 m	Enmascaramiento de nubes

Cuadro 2.1. *Bandas de Sentinel-2 L2A empleadas en este trabajo. Elaboración propia a partir de https://docs.sentinel-hub.com/api/latest/data/sentinel-2-l2a/*

En conjunto, la resolución de 10 metros de las bandas ópticas constituye la restricción central del problema, cuyas implicancias sobre el objeto de estudio se abordan a continuación y se retoman, como decisiones de diseño, en el Capítulo 3 (Secciones 3.7 y 3.9).

2.2. El silo-bolsa como objeto de estudio

El silo-bolsa es una estructura plástica oblonga, compuesta por polietileno de alta densidad, utilizada para el almacenamiento hermético y temporal de granos secos y forraje (Muzlera, 2024), siendo estos en su gran mayoría de color blanco (también se pueden encontrar variantes en verde y rosa pero en una proporción muy baja). Originado en Alemania en la década de 1960 para forraje, se popularizó en Argentina en los años noventa, y el desarrollo tecnológico del INTA lo transformó en un dispositivo apto para granos secos como soja, maíz y trigo (Muzlera, 2024; Expoagro, 2025). Permite almacenar la cosecha entre seis meses y dos años (Casini et al., 2009), habilitando estrategias comerciales o financieras en función de los precios para los productores agropecuarios. En particular, el silo-bolsa habilita la venta a contraestación: al tratarse de commodities cuyo precio fluctúa a lo largo del año, el productor puede retener el grano a bajo costo tras la cosecha y venderlo en los momentos de precios más favorables, desacoplando la decisión comercial del calendario agrícola (Muzlera, 2024). Esta doble condición (logística y financiera) explica su adopción masiva. Su relevancia económica (cerca del 40 % de la producción nacional se encuentra almacenada en silo-bolsa [Gobierno de Argentina, 2025a]) y la falta de información objetiva sobre su distribución justifican el interés por su monitoreo automatizado. Las iniciativas de monitoreo existentes, como los sistemas automáticos impulsados por el INTA, se orientan a la condición del grano dentro de cada bolsa (Gobierno de Argentina, 2025b); no abordan, en cambio, su distribución a escala territorial.



Figura 2.2. (a) Imagen de silo-bolsa fotografía a escala real. (b) imagen silo bolsa tomada con imágenes satelital de alta resolución Google Earth (c) La misma clase de objeto en una imagen Sentinel-2 (RGB, 10 m/píxel). Fuente: Elaboración propia

La Figura 2.2 ilustra el silo-bolsa en tres escalas de observación: a nivel del suelo (a), en una imagen satelital de alta resolución (b) y en una imagen Sentinel-2 a 10 metros por píxel (c), que es la que efectivamente procesa el modelo. El contraste entre (b) y (c) sintetiza la dificultad central del trabajo: a esa resolución el silo-bolsa se reduce a un rasgo lineal de apenas unos pocos píxeles, en el límite de lo resoluble por el sensor y muy por debajo del detalle disponible en (b).

2.3. Detección de objetos en imágenes satelitales con aprendizaje profundo

Las redes neuronales convolucionales (CNN) revolucionaron la visión por computadora y, con ella, el análisis automático de imágenes de teledetección (Ball et al., 2017; Zhang et al., 2016). En detección de objetos coexisten dos grandes familias: los detectores de una etapa, como YOLO y SSD, que privilegian la velocidad, y los de dos etapas, como la familia R-CNN, que privilegian la precisión de localización. En esta segunda familia, Fast R-CNN (Girshick, 2015) y, sobre todo, Faster R-CNN (Ren et al., 2015) introdujeron la red de propuestas de regiones (Region Proposal Network), que integra la generación de candidatos dentro de la propia red y la vuelve entrenable de extremo a extremo.

El desempeño de estos detectores depende fuertemente del extractor de características o backbone. ResNet (He et al., 2016) habilitó el entrenamiento de redes muy profundas mediante conexiones residuales, y las redes piramidales de características (Feature Pyramid Network, FPN; Lin et al., 2017) mejoraron la detección de objetos a múltiples escalas combinando información de distintos niveles de resolución. En años recientes la investigación avanzó hacia detectores basados en transformers (Carion et al., 2020) y sucesivas iteraciones de la familia YOLO; no obstante, la combinación Faster R-CNN con backbone ResNet50-FPN se mantiene como una línea de base robusta y ampliamente adoptada en aplicaciones de teledetección, y es la arquitectura seleccionada en este trabajo (los criterios de esta elección se desarrollan en el Capítulo 3).

2.3.1. Detección de objetos pequeños

La detección de objetos pequeños es un problema reconocidamente difícil: a baja resolución, los objetos aportan pocos píxeles y poco contexto, lo que degrada tanto la localización como la clasificación. En teledetección se han abordado con éxito casos de objetos reducidos o específicos (embarcaciones, aeronaves, pivotes de riego) mediante CNN (Ball et al., 2017). En el caso de los silo-bolsas, su geometría marcadamente alargada exige adaptar las cajas de anclaje del detector a relaciones de aspecto extremas, aspecto que se desarrolla en la metodología.

2.3.2. Transferencia de aprendizaje y preentrenamiento

Las CNN aprenden representaciones jerárquicas: las primeras capas detectan patrones elementales (bordes, texturas, contrastes) y las capas sucesivas los combinan en estructuras de complejidad creciente (Zeiler y Fergus, 2014; LeCun et al., 2015). Dado que esas representaciones de bajo nivel son en gran medida genéricas, resulta posible transferirlas entre tareas (Yosinski et al., 2014). La transferencia de aprendizaje (transfer learning) consiste en inicializar la red con pesos aprendidos sobre un conjunto masivo de datos y ajustarla luego (fine-tuning) sobre el problema específico, con una fracción de los datos y del cómputo que exigiría un entrenamiento desde cero. El conjunto de preentrenamiento de referencia es ImageNet, en su subconjunto ILSVRC (ImageNet Large Scale Visual Recognition Challenge), de aproximadamente 1,2 millones de imágenes naturales RGB etiquetadas en mil categorías (Russakovsky et al., 2015). Análogamente, para la tarea de detección de objetos el conjunto de referencia es COCO (Common Objects in Context; Lin et al., 2014), con cientos de miles de imágenes

cotidianas y 80 categorías anotadas mediante cajas delimitadoras, empleado habitualmente para preentrenar detectores completos.

En teledetección, la transferencia desde ImageNet demostró ser eficaz pese a las diferencias de dominio entre fotografías naturales e imágenes satelitales (Hu et al., 2015); en particular, sobre imágenes Sentinel-2 se reportó que las redes preentrenadas con fine tunning alcanzan su mejor desempeño con la combinación de bandas RGB (Helber et al., 2019). Este salto de dominio (domain gap) es real y conocido: las fotografías de ImageNet son tomas a nivel del suelo, con orientación fija impuesta por la gravedad y objetos que ocupan gran parte del encuadre, mientras que la teledetección presenta vista cenital, objetos en orientaciones arbitrarias y de tamaño reducido respecto de la escena. La transferencia resulta eficaz, aun así, porque lo que se reutiliza con mayor provecho son las representaciones de bajo y medio nivel, en gran medida independientes del punto de vista, mientras que el ajuste fino adapta las capas profundas al dominio específico.

En este trabajo, además, las restantes dimensiones de ese salto se atienden mediante decisiones de diseño: la entrada RGB alinea la representación con la de los pesos preentrenados, las cajas de anclaje con relaciones de aspecto extremas en ambas orientaciones contemplan la disposición arbitraria de los objetos (a lo que las versiones V2 a V4 suman aumento de datos por volteo), y la FPN con anclas de escalas reducidas atiende su tamaño pequeño (véase el Capítulo 3). La transferencia de aprendizaje resulta central en el presente trabajo, donde el tamaño reducido del conjunto curado y la restricción de cómputo en CPU vuelven determinante el aprovechamiento de pesos preentrenados (véase la Sección 3.7).

2.4. Trabajos previos sobre detección de silo-bolsas

El antecedente más directo es el trabajo de Barbiani y Bustamante (2022), quienes desarrollaron un detector de pivotes de riego y silo-bolsas basado en YOLOv5, utilizando imágenes de fuentes mixtas (Google Earth y Sentinel) y un dataset construido mediante etiquetado manual y aumento de datos, con un prototipo de API (Interfaz de Programación de Aplicaciones, o Application Programming Interface en inglés). Si bien demostraron la viabilidad del enfoque, su trabajo no se centró exclusivamente en Sentinel-2 ni analizó de manera sistemática la calidad de las etiquetas. El presente trabajo se diferencia al concentrarse en Sentinel-2 L2A, emplear un detector de dos etapas (Faster R-CNN), trabajar sobre temporalidad de imágenes, en una superficie o área de estudio de 9.490 km² y, principalmente, al situar en el centro del análisis la comparación entre verdad de terreno limpia vs. ruidosa.

En problemas afines de teledetección, Fernández Marcos (2023) comparó variantes de YOLO para detección de objetos (piscinas, paneles solares) en imágenes satelitales; Tapia Catacora (2023) aplicó U-Net a la segmentación de deforestación en Landsat-8 (Constelacion de satélites de resolución de 30m) con alta precisión; e Iglovikov et al. (2017) adaptaron U-Net a entradas multiespectrales en una

competencia de Kaggle. Estos trabajos establecen metodologías y arquitecturas de referencia, aunque sobre objetos, resoluciones y sensores distintos a los de esta tesis.

2.5. Calidad de las etiquetas, ruido y aprendizaje centrado en los datos

La literatura clásica de aprendizaje automático asume conjuntos de entrenamiento correctamente etiquetados; en la práctica, las etiquetas suelen contener ruido, especialmente cuando se generan de manera automática o mediante supervisión débil (Frénay y Verleysen, 2014). El ruido de etiqueta puede degradar la generalización, sesgar las métricas y, en casos extremos, inducir el memorizado de errores por parte de la red.

Existe, sin embargo, una tensión interesante en los hallazgos del campo. Por un lado, se ha mostrado que las redes profundas pueden ser sorprendentemente robustas a grandes volúmenes de ruido de etiqueta cuando el conjunto es masivo y el ruido es no sistemático (Rolnick et al., 2017). Por otro, trabajos sobre errores de etiqueta en benchmarks de referencia (conjuntos de datos estándar utilizados para comparar modelos entre estudios) evidencian que incluso conjuntos consolidados contienen errores que afectan la evaluación y la comparación de modelos (Northcutt et al., 2021). Esta tensión (cantidad con ruido frente a calidad curada) es la que esta tesis examina empíricamente sobre un caso real.

El paradigma del aprendizaje centrado en los datos (data-centric) propone, frente a la mejora incremental de arquitecturas, concentrar el esfuerzo en la calidad, la consistencia y la representatividad del conjunto de entrenamiento. El método de etiquetado semiautomático y curación manual propuesto en este trabajo, así como el diseño experimental V2-V5, se inscriben en ese paradigma: en lugar de variar el modelo, se varía sistemáticamente la calidad del dato para medir su efecto.

2.6. Índices espectrales para la generación de etiquetas

Los índices espectrales combinan bandas para realzar coberturas de interés. El más difundido es el NDVI (Rouse et al., 1974), que explota el contraste entre el rojo y el infrarrojo cercano para caracterizar la vegetación; con la misma estructura algebraica de diferencia normalizada, el NDWI (McFeeters, 1996) contrapone el verde y el NIR para delinear cuerpos de agua. Esta forma, $(A - B)/(A + B)$, otorga a la familia propiedades convenientes: valores acotados, normalizados y robustez frente a variaciones de iluminación, por tratarse de cocientes de bandas. Sobre superficies plásticas agrícolas existen antecedentes de índices diseñados ad hoc: Yang et al. (2017) propusieron un índice para el mapeo de invernaderos plásticos en resolución media, y Zhang et al. (2022) desarrollaron un índice específico para su mapeo robusto a gran escala a partir de imágenes Sentinel-2. No se registran, en cambio, índices específicos para silo-bolsas. En este trabajo se propone el INBNV (Índice Normalizado de Blancos No Vegetados), un índice de elaboración propia perteneciente a la familia de diferencias normalizadas, diseñado para realzar superficies brillantes y poco vegetadas (como el polietileno blanco de los silo-bolsas) frente al resto de la escena agrícola. Su formulación se obtuvo de manera empírica, mediante pruebas iterativas sobre imágenes del área de estudio, y hasta donde alcanzó la revisión bibliográfica

realizada no se identificó una formulación equivalente en la literatura. A diferencia de los antecedentes citados, el INBNV no se emplea como clasificador final, sino como generador de candidatos dentro de un flujo de etiquetado semiautomático; su formulación y justificación se desarrollan en el Capítulo 3. La utilización del NIR en este trabajo se concentra, por lo tanto, en la generación de las etiquetas (no en la entrada del modelo, que es RGB), lo que constituye una decisión de diseño deliberada.

2.7. Síntesis y posicionamiento

En síntesis, si bien existen métodos generales de detección y segmentación en teledetección y un antecedente puntual sobre silo-bolsas, persiste un vacío en torno a dos cuestiones: la construcción eficiente de verdad de terreno para objetos pequeños en Sentinel-2 y la cuantificación rigurosa del efecto de la calidad de las etiquetas sobre el desempeño. Esta tesis se posiciona en ese nicho, aportando tanto un método de etiquetado semiautomático reproducible como evidencia empírica sobre la eficiencia de datos. Los detalles metodológicos se desarrollan a continuación en el Capítulo 3 y se continua con los resultados en el Capítulo 4.

Capítulo 3. Solución e implementación

Este capítulo describe la solución desarrollada, desde la adquisición de las imágenes hasta el protocolo de evaluación. El sistema se estructura como un pipeline modular de jupyter notebooks numerados, lo que facilita su ejecución por etapas, su reanudación ante interrupciones y su reproducibilidad (el acceso al repositorio de código y la descripción de cada notebook se detalla en el Apéndice A). Se presentan sucesivamente el área de estudio, el flujo de procesamiento de imágenes, el método de generación semiautomática de la verdad de terreno, el diseño experimental de las versiones del modelo, la arquitectura y el entrenamiento, y finalmente el protocolo de evaluación.

3.1. Tipo de estudio y entorno

Se trata de una investigación aplicada de tipo cuantitativo, que emplea técnicas de aprendizaje profundo para detección de objetos con el fin de resolver un problema práctico del ámbito agrícola. El desarrollo se realizó íntegramente por medios computacionales, con recursos personales y sin disponibilidad de GPU. Esta restricción condicionó decisiones de diseño relevantes, en particular el tamaño del modelo, el tamaño de lote y la incorporación de una lógica de reanudación desde puntos de control (checkpoints) para tolerar interrupciones durante entrenamientos prolongados. El stack tecnológico principal incluye Python, PyTorch (Paszke et al., 2019) y torchvision para el modelado, rasterio y GDAL para el manejo de imágenes, GeoPandas y QGIS (un sistema de información geográfica o SIG/GIS de escritorio, libre y de código abierto) para los datos vectoriales y la curación manual. Las versiones exactas de cada componente se detallan en el Apéndice B.

3.2. Área de estudio

El área de estudio es el departamento de Marcos Juárez, en el sudeste de la provincia de Córdoba, dentro de la denominada zona núcleo agrícola argentina. Se trata de una región de alta productividad de granos gruesos (soja y maíz), en la que el almacenamiento en silo-bolsas durante el período invernal de barbecho es una práctica extendida y común. La Figura 3.1 muestra su ubicación dentro de la provincial.

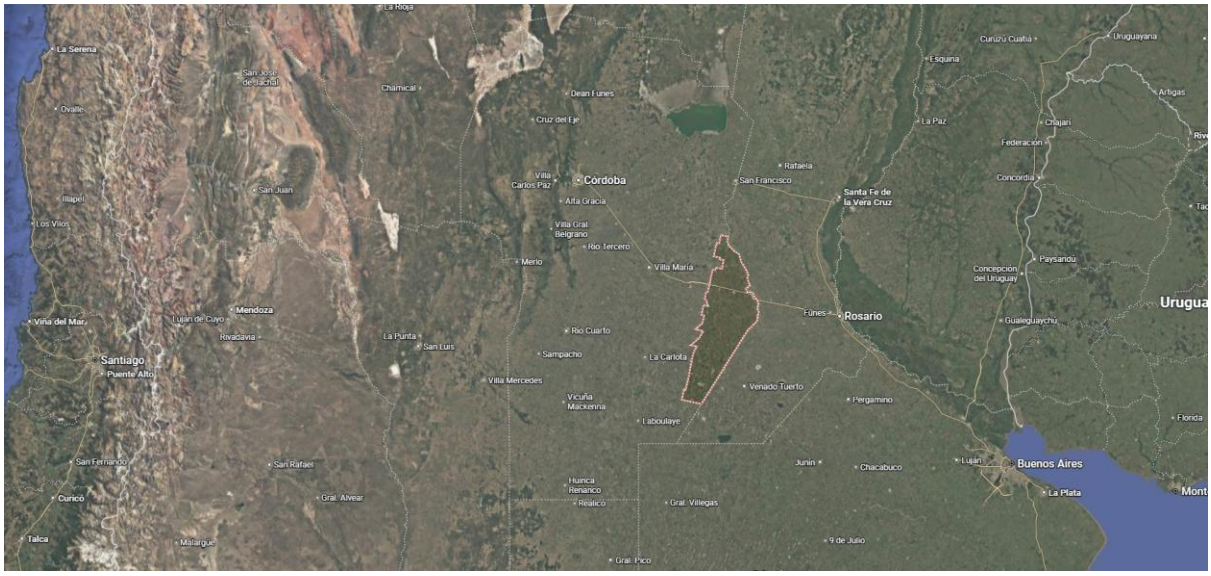


Figura 3.1. Área de estudio: departamento de Marcos Juárez, provincia de Córdoba. Superficie aproximada 9.490 km². Fuente: Google Maps

El período de estudio comprende los meses de junio, julio y agosto de los años 2020 a 2025. Esta ventana concentra la presencia de silo-bolsas en el campo (el grano ya embolsado tras la cosecha estival) sobre un paisaje de barbecho invernal con suelo mayormente desnudo (en condiciones menores en paisajes de cultivo de fina como trigo), condición que favorece su contraste y detectabilidad en las imágenes. La Figura 3.2 sitúa esta ventana en el ciclo productivo de los cultivos de la región.

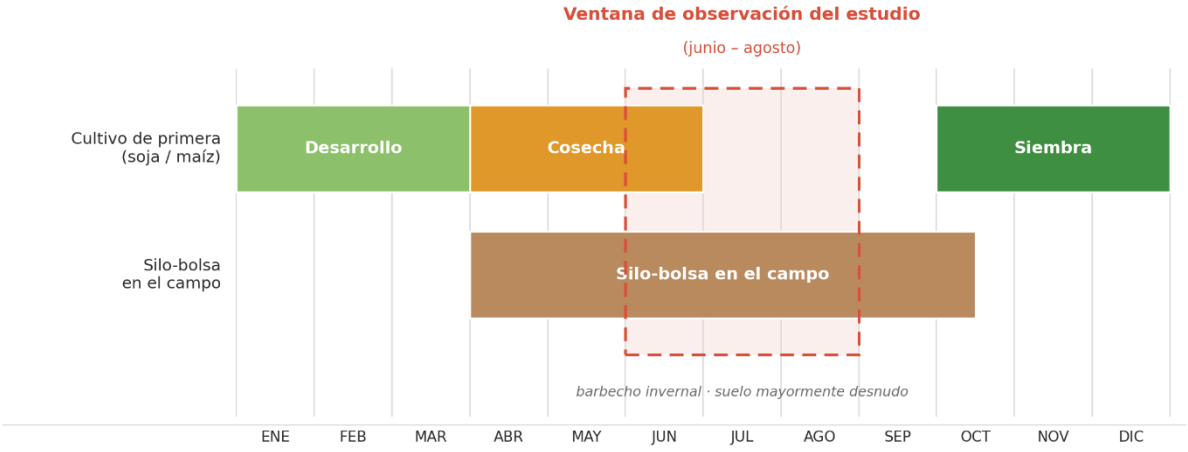


Figura 3.2. Ciclo productivo de los cultivos estivales principales (soja y maíz de primera) en la zona núcleo y ventana de observación del estudio. Tras la cosecha (aprox. Abril-junio), el grano se almacena en silo-bolsas que permanecen en el campo durante el barbecho invernal (extendiéndose a veces hasta 1-2 años en el campo). La ventana de junio a agosto (resaltada) concentra la presencia de silo-bolsas sobre (mayoritariamente) suelo desnudo, condición que favorece su detectabilidad en las imágenes Sentinel-2. Las fechas son aproximadas y varían según campaña, región climatica y tipo de cultivo. Fuente: elaboración propia sobre [Bolsa de Cereales / INTA / Ministerio].

3.3. Adquisición de imágenes

Se utilizaron imágenes Sentinel-2 de nivel de procesamiento L2A (reflectancia de superficie), descargadas desde el repositorio público de datos abiertos de AWS (AWS Open Data Registry, s.f.). La

descarga se restringió a las teselas MGRS que cubren la mayor parte del área de estudio (identificadores 20HNH, 20HNJ y 20HNK; Figura 3.3), para el período de tiempo indicado previamente con un filtro de porcentaje de cobertura de nubes menor al 20%. La tesela 20HPJ, si bien cubre marginalmente el extremo oriental del departamento, quedó deliberadamente excluida del análisis; esta decisión se fundamenta en que abarca una fracción ínfima de territorio y su inclusión hubiera supuesto un incremento desproporcionado en el volumen de datos a procesar y almacenar, sumando complejidad computacional sin un beneficio significativo. Por último, la descarga se limitó a los archivos estrictamente necesarios para el procesamiento: las bandas B02 (azul), B03 (verde), B04 (rojo) y B08 (infrarrojo cercano) a 10 m de resolución, y la capa de clasificación de escena (Scene Classification Layer, SCL) a 20 m, empleada para el enmascaramiento de nubes.

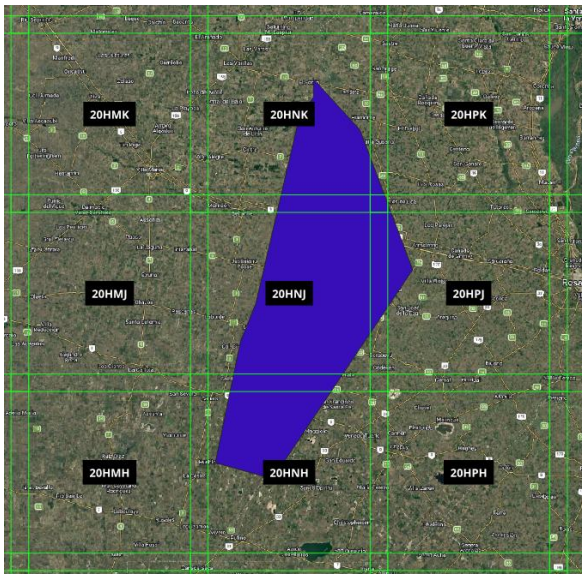


Figura 3.3. Teselas MGRS de Sentinel-2 (Líneas verdes) que cubren el área de estudio (Polígono azul). El departamento de Marcos Juárez queda comprendido por las teselas 20HNH, 20HNJ Y 20HNK (20HPJ excluida) de la grilla MGRS; cada tesela es una unidad fija de la grilla en la que Sentinel-2 distribuye sus productos. La descarga y el procesamiento se restringieron a estas tres teselas. Fuente: elaboración propia sobre grilla MGRS y límite departamental [Elaboración propia a partir de NASA: https://hls.gsfc.nasa.gov/products-description/tiling-system/].

3.4. Preprocesamiento de imágenes

El preprocesamiento se organiza en una secuencia de etapas, sintetizada en la Figura 3.4, cada una implementada como un notebook de Jupyter independiente, que se ejecuta de manera automática y secuencial sobre cada imagen cruda descargada:

1. **Composición de bandas y enmascaramiento de nubes.** Para cada escena se apilan las bandas en el orden rojo-verde-azul-NIR (B04, B03, B02, B08) y se construye una máscara de píxeles válidos a partir de la SCL, conservando las clases correspondientes a vegetación, suelo desnudo, agua y nieve/hielo, y descartando nubes y sombras. De esta forma la resultante es una imagen compuesta sin presencia de nubes

2. **Mosaico por escena.** Los fragmentos de imagenes correspondientes a una misma fecha se combinan en un único mosaico mediante operaciones de combinado o merge, agrupando por identificador de escena (año, mes, día y secuencia). De esta manera se unifican escenas (20HNH/20HNJ/20HNK) en una única imagen por día.
3. **Recorte a la zona agrícola.** Cada mosaico se recorta con una capa vectorial del departamento que delimita las zonas rurales, obtenida del portal de datos abiertos de la Infraestructura de Datos Espaciales de la Provincia de Córdoba (IDECOR, 2021), de modo de descartar superficies urbanas, cuerpos de agua y áreas no productivas (caminos, ciudades, cascos, etc.) y acotar el área de estudio a las zonas rurales, reduciendo así el espacio de búsqueda y las fuentes de confusión.
4. **Teselado en parches.** Los mosaicos recortados se dividen en parches de 1024 × 1024 píxeles con un solapamiento del 20 %. Se descartan los parches con escasa información útil, según dos condiciones: que menos del 20 % de sus píxeles sean válidos, es decir, que la mayor parte del parche corresponda a sectores enmascarados por nubes o excluidos por el recorte a la zona rural; o que más del 80 % de sus píxeles válidos sean muy oscuros (valor digital inferior a 50 en todas las bandas), situación característica de los bordes del mosaico y de los sectores sin datos. Se preserva la georreferenciación de cada parche, lo que permite reconstruir la posición geográfica de las detecciones.

Los productos L2A presentan, además, una particularidad de escala radiométrica. A partir del Processing Baseline 04.00, operativo desde el 25 de enero de 2022, la Agencia Espacial Europea desplazó el rango dinámico de los productos mediante una constante de −1000 cuentas o numeros digitales (BOA_ADD_OFFSET), con el fin de permitir la codificación de reflectancias negativas sobre superficies muy oscuras (European Space Agency [ESA], 2022; ESA, s.f.). Desde entonces, la reflectancia de superficie se obtiene como (DN + BOA_ADD_OFFSET) / 10.000. El repositorio empleado distribuye los valores digitales sin aplicar esa corrección, y el pipeline aquí descripto tampoco la aplica: convierte los valores digitales dividiendo por 10.000 en todas las fechas. En consecuencia, las imágenes posteriores a enero de 2022 quedan desplazadas aproximadamente 0,1 hacia arriba, en la escala [0, 1], respecto de las anteriores. Dado que las cuatro versiones del modelo comparten este mismo preprocesamiento, la condición es constante en todo el diseño experimental y no introduce diferencias entre versiones. El análisis de sensibilidad del Apéndice D muestra, además, que la corrección de la escala mejora el desempeño sin alterar el orden entre versiones, de modo que las métricas reportadas resultan conservadoras. Las implicancias de esta decisión se retoman en la Sección 4.10 y su corrección se plantea como trabajo futuro (Sección 5.2).

La nomenclatura o UID de cada parche codifica su procedencia (año, mes, día, secuencia y posición de fila y columna en el mosaico), lo que garantiza su trazabilidad a lo largo de todo el pipeline. La Figura 3.5 ilustra cada etapa sobre una fecha real del período de estudio.

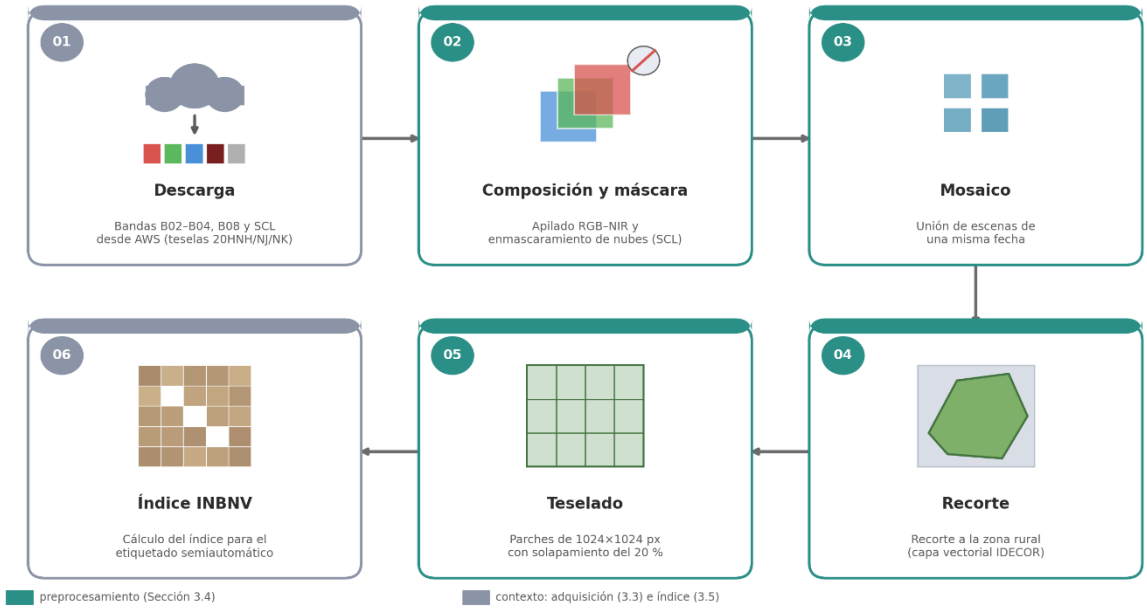


Figura 3.4. Flujo de preprocesamiento de imágenes Sentinel-2. Fuente: Elaboracion propia

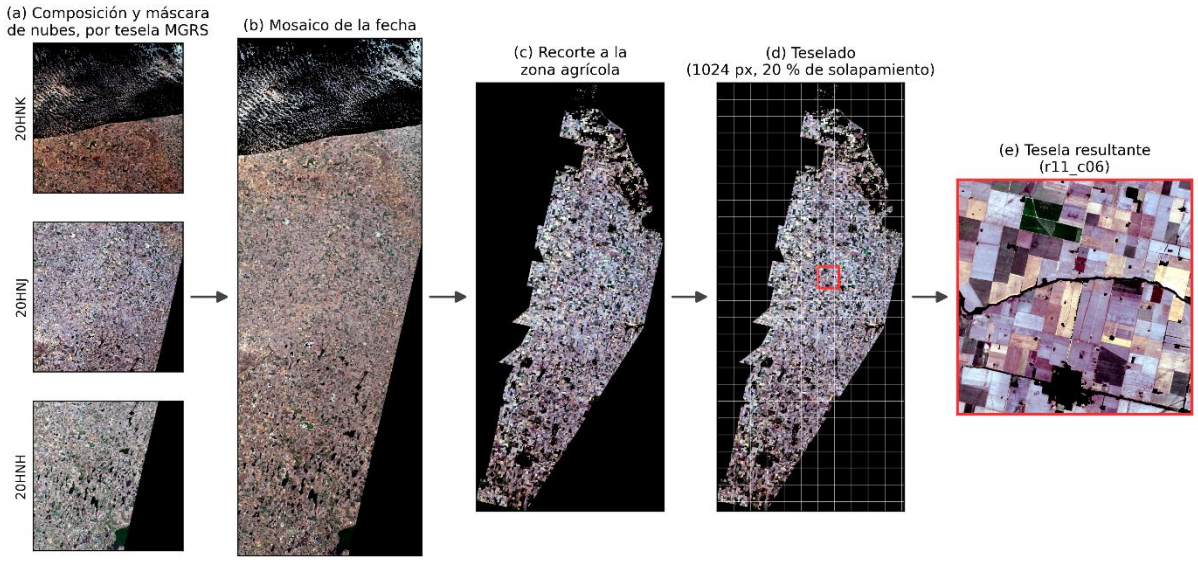


Figura 3.5. Ejemplo real de las etapas del preprocesamiento para la fecha del 12/08/2020. (a) Composición RGB con enmascaramiento de nubes para cada una de las tres teselas MGRS. (b) Mosaico de la fecha. (c) Recorte a la zona agrícola del departamento. (d) Grilla de teselado, con la tesela r11_c06 recuadrada en rojo. (e) Tesela resultante, a resolución completa. En negro, píxeles sin datos: fuera de la franja de adquisición, enmascarados o excluidos por el recorte. Las nubes finas visibles en el extremo norte no fueron detectadas por la capa SCL, pero quedan fuera del área de estudio tras el recorte. Las imágenes (a) a (d) se muestran a resolución reducida. Fuente: elaboración propia.

3.5. Generación semiautomática de la verdad de terreno

La construcción del conjunto de verdad de terreno constituye una de las contribuciones centrales del trabajo. En lugar de etiquetar manualmente desde cero, se diseñó un procedimiento en dos fases: una generación automática de candidatos mediante un índice espectral INBNV nombrado previamente en

la sección 2.6, seguida de una curación manual para la generación del set de entrenamiento del modelo V5 y además para la posterior generación de un set de test de todos los modelos.

3.5.1. Índice INBNV y obtención de polígonos candidatos

El diseño de este índice responde a la necesidad algorítmica de aislar la firma espectral de los polímeros plásticos blancos frente a las coberturas predominantes en entornos agrícolas, como el suelo desnudo y el tejido vegetal.

La formulación matemática explota el alto nivel de reflectancia característico del polietileno de alta densidad en las longitudes de onda del espectro visible (bandas verde y roja), en contraste con su moderada reflectancia en el espectro infrarrojo cercano (NIR). La ecuación empleada es la siguiente (calculada sobre cada parche de imagen):

$$INBNV = ((Verde + Rojo) - NIR) / ((Verde + Rojo) + NIR)$$

La formulación responde a la lógica espectral de las coberturas presentes en la escena. La vegetación fotosintéticamente activa absorbe en el rojo y refleja intensamente en el NIR, por lo que el numerador resulta fuertemente negativo. El suelo desnudo y el rastrojo presentan una reflectancia creciente del visible hacia el NIR, lo que arroja valores levemente negativos o próximos a cero. El polietileno blanco, en cambio, exhibe una reflectancia alta y aproximadamente plana en el espectro visible junto con una respuesta comparativamente moderada en el NIR, lo que produce los valores más altos del índice. La suma de las bandas verde y roja en lugar de una banda única refuerza la respuesta de las superficies blancas (brillantes en ambas) y penaliza la vegetación (oscura en el rojo). La estructura de diferencia normalizada, común al NDVI y al NDWI, aporta además valores acotados y robustez frente a diferencias de iluminación entre escenas y fechas.

A partir del índice se genera una máscara binaria por umbralización: se conservan los píxeles cuyo valor supera el percentil 99,8 de la distribución de píxeles válidos de cada tesela, es decir, su 0,2 % más brillante. La máscara se depura eliminando los objetos de tres píxeles o menos (para eliminar objetos extremadamente pequeños) y aplicando una dilatación o buffer de un píxel, y finalmente se vectoriza en polígonos. El resultado es una capa de polígonos candidatos a silo-bolsa para cada parche de imagen, en formato shapefile. La Figura 3.6 ilustra cada paso del procedimiento: el cálculo del índice, la máscara resultante del umbralado y los polígonos candidatos finales.

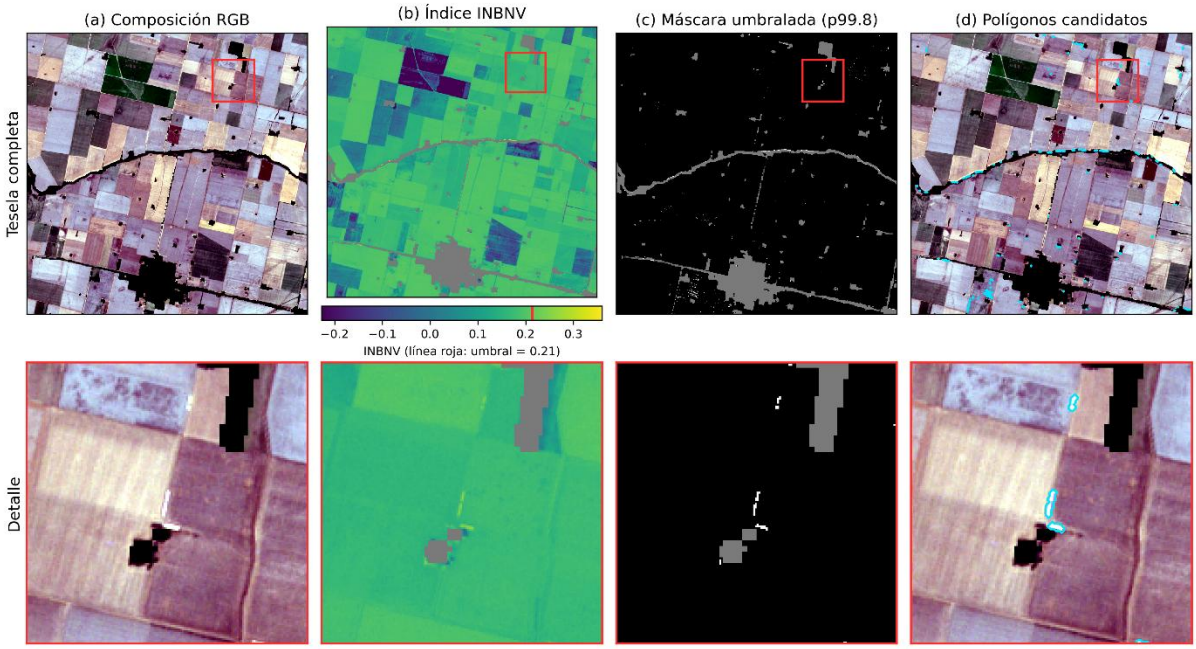


Figura 3.6. Generación de candidatos mediante el índice INBNV sobre una tesela del conjunto de prueba (2020_8_12_1_tile_r11_c06). (a) Composición RGB. (b) Valores del índice, con el umbral de la tesela (percentil 99,8, igual a 0,21) señalado en rojo sobre la escala. (c) Máscara binaria resultante del umbralado, que conserva el 0,2 % de píxeles con mayor valor. (d) Polígonos candidatos (en cian), tras eliminar los objetos de tres píxeles o menos y aplicar un buffer de un píxel. La fila inferior amplía el sector recuadrado en rojo. En gris, píxeles sin datos. Fuente: elaboración propia.

La elección del umbral merece justificación. El percentil calculado por parche constituye en la práctica un umbral adaptativo: cada tesela selecciona su propio 0,2 % más brillante, sin requerir calibración ni entrenamiento. Existen métodos alternativos de umbralado automático global, como el de Otsu (1979) o el método del triángulo; sin embargo, su diseño supone la separación de dos poblaciones con presencia sustancial en el histograma, mientras que en este problema la clase objetivo constituye una minoría extrema (los silo-bolsas ocupan una fracción ínfima de cada escena respecto a la totalidad de la imagen), por lo que un umbral de separación global tendería a ubicarse entre las coberturas dominantes (suelo y vegetación) en lugar de aislar la cola brillante de interés. El carácter adaptativo resultó además necesario en la práctica: sobre las 25.749 teselas procesadas, el umbral resultante varió entre 0,03 y 0,59 (mediana: 0,21; el 90 % central de los valores, entre 0,10 y 0,28), lo que evidencia que un valor fijo único hubiera sido inadecuado para la mayoría de las escenas y que el cálculo por parche absorbe las diferencias radiométricas entre fechas y escenas.

El índice presenta limitaciones conocidas, coherentes con su lógica: en superficies muy brillantes el contraste visible-NIR tiende a aplanarse, por lo que rastrojos secos muy claros, suelos desnudos de alta reflectancia, caminos, bordes de lotes, techos y bordes salinos pueden alcanzar valores comparables a los del plástico. Este comportamiento explica la elevada proporción de falsos positivos del índice. Contrastados con la verdad de terreno final de las 270 teselas curadas, y considerando correcto todo

candidato que se superponga, aun parcialmente, con alguna silo-bolsa, de los 12.463 polígonos candidatos generados, 7.529 (el 60,4 %) no recaen sobre ninguna silo-bolsa. A la inversa, 1.430 de las 6.410 silo-bolsas de la verdad de terreno (el 22,3 %) no tienen ningún candidato asociado. Ambas cifras son aceptables por diseño: el INBNV no se emplea como clasificador, sino como generador de candidatos, y se aceptan tanto las falsas alarmas, que la curación manual elimina, como las omisiones, que el barrido sistemático de cada tesela recupera (Sección 3.5.2). Lejos de ser un defecto, esta característica define la tarea de curación: el índice aporta una capa base que concentra la atención del analista en las regiones de interés, transformando un problema de etiquetado desde cero en uno de verificación y corrección.

3.5.2. Curación manual en QGIS

La capa de candidatos generada por el INBNV constituye el punto de partida del proceso de etiquetado. La verdad de terreno definitiva se obtiene mediante curación manual experta, cuyo protocolo se describe en detalle a continuación para favorecer su reproducibilidad y su extrapolación a otras aplicaciones.

La selección de las teselas a curar no fue arbitraria. Sobre el universo de 25.749 teselas procesadas se aplicó un muestreo estratificado por año y mes de campaña (18 estratos, período 2020-2025), con una distancia mínima de dos teselas entre muestras seleccionadas para reducir la autocorrelación espacial, y semilla aleatoria fija para garantizar la trazabilidad del sorteo. Para cada tesela seleccionada se prepararon automáticamente tres insumos: la imagen RGB, la capa de polígonos candidatos derivada del índice INBNV (denominada *gt_*, que contiene inicialmente los candidatos del índice y, tras la curación, la verdad de terreno definitiva) y la capa de predicciones de la versión V3 del modelo (denominada *pred_*, con umbral de confianza 0,5). V3, entrenada con etiquetas ruidosas (Sección 3.6), era la versión disponible en ese momento del proyecto; su capa no interviene en la construcción de las etiquetas, sino que se consulta al final de la revisión de cada tesela como verificación complementaria, según se describe más adelante. La cantidad de teselas candidatas surge del propio procedimiento de muestreo: se fijó un objetivo inicial de 1.000 teselas, distribuidas entre los estratos en proporción a la cantidad de teselas disponibles en cada uno, pero el filtro de distancia mínima limitó las teselas seleccionables por estrato, dado que las distintas fechas de un mismo mes comparten la misma grilla de posiciones; la selección final quedó así en 615 teselas. Este conjunto se administró mediante una planilla de seguimiento generada automáticamente que registra el estado de avance de cada tesela. La curación no se extendió a la totalidad del conjunto: una vez fijado el objetivo de un conjunto balanceado de doce teselas por estrato (Sección 3.6.1), 216 teselas curadas conformaron el dataset V5 y otras 54, también curadas, se reservaron para la evaluación (Sección 3.6.2), mientras que las 345 restantes quedaron sin curar.

El trabajo de curación se realizó en un sistema de información geográfica de escritorio; se empleó QGIS (QGIS Development Team, 2025), software libre y de código abierto, aunque el procedimiento es replicable en cualquier SIG equivalente. Para cada tesela se cargan la imagen y su capa de candidatos

asociada. La visualización utiliza composición color multibanda con realce de contraste por media ± desviaciones estándar calculadas sobre el lienzo actual, con un multiplicador (±8) definido empíricamente por inspección visual para maximizar el contraste de las silo-bolsas, reaplicando el realce sobre la extensión visible a medida que se recorre la tesela; esta práctica adapta el contraste a las condiciones locales de cada sector (suelos muy desnudos, nubosidad parcial) y mantiene resaltadas las superficies brillantes en escenarios radiométricos diversos. El remuestreo de visualización se fija en vecino más cercano, preservando los límites de píxel (relevante cuando el objeto de interés ocupa pocos píxeles). Se adoptan convenciones de color para reducir errores de interpretación: candidatos del índice en cian (#00E5FF), verdad de terreno en verde (#18FC25) y predicciones del modelo en azul (#0507FF).

La revisión de cada tesela sigue un barrido sistemático: un recorrido lateral de este a oeste que desciende fila a fila hasta cubrir la totalidad de la escena. Este protocolo garantiza que la inspección sea exhaustiva e independiente de la capa de candidatos, condición necesaria para que la curación no se limite a filtrar los polígonos propuestos, sino que además incorpore las silo-bolsas omitidas por el índice, situación frecuente en la práctica: más de una de cada cinco silo-bolsas de la verdad de terreno final no contaba con ningún candidato del índice (Sección 3.5.1; Figura 3.8a).

Sobre cada candidato se aplica una decisión basada en tres tipos de evidencia complementaria. La evidencia geométrica: se confirman las formas alargadas de proporciones compatibles con una silo-bolsa, y se descartan las manchas irregulares. La evidencia espectral: se confirman los blancos y claros nítidos, y se descartan los brillos difusos o que representan otro objeto. Y la evidencia contextual, que resulta decisiva en los casos ambiguos: las silo-bolsas se disponen típicamente asociadas a caminos rurales internos o a sectores de acopio próximos a los cascos de los establecimientos, con frecuencia agrupadas en baterías de bolsas paralelas; en cambio, se eliminan las anomalías brillantes aisladas en el interior de los lotes, los tramos de caminos rurales y bordes de lote de suelos claros, los bordes salinos irregulares, los bordes de ríos y cuerpos de agua, los techos de construcciones pequeñas que, pese al recorte previo del área de análisis a zonas rurales (Sección 3.4), ocasionalmente persisten en las escenas, y los brillos asociados a nubes o bruma residual y a los bordes de las zonas enmascaradas. Los polígonos válidos se conservan; su geometría se ajusta únicamente cuando el candidato delimita la bolsa de manera parcial (Figura 3.8b). Cuando dos o más silo-bolsas contiguas no resultan distinguibles a 10 m de resolución, se digitalizan como un único polígono, dado que el objetivo del etiquetado es delimitar la presencia del objeto y no contabilizar unidades individuales. En la práctica, las operaciones predominantes durante la curación fueron dos: la eliminación de falsos positivos y la digitalización manual de bolsas omitidas por el índice. La Figura 3.7 contrasta silo-bolsas verdaderas con los confusores más frecuentes.

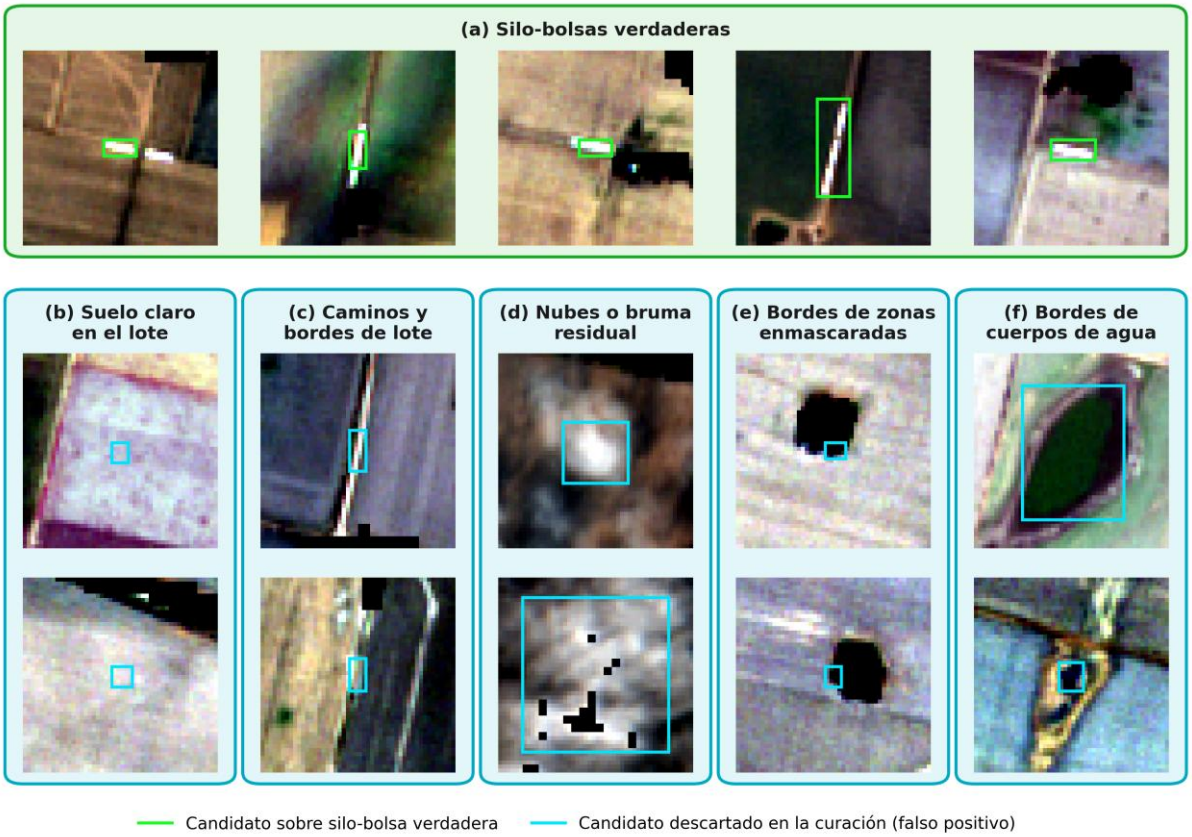


Figura 3.7. Candidatos generados por el índice INBNV sobre silo-bolsas verdaderas y sobre los confusores más frecuentes, a resolución Sentinel-2 (10 m). (a) Silo-bolsas verdaderas: rasgos alargados, blancos y nítidos. (b)-(f) Candidatos descartados durante la curación, dos ejemplos por categoría: (b) suelo claro en el interior del lote, (c) caminos rurales y bordes de lote, (d) nubes o bruma residual no removidas por el enmascaramiento, (e) bordes de zonas enmascaradas y (f) bordes de cuerpos de agua. Recortes de 48 × 48 píxeles tomados al azar de las teselas curadas, con realce de contraste por percentiles; en cada recorte se marca únicamente el candidato de ejemplo. Fuente: elaboración propia.

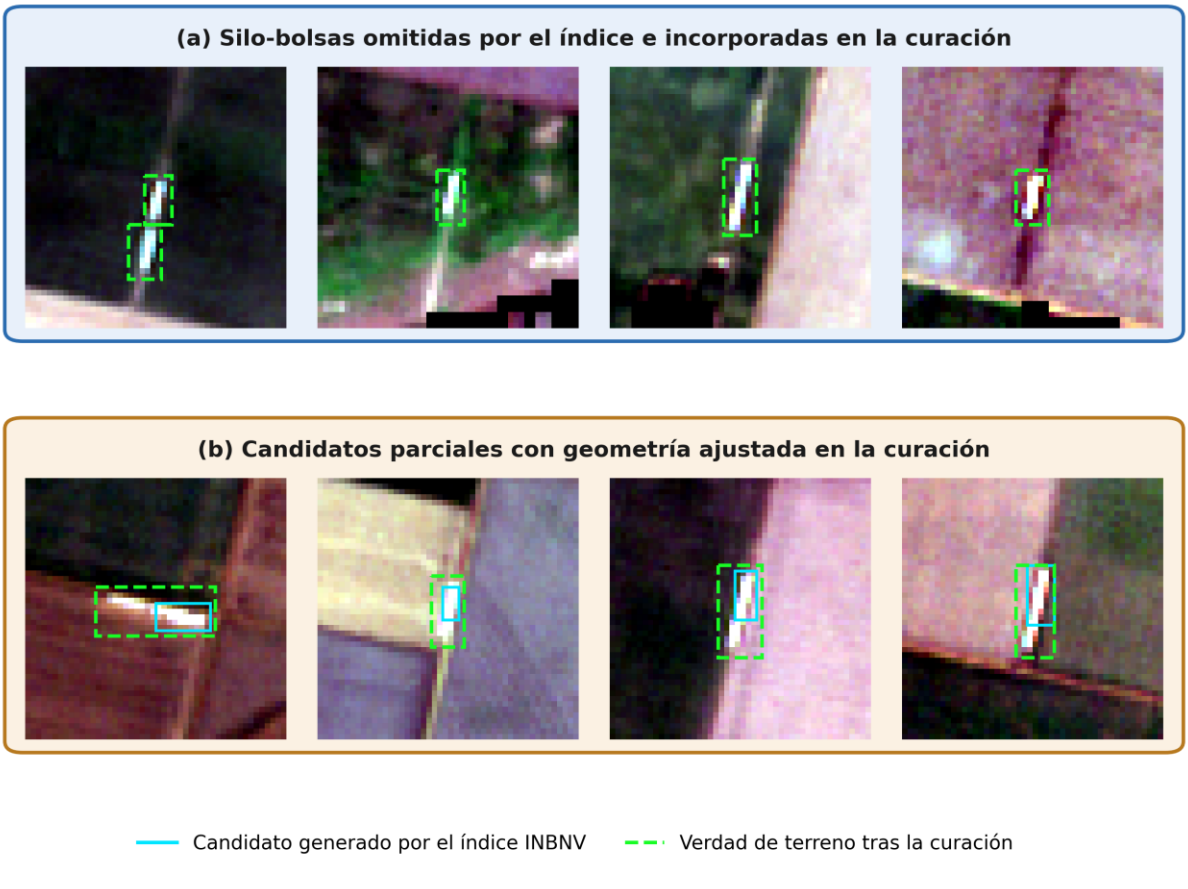


Figura 3.8. Correcciones introducidas por la curación manual sobre la capa de candidatos del índice INBNV. (a) Silo-bolsas sin ningún candidato asociado, omitidas por el índice y digitalizadas durante el barrido sistemático de la tesela. (b) Candidatos que delimitaban la silo-bolsa de manera parcial, cuya geometría se ajustó para cubrir el objeto completo. En cian, candidatos del índice; en verde discontinuo, verdad de terreno final. Recortes de 48 × 48 píxeles de las teselas curadas, con realce de contraste por percentiles. Fuente: elaboración propia.

Como verificación complementaria, al finalizar el barrido visual se consulta la capa de predicciones de V3 (*pred_*): las detecciones del modelo no coincidentes con la verdad de terreno en construcción se reinspeccionan, funcionando como una segunda fuente independiente para recuperar omisiones del anotador. La curación resulta así doblemente asistida (por el índice espectral y por el modelo), si bien la decisión final es siempre humana. La Figura 3.9 ilustra el resultado del proceso sobre un parche representativo.

El proceso completo demandó aproximadamente tres meses de trabajo, con una dedicación promedio de entre cinco y diez minutos por tesela, y fue realizado por un único anotador con formación agronómica y experiencia profesional previa en el manejo de silo-bolsas. El procedimiento tiene dos limitaciones. Primero, la verdad de terreno se estableció por fotointerpretación experta, sin verificación in situ mediante relevamiento a campo; las etiquetas representan, por tanto, la mejor interpretación posible de la evidencia satelital y contextual disponible. Segundo, la participación de un único anotador

impide cuantificar la concordancia inter-anotador; la sistematización del protocolo aquí descripto busca acotar la subjetividad de las decisiones individuales. Ambas limitaciones se retoman en la Sección 5.2.

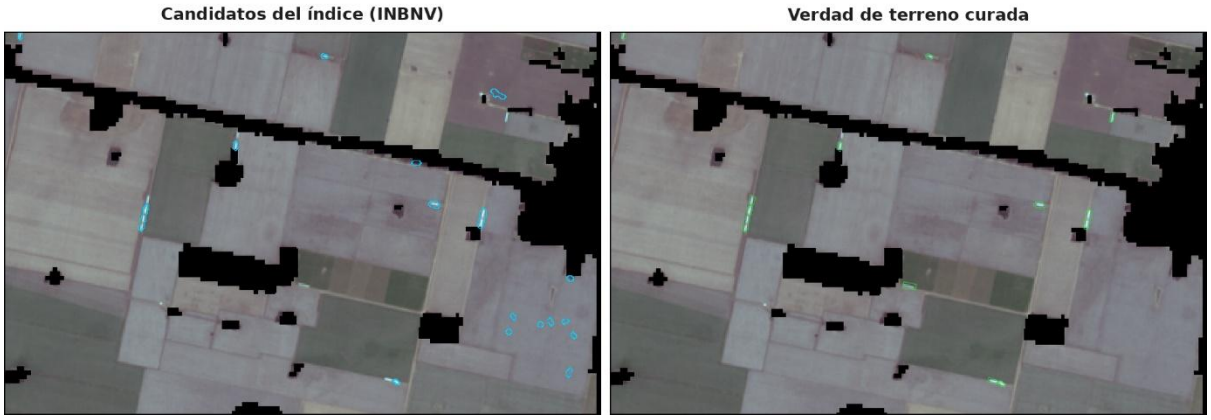


Figura 3.9. Generación semiautomática y curación de la verdad de terreno. Izquierda: capa de polígonos candidatos generada por el INBNV sobre un parche representativo (en azul), con falsos positivos sobre suelos claros y anomalías brillantes aisladas. Derecha: verdad de terreno resultante de la curación manual del mismo parche (en verde), tras la eliminación de falsos positivos y el ajuste de geometrías. Composición RGB Sentinel-2 con realce de contraste. Fuente: elaboración propia.

3.6. Diseño experimental: las versiones V2-V5

Para responder a la pregunta de investigación se definió una progresión de cuatro versiones del modelo que mantienen fija la arquitectura y varían el conjunto de entrenamiento de manera progresiva. El Cuadro 3.1 resume sus características.

Versión	Etiquetas (GT)	N.º imágenes (entrenamiento / validación)	Muestreo	Aumento de datos	Observaciones
V2	Ruidoso (índice)	500 (400 / 100)	Aleatorio simple	Volteo horizontal	Línea de base inicial.
V3	Ruidoso (índice)	600 (480 / 120)	Aleatorio simple	Volteos horizontal y vertical; brillo y contraste	Aumento de datos ampliado.
V4	Ruidoso (índice)	10.000 (8.500 / 1.500)	Estratificado	Volteos horizontal y vertical; brillo y contraste	Conjunto grande con etiquetas ruidosas.
V5	Curado (manual)	216 (183 / 33)	Estratificado balanceado	Ninguno	Conjunto pequeño y limpio; filtro de distancia entre teselas.

Cuadro 3.1. Diseño experimental de las versiones del modelo.

La progresión puede leerse en dos tramos. Las versiones V2 y V3 constituyen las primeras aproximaciones al problema y comparten el mismo origen de datos: conjuntos reducidos (500 y 600 imágenes), seleccionados por muestreo aleatorio simple sobre el universo de teselas procesadas y etiquetados automáticamente mediante el índice INBNV, sin curación. Se diferencian principalmente en el aumento de datos: V2 emplea únicamente volteo horizontal aleatorio, mientras que V3 incorpora volteo vertical y variaciones aleatorias de brillo y contraste, lo que permitió evaluar el efecto de una aumentación más amplia manteniendo el mismo tipo de etiquetas. V4 y V5, en cambio, conforman el

tramo central del diseño experimental: ambas adoptan muestreo estratificado por año y mes, y difieren en la calidad de las etiquetas y en el tamaño del conjunto.

La comparación clave es la que enfrenta a V4 con V5. V4 emplea un conjunto grande (del orden de 10.000 parches o teselas) con etiquetas ruidosas autogeneradas, mientras que V5 emplea un conjunto pequeño (216 parches o teselas) con etiquetas curadas manualmente. Ambas comparten arquitectura y muestreo estratificado; además de la calidad de las etiquetas, V5 recibió un régimen de entrenamiento más extenso (más épocas y reducción escalonada de la tasa de aprendizaje; véase la Sección 3.8) y, a diferencia de V4, no empleó aumento de datos. La incidencia de esa diferencia sobre la comparación, y las razones por las que el resultado se atribuye a la calidad de las etiquetas, se analizan en el Capítulo 4. Las versiones V2 y V3, anteriores, funcionan como puntos de referencia adicionales.

3.6.1. Muestreo estratificado y control de fuga espacial

Las versiones preliminares (V2 y V3) utilizaron muestreo aleatorio simple sobre el universo de teselas procesadas. Para evitar el sesgo temporal y garantizar la representatividad, en V4 y V5 se adoptó un muestreo estratificado por año y mes: los tres meses de observación (junio, julio y agosto) de cada uno de los seis años del período 2020-2025, lo que define 18 estratos, con semilla fija para asegurar la reproducibilidad. Ambas versiones difieren, sin embargo, en el control de la fuga espacial. En V4, las 10.000 teselas se distribuyeron entre los estratos en proporción a la cantidad disponible en cada uno, sin restricción de distancia entre las teselas seleccionadas. En V5, en cambio, se incorporó un filtro de distancia mínima de dos teselas en la grilla de teselado, a fin de evitar la fuga de información derivada del solapamiento entre parches vecinos, y el conjunto se balanceó con 12 imágenes por estrato ($18 \times 12 = 216$). El detalle del procedimiento se consigna en el Apéndice C.

3.6.2. Conjunto de reserva (holdout)

De las imágenes curadas manualmente se reservó un subconjunto (denominado Reserva) destinado exclusivamente a la evaluación, que no participó del entrenamiento de ninguna versión

La Reserva surgió como remanente del muestreo balanceado de V5 (Sección 3.6.1): fijado el objetivo de doce imágenes curadas por estrato, el excedente de imágenes ya curadas se destinó a evaluación en lugar de descartarse. Como la curación comenzó por el año 2020, ese excedente provino de dicho año, por lo que la Reserva, y el conjunto de prueba principal que de ella se deriva (Sección 3.9), quedó conformada íntegramente por imágenes de 2020.

Dado que esta evaluación principal se apoya en un único año, mide la generalización a teselas no vistas dentro de un año conocido, pero no la generalización a años distintos. Para atender ese punto, se construyó de manera independiente un segundo conjunto de prueba con imágenes del año 2026 posterior al período de estudio (2020-2025) y no visto por ningún modelo, curado manualmente y evaluado con el mismo protocolo. Esta validación temporal se presenta en el Capítulo 4.

3.7. Arquitectura del modelo

Se adoptó la arquitectura Faster R-CNN con backbone ResNet50-FPN (He et al., 2016; Lin et al., 2017; Ren et al., 2015), por su robustez y su buen desempeño en localización de objetos. La entrada del modelo es de tres canales (RGB); el infrarrojo cercano se reserva para la generación de las etiquetas, según se explicó en el capitulo 2.6. Dado el carácter pequeño y marcadamente alargado de los silo-bolsas, se personalizaron las cajas de anclaje (anchors) del detector. Las anclas son cajas de referencia, de tamaño y forma predefinidos, que la red de propuestas de regiones distribuye de manera regular sobre la imagen y luego ajusta para ceñirlas a los objetos; su conjunto define el repertorio de tamaños y formas que el detector está predispuesto a encontrar. Las gobiernan dos parámetros: la escala (el tamaño de la caja, en píxeles) y la relación de aspecto (la proporción entre sus lados, donde 1,0 es cuadrada y los valores alejados de 1 describen rectángulos cada vez más alargados).

Se ajustaron ambos a la geometría del objeto. En la escala se privilegiaron valores pequeños (16, 32, 64, 128 y 256 píxeles), con un nivel de 16 px por debajo de los tamaños que la arquitectura emplea por defecto, para atender el tamaño reducido de las bolsas a 10 m de resolución. En la relación de aspecto, a las proporciones habituales (0,5; 1,0; 2,0) se agregaron dos valores extremos, 0,2 y 5,0: ambos describen la misma forma marcadamente alargada (uno es el recíproco del otro) pero en orientaciones perpendiculares, de modo que una silo-bolsa se reconozca tanto si aparece dispuesta en sentido horizontal como vertical en la escena. Esta adaptación de las anclas al tamaño y la geometría de los silo-bolsas resulta central para su detectabilidad a 10 m.

La decisión de usar únicamente los tres canales visibles (RGB) y reservar el NIR para la generación de etiquetas no responde a una imposibilidad técnica: una red convolucional puede adaptarse para recibir cuatro o más bandas modificando su primera capa convolucional (Iglovikov et al., 2017). Sin embargo, la arquitectura adoptada utiliza un backbone ResNet50 preentrenado sobre ImageNet, un conjunto de imágenes naturales de tres canales, y el aprovechamiento de esos pesos preentrenados (transfer learning) resulta determinante cuando el conjunto de entrenamiento es reducido y el cómputo está restringido a CPU (Yosinski et al., 2014; Hu et al., 2015). Incorporar el NIR como cuarto canal habría implicado reinicializar parcialmente la primera capa y redefinir la normalización de entrada, generando un costo computacional y de ajuste que desprovecha la adaptabilidad directa de los pesos preentrenados. La evidencia empírica sobre Sentinel-2 respalda esta elección: Helber et al. (2019) reportan que, con redes preentrenadas, la combinación RGB supera a otras combinaciones de bandas, y que la banda NIR aislada no aporta ventajas frente a las bandas visibles. Finalmente, mantener la entrada fija (RGB) en las cuatro versiones evita introducir un cambio adicional en la representación de entrada al comparar las versiones. La evaluación del NIR como cuarto canal queda planteada como trabajo futuro.

3.8. Entrenamiento

El conjunto de entrenamiento de V5 se obtuvo a partir de la planilla de seguimiento de la curación (Sección 3.5.2), seleccionando las teselas que cumplían dos condiciones: tener la curación registrada como completa y haber sido asignadas a V5 por el muestreo balanceado (Sección 3.6.1). Este criterio excluye por construcción a las teselas de la Reserva, que nunca participan del entrenamiento. Las 216 imágenes curadas se particionaron de manera aleatoria, con semilla fija, en proporción 85/15: 183 de entrenamiento y 33 de validación. Ambos subconjuntos incluyen teselas sin silo-bolsas (13 en total, nueve de ellas en el de entrenamiento), incorporadas deliberadamente como fondo negativo para que el modelo aprenda también a no emitir detecciones en escenas donde no hay objetos de interés.

El entrenamiento siguió un esquema de transferencia de aprendizaje parcial (Sección 2.3.2). El backbone ResNet50 se inicializó con pesos preentrenados sobre ImageNet, mientras que los componentes específicos de detección como la FPN, la red de propuestas de regiones con las anclas personalizadas (Sección 3.7) y las cabezas de clasificación y regresión, se entrenaron desde cero, con la capa de predicción final redefinida para dos clases (fondo y silo-bolsa). No se emplearon pesos de detector preentrenados sobre COCO: la personalización de las anclas modifica la estructura de la red de propuestas y, además, restringir la transferencia al backbone permite atribuir el aporte del preentrenamiento a la extracción de características genéricas. Durante el ajuste fino, las capas iniciales del backbone (el tallo convolucional y el primer bloque residual) se mantuvieron congeladas en sus valores de ImageNet (comportamiento por defecto de la implementación), actualizándose únicamente los tres bloques residuales más profundos.

Los hiperparámetros de entrenamiento de V5 fueron los siguientes:

- Optimizador: SGD (momentum 0,9; weight decay 0,0005). Valores estándar del esquema de referencia para detectores de dos etapas; no se realizó una búsqueda específica sobre ellos.
- Tasa de aprendizaje: 0,005, con reducción escalonada (factor 0,1 cada 15 épocas). Valor conservador acorde al tamaño de lote reducido; la reducción escalonada afina la convergencia en la etapa final.
- Tamaño de lote: 2. Máximo admisible por la memoria disponible al entrenar en CPU; una restricción de hardware.
- Épocas: 40. Hasta la estabilización de la función de pérdida sobre el conjunto reducido.
- Recorte de norma de gradiente: 1,0. Acota la magnitud de las actualizaciones para estabilizar la optimización, útil con lotes pequeños.
- Semilla fija: 456. Reproducibilidad de la partición y del entrenamiento; misma semilla del muestreo estratificado (Sección 3.6.1).

El optimizador (SGD, momentum 0,9, weight decay 0,0005) y el tamaño de lote se mantuvieron en todas las versiones; el resto del régimen (tasa de aprendizaje, número de épocas, scheduler y recorte de gradiente) se ajustó a lo largo de la progresión hasta su forma definitiva en V5 (las implicancias de estas diferencias para la comparación entre versiones se discuten en el Capítulo 4).

El entrenamiento se ejecutó íntegramente en CPU. Cada época demandó del orden de 34 minutos (unas 22 horas para las 40 épocas), lo que vuelve costosa cualquier interrupción; por ello se guardó un checkpoint por época con el estado necesario para reanudar (época, pesos del modelo y estado del optimizador), lo que permitió retomar el entrenamiento tras un corte de energía sin pérdida de progreso. El mecanismo resultó especialmente necesario en el entrenamiento del conjunto grande (V4), de épocas mucho más extensas (del orden de treinta horas cada una).

3.9. Protocolo de evaluación

La evaluación se realizó sobre el conjunto de Reserva, con verdad de terreno curada manualmente (explicacdo en la sección 3.6.2), de modo que las métricas reflejen el desempeño real frente a un patrón de referencia confiable. Si bien la Reserva comprende 54 teselas curadas (Sección 3.6.2), no todas resultan aptas para la evaluación: los conjuntos de entrenamiento de V2, V3 y V4, construidos con etiquetas ruidosas, reúnen en conjunto 10.644 teselas del universo procesado, y algunas de las teselas de la Reserva se encontraban entre ellas. Para asegurar que ninguna versión hubiera visto las teselas de prueba durante su entrenamiento, se excluyeron mediante una lista negra (blacklist) las 27 teselas en esa situación. El conjunto de prueba resultante quedó conformado por las 27 teselas restantes, con 586 cajas de verdad de terreno, correspondientes en su totalidad al año 2020 (la implicancia de esta característica se discute en el Capítulo 4).

Se computaron las métricas estándar de detección de objetos (Everingham et al., 2010; Padilla et al., 2020): **precisión** (proporción de detecciones correctas), **recall** o exhaustividad (proporción de silo-bolsas efectivamente detectadas), **F1** (media armónica de ambas) y **AP** (Average Precision). Una detección se considera verdadero positivo cuando su intersección sobre unión (IoU) con una caja de verdad de terreno supera un umbral determinado. Se adoptó un umbral de IoU de 0,15 para el cómputo de AP (inferior al valor de 0,5 habitual en objetos grandes) por el tamaño reducido de las silo-bolsas: sobre objetos de pocos píxeles, desplazamientos menores de la caja producen caídas abruptas de IoU, de modo que un criterio estricto penalizaría localizaciones correctas a efectos prácticos; se prioriza así la identificación de la presencia del objeto por sobre el ajuste exacto de la caja delimitadora. Este umbral, que compara cada predicción con la verdad de terreno, no debe confundirse con el de 0,3 empleado en la deduplicación, que compara predicciones entre sí. Para el punto de operación reportado en precisión, recall y F1 se fijó un umbral de confianza de 0,5.

En detección de objetos, a diferencia de la clasificación, no existe un conteo de verdaderos negativos. Cada caja predicha es un verdadero positivo si se superpone con una silo-bolsa real o un falso positivo

si no corresponde a ninguna, y cada silo-bolsa real no detectada es un falso negativo; en cambio, un "verdadero negativo" (una región de fondo sin bolsa correctamente no señalada) no está acotado, ya que el fondo admite una cantidad prácticamente infinita de cajas candidatas y no constituye un conjunto contable. Por ello, las métricas empleadas se construyen exclusivamente sobre verdaderos positivos (TP), falsos positivos (FP) y falsos negativos (FN), y no se reportan métricas que requieran verdaderos negativos, como la exactitud (accuracy) o la especificidad.

Las detecciones se sometieron, además, a una etapa de deduplicación. Los detectores como Faster R-CNN suelen proponer varias cajas sobre un mismo objeto, y para conservar una sola aplican internamente la supresión de no máximos (NMS): entre las cajas que se superponen, se queda con la de mayor confianza y descarta las demás cuando su IoU con ella supera un umbral, fijado por defecto en 0,5. Ese criterio funciona bien con objetos compactos, pero no con objetos marcadamente alargados como los silo-bolsas: dos cajas ubicadas sobre la misma bolsa, desplazadas a lo largo de su eje mayor, comparten una fracción pequeña de su área, su IoU queda por debajo de 0,5 y ambas sobreviven, de modo que un único objeto se contabiliza como un acierto más un falso positivo. Para evitarlo se incorporó al protocolo una segunda etapa de NMS, con un umbral de IoU más estricto de 0,3, aplicada de manera idéntica a todas las versiones (su efecto se ilustra en la Figura 4.1). El umbral de confianza de 0,5 se fijó a priori como punto de operación; tanto su incidencia como el efecto de la deduplicación se analizan en detalle en el Capítulo 4 (Secciones 4.2 y 4.3).

Capítulo 4. Discusión, análisis y lecciones aprendidas

Este capítulo presenta los resultados cuantitativos de la comparación entre versiones, los interpreta a la luz de la pregunta de investigación, expone las lecciones aprendidas a lo largo del proyecto y desarrolla las consideraciones éticas, legales y de transferencia, así como las limitaciones del estudio.

4.1. Resultados cuantitativos

El Cuadro 4.1 reporta el desempeño de las cuatro versiones sobre el conjunto de prueba de Reserva, con verdad de terreno curada. Se informan precisión, recall, F1 y AP con umbral de IoU de 0,15, junto con el conteo de verdaderos positivos (TP), falsos positivos (FP) y falsos negativos (FN).

Modelo	Precisión	Recall	F1	AP@0.15	TP/FP/FN
V2 (ruidoso)	0,681	0,826	0,746	0,784	484/227/102
V3 (ruidoso, aleatorio)	0,800	0,751	0,775	0,702	440/110/146
V4 (ruidoso, 10k, estrat.)	0,728	0,826	0,774	0,781	484/181/102
V5 (limpio, 216, estrat.)	**0,864**	**0,826**	**0,845**	**0,795**	**484/76/102**

Cuadro 4.1. Desempeño comparativo de las versiones V2-V5 sobre el conjunto de prueba con verdad de terreno curada, tras aplicar supresión de no máximos (NMS, IoU 0,3) de manera uniforme a todas las versiones. La fila destacada corresponde a la versión propuesta (V5).

La versión V5 (entrenada con 216 imágenes curadas) obtiene la mejor precisión (0,864), el mejor F1 (0,845) y la menor cantidad de falsos positivos del conjunto. Resulta especialmente significativa la comparación con V4: con idéntico recall (484 verdaderos positivos sobre 586), V5 mejora la precisión y el F1 y reduce los falsos positivos a menos de la mitad (76 frente a 181), utilizando aproximadamente el 2 % de los datos de entrenamiento de V4.

Un rasgo central, analizado en detalle en la Sección 4.3, es que V2, V4 y V5 comparten exactamente el mismo recall (484 verdaderos positivos): las tres versiones detectan la misma cantidad de silo-bolsas, por lo que la comparación se dirime en la precisión (esto es, en los falsos positivos), donde la ventaja de V5 es marcada (76 frente a 181 de V4 y 227 de V2). Sobre la curva completa de precisión-recall (Figura 4.2, panel derecho), V5 vuelve a ubicarse primera (AP 0,852, frente a 0,810 de V4 y 0,783 de V2): su ventaja se sostiene, así, en las dos variantes de la métrica. Entre V4 y V2 (ambos con etiquetas ruidosas) la diferencia es pequeña y su orden relativo depende de la variante considerada; la columna AP@0,15 del Cuadro 4.1, más comprimida, los ubica prácticamente empatados (0,781 y 0,784). Estas diferencias entre ambas formas de la métrica se detallan en la Sección 4.2.

4.2. Consideraciones metodológicas de la evaluación: deduplicación y umbral de confianza

Durante la evaluación se identificaron dos cuestiones metodológicas que condicionan la interpretación de las métricas y que, por su valor formativo, se documentan de manera explícita: la presencia de detecciones duplicadas y la elección del umbral de confianza.

4.2.1. Detecciones duplicadas

Una primera versión del cómputo, sin postprocesamiento, arrojó para V5 una cantidad de falsos positivos llamativamente alta, en aparente contradicción con la inspección visual en QGIS, donde sus detecciones lucían ajustadas. El análisis de esos falsos positivos reveló que la amplia mayoría correspondía a cajas duplicadas sobre una misma silo-bolsa, y no a falsas alarmas. El origen es el descripto en la Sección 3.9: la supresión de no máximos interna de Faster R-CNN, con un umbral de IoU de 0,5, no elimina las cajas redundantes sobre objetos marcadamente alargados, porque dos cajas desplazadas a lo largo de una misma bolsa se superponen poco. Al incorporar una etapa de NMS posterior, con umbral de IoU de 0,3 aplicada por igual a todas las versiones, los falsos positivos de V5 se redujeron de 230 a 76, a costa de once detecciones verdaderas (de 495 a 484), y los de V4, de 249 a 181. La Figura 4.1 ilustra el efecto sobre tres silo-bolsas del conjunto de prueba. La deduplicación reduce las cajas redundantes, pero no las elimina por completo: persisten algunas cajas parciales o contenidas dentro de otra, cuya IoU con la caja principal queda por debajo del umbral y que la evaluación sigue contabilizando como falsos positivos. Tras esta corrección, la métrica resultó coherente con la lectura visual.

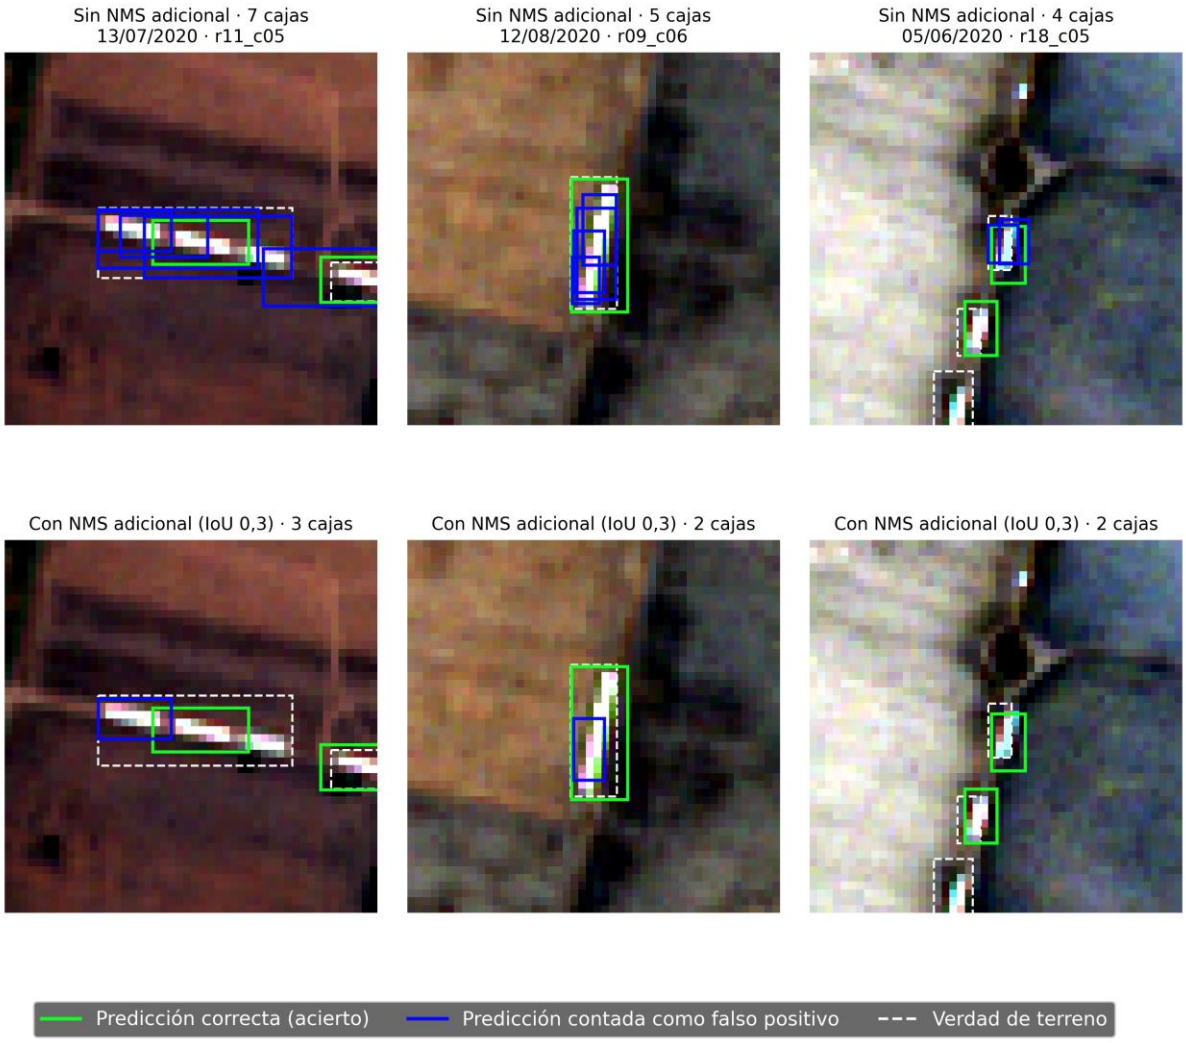


Figura 4.1. Efecto de la deduplicación por NMS sobre las predicciones de V5, en tres silo-bolsas del conjunto de prueba de 2020 con cajas duplicadas. Arriba: predicciones con umbral de confianza de 0,5, sin NMS adicional; sobre cada silo-bolsa, una caja se contabiliza como acierto (verde) y las restantes como falsos positivos (azul). Abajo: las mismas predicciones tras la NMS adicional con IoU de 0,3. En línea discontinua blanca, la verdad de terreno. Recortes de 48 × 48 píxeles con realce de contraste por percentiles. Fuente: elaboración propia.

La naturaleza de los errores también difiere según la calidad de las etiquetas. Antes de la deduplicación, los falsos positivos de V5 eran mayormente cajas redundantes sobre silo-bolsas reales, removibles por postprocesamiento. Para caracterizar los que persisten tras ella, se clasificó cada falso positivo según la fracción de su área contenida en alguna caja de la verdad de terreno: se consideró que recae sobre una silo-bolsa real cuando esa fracción alcanza el 50 %, y sobre el fondo en caso contrario. En V2 y V4, el 92 % de los falsos positivos recae sobre el fondo (208 de 227 y 166 de 181, respectivamente), es decir, sobre superficies que no son silo-bolsas, aprendidas del ruido del índice y no eliminables por NMS. En V5, en cambio, el 34 % (26 de 76) recae sobre silo-bolsas reales: cajas parciales o redundantes que la deduplicación no alcanza a suprimir y bolsas contiguas que la verdad de terreno agrupa en una sola

caja. La diferencia decisiva se observa en las falsas alarmas sobre el fondo, que V5 reduce de 166 a 50 respecto de V4, alrededor de un 70 %. Las etiquetas limpias reducen, así, el tipo de error que el postprocesamiento no puede corregir.

4.2.2 Umbral de confianza

El umbral de 0,5 con el que se reportan precisión, recall y F1 es un valor por defecto fijado a priori, no un óptimo: bajarlo incrementa el recall a costa de la precisión, y subirlo produce el efecto inverso. Por ese motivo la métrica de síntesis es el AP, que integra el desempeño sobre todo el rango de umbrales y es, por construcción, independiente del punto de operación. Para verificar que la conclusión no depende del umbral elegido, se realizó un análisis de sensibilidad barriendo el umbral de confianza (Figura 4.2).

El panel izquierdo de la Figura 4.2 muestra el F1 en función del umbral: la curva de V5 se ubica por encima de las de V4 y V2 prácticamente en todo el rango, y el umbral de 0,5 cae muy cerca de su máximo. El panel derecho presenta las curvas de precisión-recall, cuya área (AP) ubica a V5 en primer lugar (0,852), por delante de V4 (0,810) y V2 (0,783), con V5 dominando en casi todo el recorrido. Esta AP, calculada sobre el rango completo de confianza, constituye la forma estándar de la métrica; difiere de la columna AP@0,15 del Cuadro 4.1 (computada solo sobre las detecciones por encima del umbral de operación de 0,5), que comprime las diferencias y, entre V4 y V2, prácticamente las iguala.

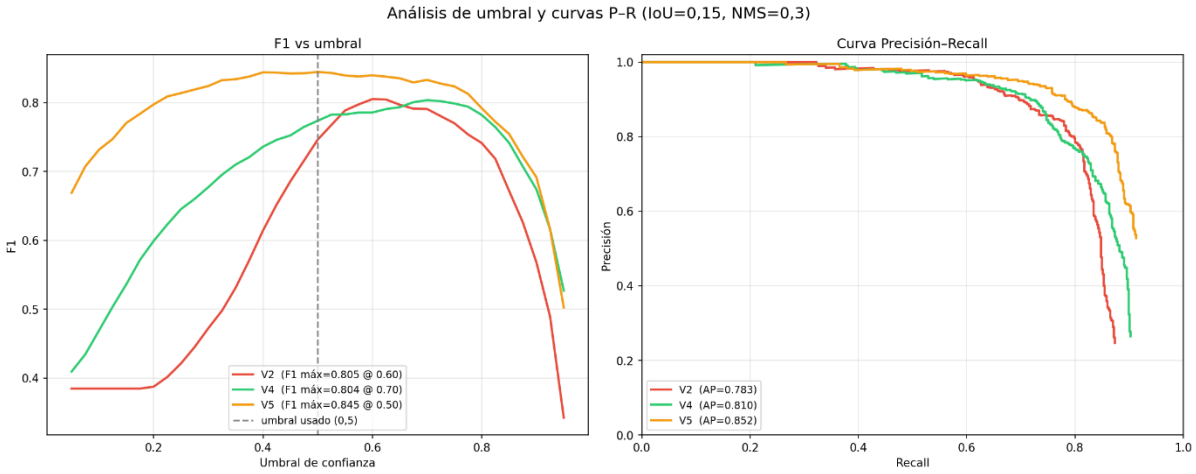


Figura 4.2. Análisis de sensibilidad al umbral sobre el conjunto de prueba (V2, V4 y V5; IoU 0,15; NMS 0,3). Izquierda: F1 en función del umbral de confianza (línea de trazos: umbral de 0,5 adoptado). Derecha: curvas de precisión-recall y AP por versión. Fuente: elaboración propia.

A modo de referencia, los umbrales que maximizan el F1 sobre este conjunto resultan ser 0,60 para V2, 0,70 para V4 y 0,50 para V5. No obstante, no se adopta esa optimización para el reporte: el umbral óptimo debe seleccionarse sobre un conjunto de validación independiente y no sobre el de prueba, ya que ajustarlo al mismo conjunto con el que se informa introduce un sesgo optimista. Se mantiene, por lo tanto, el umbral fijo de 0,5 y se documenta la robustez de la conclusión frente a su variación.

4.2.3 Significancia estadística

Para determinar si las diferencias entre versiones son estadísticamente reales y no un artefacto del tamaño acotado del conjunto de prueba (27 teselas), se aplicaron dos contrastes pareados sobre las imágenes: la prueba de Wilcoxon de rangos con signo sobre el conteo de falsos positivos por imagen, y un bootstrap pareado (2000 remuestreos) para el intervalo de confianza de la diferencia de AP. Los resultados se resumen en el Cuadro 4.2. La ventaja de V5 es significativa en ambas métricas (menos falsos positivos y mayor AP) frente a V4 y frente a V2. En cambio, V4 y V2 no resultan distinguibles: ni en falsos positivos ($p = 0{,}056$) ni en AP ($p = 0{,}41$, con un intervalo de confianza que incluye el cero). El análisis respalda así, cuantitativamente, las lecturas de las secciones precedentes: la mejora por calidad de etiquetas es estadísticamente sólida, mientras que la diferencia entre los dos modelos ruidosos no lo es.

Comparación	ΔFP (mediana/imagen)	Wilcoxon (p)	ΔAP	IC 95 % (ΔAP)	Bootstrap (p)	¿Diferencia significativa?
V5 vs V4	−2	0,0005	+0,038	[+0,008; +0,083]	0,027	Si
V5 vs V2	−4	0,0001	+0,060	[+0,014; +0,092]	0,002	Si
V4 vs V2	−1	0,056	+0,022	[−0,014; +0,059]	0,410	No

Cuadro 4.2. *Significancia estadística de las diferencias entre versiones sobre el conjunto de prueba (27 teselas). ΔFP: diferencia mediana en falsos positivos por imagen (prueba de Wilcoxon de rangos con signo). ΔAP: diferencia de Average Precision (curva completa) con intervalo de confianza por bootstrap pareado de 2000 remuestreos. La última columna indica si la diferencia es significativa ($p < 0{,}05$) en ambas métricas. Fuente: elaboración propia.*

4.3. Anatomía de los errores: recall equivalente y límite de detectabilidad por resolución

Un rasgo llamativo de los resultados es que tres de las cuatro versiones (V2, V4 y V5) detectan la misma cantidad de silo-bolsas (484 verdaderos positivos sobre 586). Su interpretación es central para entender qué distingue a un modelo de otro.

En primer lugar, el número de verdaderos positivos no puede superar la cantidad de objetos reales presentes en el conjunto de prueba: existen 586 silo-bolsas etiquetadas, de modo que ninguna versión puede acertar más de 586. Dibujar más cajas no incrementa los aciertos sino los falsos positivos: V2, por ejemplo, emite 711 cajas pero acierta 484, y las 227 restantes son falsas alarmas. La pregunta pertinente, entonces, es cuántas de las 586 silo-bolsas son efectivamente detectables.

Para descartar que la coincidencia fuese un artefacto de cómputo, se verificó la cantidad de aciertos barriendo el umbral de confianza (Cuadro 4.3). Solo en el umbral de 0,50 las tres versiones coinciden exactamente; en el resto del barrido sus valores se separan, aunque se mantienen muy próximos. La coincidencia en 484 es, por lo tanto, el punto en que las tres curvas de aciertos, cercanas entre sí por compartir la misma arquitectura, se cruzan al umbral de 0,50, y no responde a ningún valor forzado.

Umbral de confianza	V2	V4	V5
0.40	497	502	501
0.45	491	491	492
0.50	484	484	484
0.55	476	469	471
0.60	459	453	464

Cuadro 4.3. Verdaderos positivos por versión según el umbral de confianza, sobre el conjunto de prueba de 2020 (586 silo-bolsas). Solo en el umbral de 0,50 las tres versiones coinciden exactamente. Fuente: elaboración propia.

El análisis de los fallos compartidos permite descomponer las 586 silo-bolsas en tres grupos. Un primer grupo de 439 es detectado por las tres versiones: son los casos claros, de tamaño suficiente. Un segundo grupo de 61 no es detectado por ninguna: constituye el límite duro de detectabilidad. Un tercer grupo de 86, en la frontera, es detectado de manera parcial: cada versión acierta alrededor de 45 de esos casos, pero no necesariamente los mismos. De allí que el total coincida (439 compartidos más unos 45 de frontera equivalen a 484) aunque los ejemplares no sean idénticos: misma capacidad de detección impuesta por la arquitectura y, por ende, la misma cantidad de casos de frontera resueltos, pero con pesos distintos que resuelven ejemplares distintos.

El factor predominante en la pertenencia al grupo no detectado es el tamaño (Figura 4.3, fila inferior). Las silo-bolsas que ninguna versión detecta son, en mediana, más pequeñas en píxeles (seis píxeles de lado mayor, frente a ocho en las detectadas por las tres). A ello se suma, en 28 de los 61 casos no detectados, una oclusión parcial del objeto: la bolsa aparece cortada por el borde de la tesela o cubierta en parte por la máscara de nubes. A 10 metros de resolución, una bolsa de unos 40 a 60 metros de largo ocupa apenas unos pocos píxeles, y allí opera una limitación arquitectónica, y no un defecto de entrenamiento. El extractor de características reduce progresivamente la resolución espacial mediante convoluciones con paso y submuestreo; aun en el nivel más fino de la red piramidal de características, un objeto de cuatro a seis píxeles se reduce a aproximadamente un píxel del mapa de características, señal insuficiente para que la red de propuestas genere una región y para que la cabeza de detección la localice. Por tratarse de un límite físico-arquitectónico, afecta por igual a todas las versiones, lo que explica el techo común de recall.

Para fijar la idea con un ejemplo, supóngase un conjunto de prueba reducido con diez silo-bolsas reales (tres grandes, cinco intermedias y dos muy pequeñas) y tres modelos. El Cuadro 4.4 esquematiza qué objeto detecta cada uno (✓ indica detección; ✗, omisión).

Silo-bolsa	Tamaño	Modelo A	Modelo B	Modelo C
S1	Grande	✓	✓	✓
S2	Grande	✓	✓	✓
S3	Grande	✓	✓	✓
S4	Intermedia	✓	✗	✗
S5	Intermedia	✓	✓	✗
S6	Intermedia	✗	✓	✗
S7	Intermedia	✗	✗	✓
S8	Intermedia	✗	✗	✓
S9	Pequeño	✗	✗	✗
S10	Pequeño	✗	✗	✗
Aciertos (TP)		5	5	5
Falsos positivos (FP)		4	1	5

Cuadro 4.4. Ejemplo ilustrativo del techo de detectabilidad y del rol de los falsos positivos. Los tres modelos aciertan la misma cantidad de objetos (5) sin acertar los mismos; lo que los distingue es la cantidad de falsos positivos.

En el ejemplo, los tres modelos aciertan cinco silo-bolsas, pero no las mismas: los tres objetos grandes son detectados por todos; los dos más pequeños, por ninguno; y de los cinco intermedios cada modelo resuelve dos ejemplares distintos. El conteo coincide sin que los objetos coincidan. Lo que diferencia a los modelos no es entonces cuántas silo-bolsas encuentran (su recall es equivalente) sino cuánta superficie espuria agregan: el Modelo B emite un solo falso positivo, frente a los cuatro y cinco de A y C. Trasladado al caso real, las tres versiones de alto recall encuentran las mismas 484 silo-bolsas detectables, y la diferencia se juega en los falsos positivos: 76 en V5 (etiquetas limpias), 181 en V4 y 227 en V2 (etiquetas ruidosas).

Esta dinámica se observa también en casos reales (Figura 4.3, fila superior). En una tesela representativa del conjunto de prueba (2020_8_12_1_tile_r11_c06), de trece silo-bolsas, doce son detectadas por las tres versiones y una por ninguna, de modo que el recall es idéntico entre ellas. Los falsos positivos, en cambio, se distribuyen de manera muy distinta: trece para V2, diez para V4 y ninguno para V5. La tesela reproduce así, a escala reducida, el patrón observado sobre el conjunto completo (Cuadro 4.1): igual capacidad de detección y una diferencia concentrada en las falsas alarmas, que no necesariamente se manifiesta con la misma magnitud en cada tesela individual.

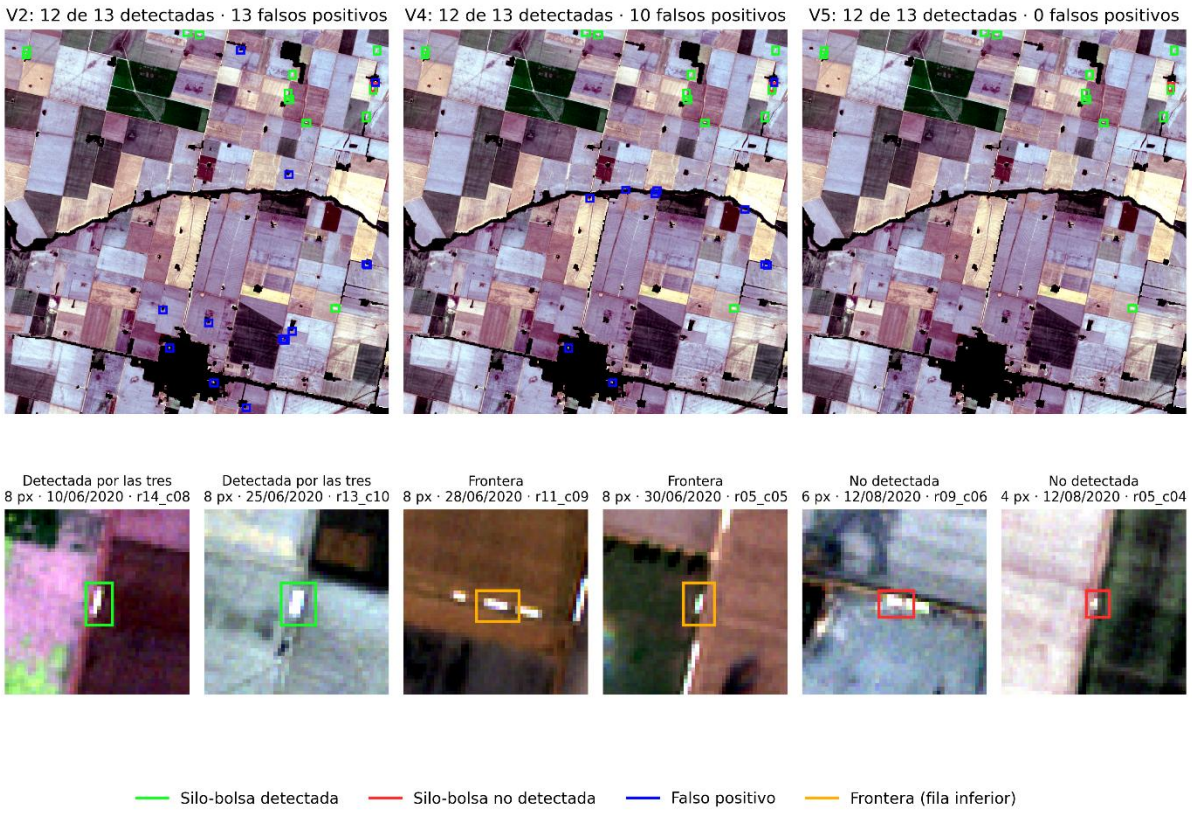


Figura 4.3. Detecciones de V2, V4 y V5 sobre una tesela representativa del conjunto de prueba de 2020 y ejemplos de los tres grupos de detectabilidad. Arriba: silo-bolsas detectadas (verde) y no detectadas (rojo) por cada versión, y sus falsos positivos (azul); la imagen se recorta a la zona con datos válidos y las cajas se amplían seis píxeles por lado para facilitar su visualización. Abajo: recortes de 48 × 48 píxeles, tomados de distintas teselas del conjunto de prueba, con dos ejemplos de silo-bolsas detectadas por las tres versiones, de frontera (detectadas por una o dos versiones) y no detectadas por ninguna, seleccionados por su cercanía al tamaño mediano de cada grupo; en cada recorte se marca únicamente la silo-bolsa de ejemplo. Umbral de confianza de 0,5 y deduplicación por NMS. Realce de contraste por percentiles, sobre la tesela completa en la fila superior y sobre cada recorte en la inferior. Fuente: elaboración propia.

4.4. Discusión: calidad de los datos frente a cantidad

El resultado central de este trabajo es un hallazgo de eficiencia de datos: un conjunto de entrenamiento pequeño y limpio iguala o supera a uno aproximadamente cincuenta veces mayor pero ruidoso. Este resultado es consistente con el paradigma centrado en los datos y con la literatura sobre ruido de etiqueta (Frénay y Verleysen, 2014; Northcutt et al., 2021), y aporta evidencia empírica, sobre un caso real de teledetección, de que invertir el presupuesto de anotación en calidad puede ser más rentable que invertirlo en cantidad.

La ventaja de V5 no depende del punto de operación elegido: se manifiesta en el F1 al umbral de 0,5, se sostiene a lo largo de todo el barrido de umbrales (Figura 4.2) y se confirma en el AP integrado sobre la curva completa de precisión-recall (Sección 4.2). En términos concretos, con datos limpios el modelo alcanza un mejor compromiso entre precisión y exhaustividad: a igual recall, reduce a menos de la mitad los falsos positivos respecto del conjunto grande y ruidoso, diferencia que además resulta estadísticamente significativa (Cuadro 4.2).

La comparación entre V4 y V5, sin embargo, no aísla una única variable: más allá de la calidad de las etiquetas, V5 se entrenó durante más épocas y con reducción escalonada de la tasa de aprendizaje. V4, además, empleó aumento de datos geométrico y radiométrico, mientras que V5 no lo empleó; esta diferencia, sin embargo, opera en sentido contrario al resultado, en tanto la aumentación tiende a favorecer la generalización del modelo que la recibe, de modo que la ventaja de V5 se obtiene pese a ella y no gracias a ella. Tres elementos, sin embargo, respaldan que el resultado obedece a la calidad del dato y no a esa diferencia de régimen. Primero, V5 alcanza su desempeño con mucho menos entrenamiento, no más: sus épocas fueron del orden de treinta y cuatro minutos, frente a las cerca de treinta horas de cada época de V4, y en total procesó unas 7.300 pasadas de imagen (183 imágenes de entrenamiento a lo largo de 40 épocas) frente a las más de 42.000 de V4 (8.500 imágenes a lo largo de 5 épocas), de modo que su ventaja no proviene de un cómputo mayor (Figura 4.4, panel b). Segundo, la pérdida de V4 se había aplanado en sus últimas épocas, con descensos inferiores a 0,01 por época (Figura 4.4, panel a), de modo que no se trata de un modelo groseramente sub-entrenado; además, su recall iguala al de V5 sobre el conjunto de prueba de 2020, como no cabría esperar de un modelo sub-

ajustado. Tercero, los falsos positivos remanentes de V4 se concentran en superficies del tipo que (el 92 % recae sobre el fondo, según la clasificación de la Sección 4.2) el índice INBNV rotula erróneamente como silo-bolsa, como caminos, bordes de lotes, techos y suelos claros (Sección 3.5.1). Para esas superficies, las etiquetas ruidosas no constituyen un error aleatorio sino una indicación sistemática: la función de pérdida premia al modelo por detectarlas. La literatura sobre ruido de etiqueta muestra que las redes profundas aprenden primero los patrones consistentes del conjunto y que, a medida que el entrenamiento se prolonga, pasan a memorizar también las etiquetas erróneas (Arpit et al., 2017). Es esperable, por lo tanto, que un entrenamiento más extenso de V4 no reduzca esas falsas alarmas, sino que tienda a consolidarlas, de modo que la marcada reducción de falsos positivos de V5, a igual recall, resulta atribuible a la limpieza de las etiquetas antes que a la duración del entrenamiento. El detalle de la configuración de entrenamiento de cada versión se consigna en el Apéndice B (Cuadro B.1).

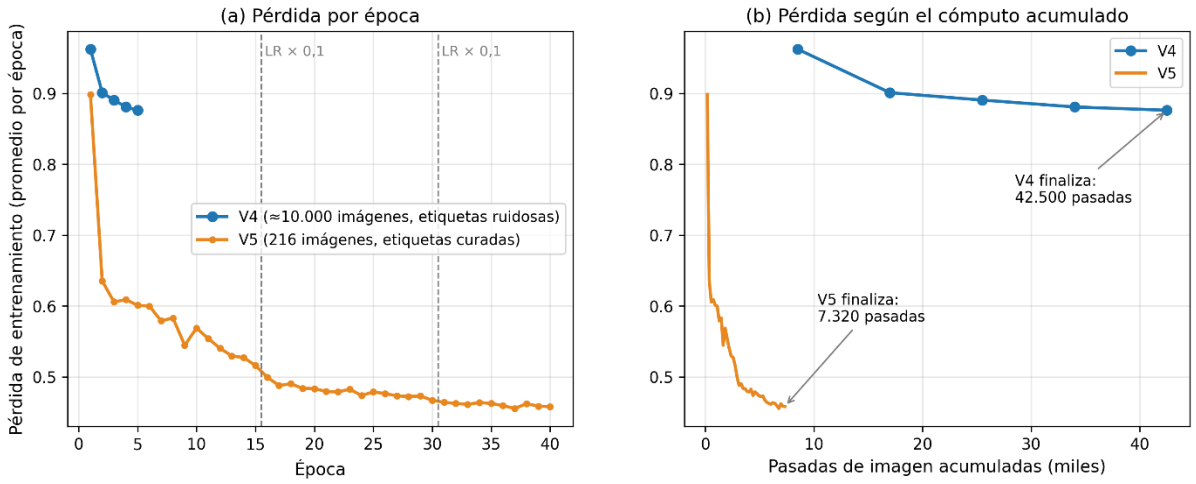


Figura 4.4. Curvas de entrenamiento de V4 y V5. (a) Pérdida de entrenamiento promedio por época; las líneas discontinuas indican las reducciones de la tasa de aprendizaje de V5 (factor de 0,1 tras las épocas 15 y 30). (b) La misma pérdida en función de las pasadas de imagen acumuladas, que expresa el cómputo efectivamente invertido en cada versión. Los valores absolutos de pérdida no son comparables entre versiones, dado que se calculan sobre conjuntos y etiquetas distintos; la comparación se limita a la forma de cada curva. Fuente: elaboración propia.

4.5. Análisis cualitativo

El análisis visual de las predicciones permite caracterizar los aciertos y los errores. Las versiones detectan con solidez las silo-bolsas aisladas y bien contrastadas, y tienden a confundirse con objetos alargados y reflectantes del entorno, en línea con lo previsto. A igual capacidad de detección, la diferencia se manifiesta en los falsos positivos. La Figura 4.5 compara, sobre una misma tesela del conjunto de prueba, las detecciones del modelo entrenado con etiquetas ruidosas (V4) y del entrenado con etiquetas curadas (V5): V4 emite varias cajas sobre superficies que no son silo-bolsas (bordes de

lotes, caminos, construcciones, suelos claros y bordes de ríos), mientras que V5 concentra sus detecciones sobre las bolsas reales, en coherencia con su menor tasa de falsos positivos.



Figura 4.5. Comparación cualitativa de detecciones sobre una tesela del conjunto de prueba (conjunto de prueba de 2020; IoU de 0,15 y umbral de confianza de 0,5). Izquierda: modelo con etiquetas ruidosas (V4). Derecha: modelo con etiquetas curadas (V5). Verdad de terreno en verde; predicciones del modelo en azul. Ambas versiones detectan las silo-bolsas reales; V4 agrega falsas alarmas sobre superficies brillantes que V5 no produce. Fuente: elaboración propia.

4.6. Validación temporal sobre imágenes de 2026

Como complemento de la evaluación sobre el conjunto de Reserva (que, según se discutió, proviene en su totalidad del año 2020), se realizó una validación temporal sobre imágenes del año 2026, posterior al período de estudio y no visto por ninguna de las versiones durante el entrenamiento. A tal fin se replicó íntegramente el flujo de adquisición y procesamiento original (las mismas bandas, el índice INBNV con idéntico percentil, el recorte a la zona agrícola y el teselado) sobre las mismas teselas MGRS que cubren el área de estudio. El preprocesamiento se mantuvo idéntico al original, incluida la escala radiométrica sin corregir (Sección 3.4), de modo que el conjunto de prueba de 2026 se evalúa en las mismas condiciones en que se entrenaron los modelos.

Sobre las teselas procesadas se aplicó un muestreo aleatorio estratificado por mes y se curó manualmente a completitud el conjunto seleccionado, con el mismo protocolo descripto en la Sección 3.5.2. El conjunto resultante quedó conformado por 29 teselas con 802 cajas de verdad de terreno, correspondientes a los meses de junio, julio y agosto de 2026, y cubre las tres teselas MGRS empleadas en el entrenamiento. Dos de las 29 se incorporaron específicamente para cubrir la franja norte del área de estudio, comprendida únicamente por la tesela 20HNK; su selección fue dirigida por ese criterio de cobertura y aplicó un filtro de calidad de imagen (porcentaje mínimo de píxeles válidos y ausencia de nubes) que no se aplicó al resto del conjunto, particularidad que se retoma en la Sección 4.10.

El Cuadro 4.5 reporta el desempeño de las cuatro versiones sobre este conjunto, con el mismo postprocesamiento de deduplicación (NMS, IoU 0,3) empleado en la evaluación de 2020.

Modelo	Precisión	Recall	F1	AP@0,15	TP/FP/FN

V2 (ruidoso)	0,688	0,752	0,718	0,694	603/274/199
V3 (ruidoso, aleatorio)	0,841	0,645	0,730	0,612	517/98/285
V4 (ruidoso, 10k, estrat.)	0,782	0,722	0,751	0,687	579/161/223
V5 (limpio, 216, estrat.)	**0,809**	**0,793**	**0,801**	**0,705**	**636/150/166**

Cuadro 4.5. Validación temporal sobre imágenes de 2026 (año no visto por ningún modelo), con deduplicación (NMS, IoU 0,3). Conjunto de 29 teselas y 802 cajas de verdad de terreno, curadas a completitud. La fila destacada corresponde a la versión propuesta (V5). Fuente: elaboración propia.

Sobre el año no visto, V5 obtiene el mejor desempeño en las cuatro métricas: F1 de 0,801, precisión de 0,809, recall de 0,793 y AP de 0,705. A diferencia de lo observado en 2020, el recall no coincide entre versiones, de modo que la comparación no se dirime únicamente en los falsos positivos. Esa diferencia importa, porque el mecanismo por el cual V5 aventaja a V4 no es el mismo en ambas evaluaciones. Sobre el conjunto de 2020, ambas versiones detectaban exactamente la misma cantidad de silo-bolsas y V5 se imponía reduciendo los falsos positivos a menos de la mitad, es decir, por precisión. Sobre 2026, en cambio, la cantidad de falsos positivos es similar entre ambas (150 y 161) y la ventaja proviene del recall: V5 detecta 636 silo-bolsas frente a las 579 de V4, esto es, 57 objetos adicionales. Las dos lecturas resultan consistentes con la hipótesis del trabajo, en tanto ambas describen un modelo que discrimina mejor la clase de interés, aunque el margen se expresa de manera distinta en cada conjunto. La Figura 4.6 ilustra este comportamiento sobre dos teselas del conjunto: con una cantidad de falsos positivos similar, V5 detecta 45 de 57 silo-bolsas frente a 39 de V4 en la primera, y 23 de 30 frente a 18 en la segunda. El conjunto completo de teselas se presenta en el Apéndice E.

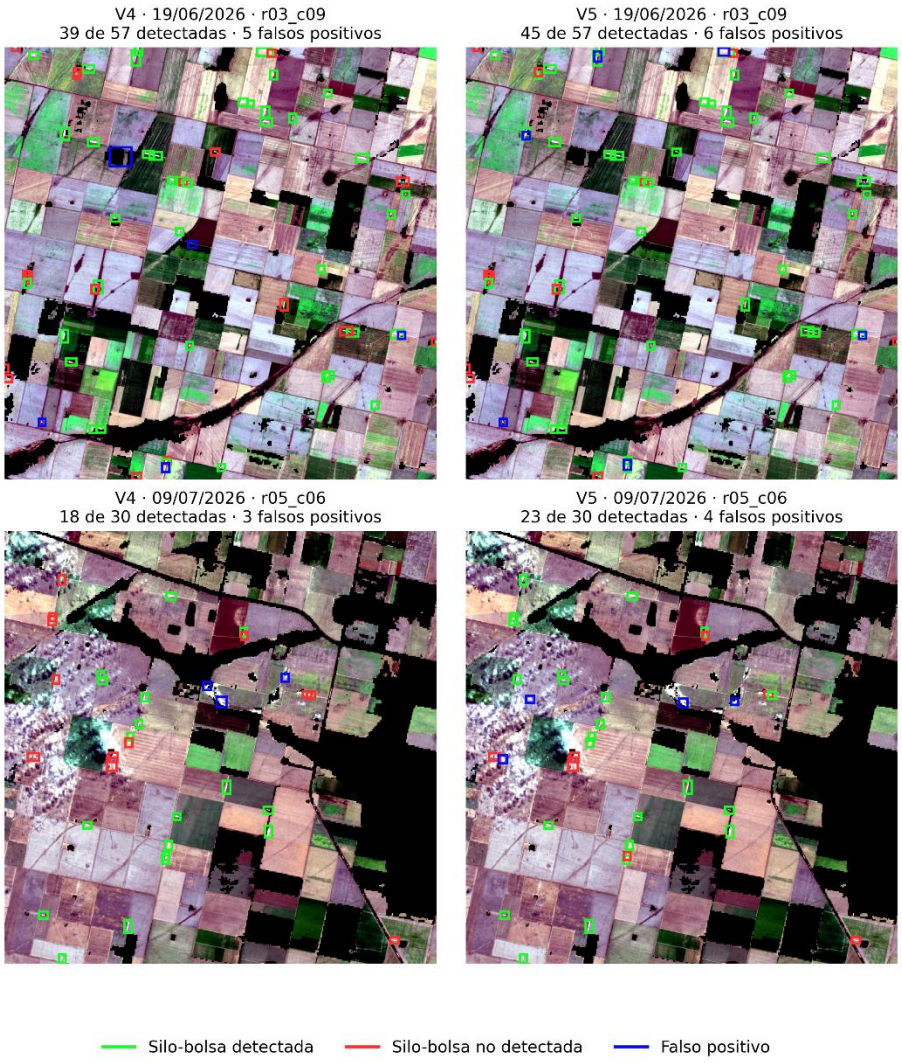


Figura 4.6. Detecciones de V4 y V5 sobre dos teselas del conjunto de validación temporal de 2026: 19/06/2026 (r03_c09) y 09/07/2026 (tesela 20HNK, r05_c06). En verde, silo-bolsas detectadas; en rojo, no detectadas; en azul, falsos positivos. Con una cantidad similar de falsos positivos, V5 detecta más silo-bolsas que V4 en ambas teselas, en línea con el comportamiento observado sobre el conjunto completo. Las cajas se amplían seis píxeles por lado para facilitar su visualización. Fuente: elaboración propia.

Para evaluar la solidez de estas diferencias se aplicaron los mismos contrastes pareados empleados en la evaluación de 2020 (prueba de Wilcoxon de rangos con signo sobre los falsos positivos por imagen y bootstrap pareado para la diferencia de AP), resumidos en el Cuadro 4.6.

Comparación	ΔFP (mediana/imagen)	Wilcoxon (p)	ΔAP	IC 95 % (ΔAP)	Bootstrap (p)	¿Diferencia significativa?
V5 vs V4	+1	0,556	+0,046	[+0,007; +0,080]	0,025	Parcial
V5 vs V2	−2	0,0005	+0,057	[+0,022; +0,084]	< 0,001	Sí
V4 vs V2	−4	0,0023	+0,011	[−0,014; +0,034]	0,328	Parcial

Cuadro 4.6. Significancia estadística de las diferencias entre versiones sobre la validación temporal de 2026 (29 teselas, 802 cajas). ΔFP: diferencia mediana en falsos positivos por imagen (Wilcoxon de rangos con signo). ΔAP: diferencia de Average Precision con intervalo de confianza por bootstrap pareado (2000

remuestreos). La última columna resume el resultado: "Sí" indica significancia (p < 0,05) en ambas métricas; "Parcial", en una sola de ellas. Fuente: elaboración propia.

La ventaja de V5 sobre la línea de base ruidosa V2 resulta significativa en ambas métricas: reduce los falsos positivos por imagen (p = 0,0005) y mejora el AP (p < 0,001). Frente a V4, la comparación es más matizada: el AP favorece a V5 con un intervalo de confianza que excluye el cero (+0,046; p = 0,025), mientras que en falsos positivos las dos versiones resultan indistinguibles (p = 0,556). La ventaja de V5 sobre V4 en el año no visto es, por lo tanto, consistente, pero de significancia acotada, y no una superioridad establecida. V4, por su parte, reduce los falsos positivos respecto de V2 (p = 0,0023) sin mejorar el AP de manera significativa, en línea con lo observado sobre el conjunto de 2020.

En conjunto, sobre imágenes de un año no incluido en el entrenamiento, el conjunto pequeño y curado (216 imágenes) alcanza el mejor desempeño global, supera de manera estadísticamente significativa a la línea de base ruidosa y mantiene una ventaja consistente, aunque de significancia acotada, sobre el conjunto grande y ruidoso (cerca de 10.000 imágenes). El conjunto de prueba cubre los tres meses de la ventana de observación y las tres teselas MGRS del área de estudio, de modo que la evaluación no queda restringida a un subconjunto del territorio ni a un momento particular del período. El resultado es coherente con el hallazgo central del trabajo, entendido como eficiencia de datos, y aporta evidencia de que la ventaja obtenida no obedece a un sobreajuste al año del conjunto de prueba principal.
Por último, las dos evaluaciones se mantienen deliberadamente separadas y no se integran en un único conjunto de prueba. Si bien un conjunto combinado ofrecería una muestra mayor, ambas evaluaciones responden a preguntas distintas: la de 2020 mide la generalización a teselas no vistas dentro de un año conocido, mientras que la de 2026 mide la generalización a un año completamente nuevo. Su agregación diluiría esa distinción, que es la que permite atribuir la robustez observada a la capacidad del modelo y no a la familiaridad con las condiciones del período de entrenamiento.

4.7. Lecciones aprendidas

El recorrido del proyecto dejó una serie de aprendizajes metodológicos que se consignan por su valor práctico:

- **Calidad por sobre cantidad.** La evidencia obtenida respalda priorizar la calidad del conjunto de entrenamiento; un dataset pequeño y bien curado puede ser más valioso que uno masivo y ruidoso.
- **El muestreo importa.** El reemplazo del muestreo aleatorio por uno estratificado por estrato año-mes, con control de distancia entre teselas para evitar fuga espacial, resultó decisivo para la representatividad del conjunto.

- **Reproducibilidad y reanudación.** En entrenamientos prolongados en CPU, la lógica de reanudación desde checkpoint resulta imprescindible; una semilla fija y un pipeline modular fueron claves para la reproducibilidad.
- **Los errores de filtrado tienen consecuencias.** Una cláusula de filtrado faltante incorporó accidentalmente imágenes de Reserva al entrenamiento; su detección y corrección a tiempo evitó contaminar la evaluación. La gestión del dataset mediante archivos de seguimiento, sin modificar el disco, facilitó la trazabilidad.
- **El postprocesamiento incide tanto como el modelo**. La deduplicación por NMS, aplicada de manera uniforme, modificó sustancialmente la lectura de las métricas sin alterar los modelos: el punto de operación y el postproceso son parte del resultado y deben explicitarse.
- **Validar con la vista, no solo con la métrica.** La discrepancia entre una métrica desfavorable y una inspección visual favorable fue la que reveló el problema de las detecciones duplicadas.
- **Las coincidencias aparentes exigen verificación.** La igualdad exacta de verdaderos positivos entre versiones se confirmó como un cruce de curvas al umbral de 0,5 y no como un artefacto mediante un barrido del umbral.
- **Conocer los límites del sensor.** Alrededor de un 10 % de las silo-bolsas resultan sub-resolución a 10 m; reconocerlo evita atribuir al modelo un techo de recall que impone la física.
- **La significancia estadística importa**. Con conjuntos de prueba acotados, contrastar formalmente las diferencias (pruebas pareadas, bootstrap) distingue una mejora real de una fluctuación de muestreo y evita sobreinterpretar diferencias que no lo son.
- **Controlar una variable exige mantener fijas las demás**. documentar con precisión qué se mantuvo constante y qué evolucionó a lo largo de los experimentos es parte del rigor del análisis.

4.8. Consideraciones éticas, legales y de privacidad

La detección automatizada de infraestructura agrícola a partir de imágenes satelitales plantea consideraciones éticas que este trabajo asume de manera explícita. La cuestión de fondo es que se observa actividad económica de actores (productores, campos, etc.) que no han prestado consentimiento para ese relevamiento.

Varios elementos acotan el alcance de esta tensión. En primer lugar, las imágenes Sentinel-2 son *públicas y de acceso libre*, y su resolución espacial de 10 metros es de carácter medio: no permite identificar personas ni realizar vigilancia individual fina. En segundo lugar, el objeto de detección es una *estructura de almacenamiento* (infraestructura agrícola) y no un individuo. En tercer lugar, el uso propuesto es de naturaleza *agregada y estadística* (estimar distribución y cantidad a escala regional), y no de fiscalización dirigida a casos particulares.

No obstante, persiste una tensión legítima entre el interés público de contar con información objetiva y la privacidad y el secreto comercial de los productores. Existe, además, un riesgo de inequidad: una herramienta de este tipo, en manos exclusivas de ciertos actores, podría conferir una ventaja informativa frente a otros con menor acceso. Por ello, en el marco de este trabajo, de carácter netamente académico y de alcance acotado, no se publica información asociada directamente a un campo, un propietario o una cantidad producida, y se tratan los resultados de manera estadística y global. En coherencia con la Ley 25.326 de Protección de Datos Personales de la República Argentina, no se expone ubicación geográfica precisa ni dato alguno que pueda vincularse a una persona determinada sin su consentimiento.

Existe, además, una salvaguarda epistémica: dado que los resultados del modelo no son completamente exactos, su uso para acciones de fiscalización individual sería metodológicamente inapropiado, lo que refuerza la pertinencia de un uso estadístico y agregado.

4.9. Propuesta de valor y transferencia

El interés del trabajo se sostiene en dos planos. En el plano metodológico, el hallazgo de eficiencia de datos trasciende el caso de los silo-bolsas: interpela a cualquier proyecto de aprendizaje supervisado en el que el etiquetado sea costoso, sugiriendo que la inversión en calidad del dato puede rendir más que la inversión en volumen. En el plano aplicado, una herramienta de monitoreo de silo-bolsas de bajo costo, escalable y de revisita frecuente resulta de interés para diversos actores:

- **Organismos públicos y agropecuarios** (por ejemplo, secretarías de agricultura, organismos de recaudación y estadística, INTA): estimación del stock de granos almacenado temporalmente, insumo para estadísticas de producción y para el diseño de políticas.
- **Acopios, aseguradoras y empresas de logística**: monitoreo de inventario regional, gestión de riesgo y planificación logística (capacidad de almacenamiento, rutas de transporte).
- **Empresas del sector y operadores de mercado**: inteligencia de mercado y planificación basada en datos objetivos y actualizados.
- **Productores y dueños de campo**: monitoreo y seguimiento de su propia producción.
- **Investigación**: base metodológica para la detección de otros objetos agrícolas a 10 m de resolución y para el estudio del etiquetado débil en teledetección.

La transferencia efectiva requeriría la publicación de la metodología y, eventualmente, del dataset y de los modelos, junto con una documentación clara de capacidades y limitaciones. El desarrollo de interfaces o servicios de consulta excede el alcance de esta tesis.

4.10. Limitaciones del estudio

Se reconocen las siguientes limitaciones. **(i) Resolución.** La resolución de 10 m limita la detección de silo-bolsas muy pequeñas, agrupadas o parcialmente visibles.

(ii) Validación temporal. El conjunto de prueba principal proviene íntegramente del año 2020, de modo que mide la generalización a teselas no vistas dentro de un año conocido, pero no a años distintos. La validación sobre imágenes de 2026 (Sección 4.6) aborda esta limitación con una muestra sustantiva: 29 teselas y 802 cajas curadas a completitud, frente a las 27 teselas y 586 cajas del conjunto de prueba principal, con contraste estadístico y cobertura de los tres meses de la ventana de observación. Sobre ella, el conjunto pequeño y curado alcanza el mejor desempeño global y supera de manera significativa a la línea de base ruidosa, con una ventaja acotada sobre el conjunto grande y ruidoso. Su consolidación requeriría, de todos modos, extender la evaluación a campañas adicionales. Por otra parte, V4 dispuso de mayor exposición a las condiciones de 2020 durante el entrenamiento y, pese a ello, no supera a V5, lo que sugiere que la ventaja de V5 no obedece a un sobreajuste a ese año.

(iii) Dependencia del dato. El desempeño depende fuertemente de la calidad y representatividad del conjunto curado.

(iv) Confusión con objetos similares. Persiste la posibilidad de confundir silo-bolsas con bordes de lotes, caminos o galpones.

(v) Especificidad de sitio. El modelo, entrenado sobre Marcos Juárez, puede presentar sesgo hacia las condiciones de esa zona, lo que sugiere la necesidad de reentrenamiento fino para su aplicación en otras regiones.

(vi) Techo de detectabilidad. Alrededor de un 10 % de las silo-bolsas del conjunto de prueba resultan indetectables para cualquiera de las versiones, principalmente por su tamaño en píxeles y, en parte de los casos, por oclusión parcial en el borde de la tesela o bajo la máscara de nubes, lo que fija un límite de recall impuesto por la resolución del sensor y no por el modelo.

(vii) Condiciones radiométricas y atmosféricas. Pese al enmascaramiento de nubes mediante la capa SCL, condiciones atmosféricas residuales (bruma, sombras de nubes no detectadas, variaciones de iluminación entre fechas) pueden alterar la reflectancia observada y afectar tanto la generación de candidatos por el índice como el desempeño de los modelos. La evaluación cualitativa sobre 2026 sugiere, de hecho, que los modelos entrenados con etiquetas ruidosas resultan más propensos a falsas alarmas en presencia de nubes residuales.

(viii) Escala radiométrica. El desplazamiento introducido por la Agencia Espacial Europea en enero de 2022 (Sección 3.4) no fue corregido, de modo que el conjunto de entrenamiento combina dos escalas: las imágenes de 2020 y 2021 sin desplazamiento (72 de las 216 de V5) y las de 2022 a 2025 con él (144). El análisis de sensibilidad del Apéndice D muestra que llevar el conjunto de prueba de 2026 a la escala previa mejora el desempeño de V4 y de V5 sin alterar el orden entre versiones, por lo que las métricas reportadas resultan, en todo caso, conservadoras. Además, el reprocesamiento del archivo histórico (Collection-1) distribuye también las imágenes anteriores a 2022 con el desplazamiento

aplicado, por lo que una reproducción del pipeline a partir de esa colección obtendría escalas distintas de las aquí empleadas.

Capítulo 5. Conclusiones y trabajos futuros

5.1. Conclusiones

Este trabajo desarrolló y validó un detector de silo-bolsas en imágenes Sentinel-2 para el departamento de Marcos Juárez, y de manera central, examinó empíricamente el efecto de la calidad de la verdad de terreno sobre el desempeño del modelo. En relación con los objetivos planteados, se construyó una base de datos de imágenes Sentinel-2 preprocesadas para el período junio-agosto de 2020 a 2025; se diseñó e implementó un método de etiquetado semiautomático basado en un índice espectral, con curación manual en QGIS; se definió una progresión experimental con arquitectura fija (V2-V5), orientada a estudiar el efecto de la calidad de las etiquetas; se entrenó un Faster R-CNN ResNet50-FPN con cajas de anclaje adaptadas a la geometría de los silo-bolsas, bajo restricciones de cómputo en CPU; se evaluaron y compararon las versiones sobre un conjunto de prueba con verdad de terreno curada; y se validó su desempeño sobre imágenes de un año no visto durante el entrenamiento (2026).

La conclusión principal es que la calidad de la verdad de terreno prima sobre su cantidad. Con apenas el 2 % de los datos, la versión entrenada con 216 imágenes curadas igualó o superó a la entrenada con cerca de 10.000 imágenes ruidosas: sobre el conjunto de prueba principal alcanzó el mejor F1 y la mejor precisión, con un recall equivalente y menos de la mitad de falsos positivos. La diferencia se concentra, además, en el tipo de error que ningún postprocesamiento corrige: las falsas alarmas sobre el fondo, que V5 redujo alrededor de un 70 % respecto de V4. El hallazgo es, ante todo, de eficiencia de datos, y respalda la adopción de un enfoque centrado en los datos para problemas de detección con etiquetado costoso. La ventaja se sostuvo sobre imágenes de un año no visto durante el entrenamiento (2026): sobre 29 teselas y 802 silo-bolsas, el conjunto pequeño y curado alcanzó el mejor desempeño global, superó de manera estadísticamente significativa a la línea de base ruidosa y mantuvo una ventaja consistente, aunque de significancia acotada, sobre el conjunto grande y ruidoso, lo que sugiere que el resultado no obedece a un sobreajuste al año de entrenamiento.

Se concluye, asimismo, que la generación semiautomática de etiquetas mediante el índice INBNV seguida de curación manual es una estrategia viable y reproducible para reducir el costo de anotación de objetos pequeños en teledetección, aun cuando el índice por sí solo resulte insuficiente como clasificador: alrededor del 60 % de sus candidatos son falsos positivos y omite cerca del 22 % de las silo-bolsas. Por último, la adaptación de las cajas de anclaje a la geometría alargada de los silo-bolsas constituyó una decisión de diseño acorde con el objeto de estudio; su aporte específico no se aisló experimentalmente y se plantea como línea de trabajo futuro.

5.2. Trabajos futuros

A partir de lo anterior, se identifican las siguientes líneas de continuación:

- **Extensión de la validación temporal.** Ampliar la evaluación a campañas posteriores y a otros años del período, a fin de caracterizar la estabilidad del desempeño a lo largo del tiempo.

- **Incorporación del NIR al modelo.** Evaluar de manera explícita y cuantitativa el aporte de una entrada de cuatro canales (RGB+NIR) frente a la entrada RGB, adaptando la arquitectura.
- **Fusión con datos de radar.** Integrar Sentinel-1, insensible a la nubosidad, para asegurar un monitoreo continuo independiente de las condiciones atmosféricas (Victor et al., 2024).
- **Segmentación y medición.** Extender de la detección a la segmentación para estimar dimensiones y, a partir de ellas, volúmenes de grano almacenado.
- **Generalización geográfica.** Aplicar y reentrenar el modelo en otras regiones agrícolas, con ajuste fino sobre datos locales.
- **Mayor resolución.** Explorar imágenes comerciales de mayor resolución para los casos donde 10 m resulte insuficiente.
- **Despliegue.** Desarrollar interfaces o servicios que faciliten la consulta de los resultados por parte de los distintos actores.
- **Otros modelos:** Ejecutar esta misma metodología (el estudio del efecto de la calidad de las etiquetas con arquitectura fija) sobre detectores más recientes, como los basados en transformers o las versiones actuales de YOLO, a fin de evaluar si el hallazgo de eficiencia de datos se sostiene con independencia de la arquitectura.
- **Otros transfer learning:** Evaluar el preentrenamiento del backbone sobre conjuntos de referencia del dominio aéreo-satelital (por ejemplo, DOTA; Xia et al., 2018) como alternativa a ImageNet, así como el empleo de detectores con cajas delimitadoras orientadas, geométricamente más ajustadas a objetos alargados de orientación arbitraria como los silo-bolsas.
- **Homogeneización de la escala radiométrica**. Aplicar el desplazamiento declarado en los metadatos de cada escena (o emplear productos armonizados), reentrenar y reevaluar, a fin de medir el efecto de una escala homogénea sobre el desempeño. El análisis de sensibilidad del Apéndice D estima la magnitud potencial de esa mejora: sobre el conjunto de 2026, llevar las imágenes a una escala uniforme incrementa el F1 de V5 de 0,801 a 0,820 y su AP@0,15 de 0,705 a 0,786, sin alterar el orden entre versiones.
- **Evaluación por superficie.** Complementar la evaluación por objeto con una evaluación por superficie detectada, que fusione las detecciones contiguas y las compare con el área total de silo-bolsas en la escena, a fin de evitar la penalización de las bolsas adyacentes que la resolución de 10 m no permite individualizar.
- **Aporte de las cajas de anclaje**. Cuantificar, mediante un experimento de ablación, el efecto de las anclas adaptadas a la geometría de los silo-bolsas frente a la configuración por defecto del detector

- **Validación de la verdad de terreno**. Contrastar una muestra de las etiquetas con relevamientos a campo e incorporar un segundo anotador independiente, a fin de cuantificar la concordancia inter-anotador y acotar la subjetividad de la fotointerpretación.

En conjunto, el trabajo aporta tanto una herramienta concreta para un problema relevante de la agroindustria argentina como una evidencia metodológica de interés general para la comunidad de aprendizaje automático.

Bibliografía

Arpit, D., Jastrzębski, S., Ballas, N., Krueger, D., Bengio, E., Kanwal, M. S., Maharaj, T., Fischer, A., Courville, A., Bengio, Y., & Lacoste-Julien, S. (2017). A closer look at memorization in deep networks. Proceedings of the 34th International Conference on Machine Learning (ICML), PMLR 70, 233-242.

AWS Open Data Registry. (s.f.). *Sentinel-2*. https://registry.opendata.aws/sentinel-2/

Ball, J. E., Anderson, D. T., & Chan, C. S. (2017). Comprehensive survey of deep learning in remote sensing: Theories, tools, and challenges for the community. *Journal of Applied Remote Sensing, 11*(4), 042609. https://doi.org/10.1117/1.JRS.11.042609

Barbiani, G., & Bustamante, L. N. (2022). *Detector de pivotes de riego y silobolsas en imágenes satelitales para aplicaciones agrícolas* [Proyecto Integrador de Grado, Universidad Nacional de Córdoba]. Repositorio GitHub. https://github.com/gianfrancob/detector_pivotes_silobolsas

Carion, N., Massa, F., Synnaeve, G., Usunier, N., Kirillov, A., & Zagoruyko, S. (2020). End-to-end object detection with transformers. *European Conference on Computer Vision (ECCV)*, 213-229. https://doi.org/10.1007/978-3-030-58452-8_13

Casini, C., Bartosik, R. E., & Rodríguez, J. C. (Eds.). (2009). *Almacenamiento de granos en bolsas plásticas: Resultados de investigación.* Instituto Nacional de Tecnología Agropecuaria (INTA).

Copernicus. (s.f.). *Sentinel-2 Data Collection*. Copernicus Data Space Ecosystem. https://dataspace.copernicus.eu/data-collections/copernicus-sentinel-data/sentinel-2

Drusch, M., Del Bello, U., Carlier, S., Colin, O., Fernandez, V., Gascon, F., Hoersch, B., Isola, C., Laberinti, P., Martimort, P., Meygret, A., Spoto, F., Sy, O., Marchese, F., & Bargellini, P. (2012). Sentinel-2: ESA's optical high-resolution mission for GMES operational services. Remote Sensing of Environment, 120, 25-36. https://doi.org/10.1016/j.rse.2012.03.026

European Space Agency. (2022). Sentinel-2 MSI annual performance report 2022 (OMPC.CS.APR.001). Copernicus. https://sentinels.copernicus.eu/documents/247904/4893455/OMPC.CS.APR.001+-+i1r0+-+S2+MSI+Annual+Performance+Report+2022.pdf

European Space Agency. (s.f.). Level-2A algorithms and products. Sentinel-2 MSI Technical Guide. https://sentinel.esa.int/en/web/sentinel/technical-guides/sentinel-2-msi/level-2a-algorithms-products

Everingham, M., Van Gool, L., Williams, C. K. I., Winn, J., & Zisserman, A. (2010). The Pascal Visual Object Classes (VOC) Challenge. *International Journal of Computer Vision, 88*(2), 303-338. https://doi.org/10.1007/s11263-009-0275-4

Expoagro. (2025). *Silobolsa: el invento argentino que soluciona problemas globales*. Expoagro Digital. https://www.expoagro.com.ar/silobolsa-el-invento-argentino-que-soluciona-problemas-globales/

Fernández Marcos, S. (2023). *Sistema de reconocimiento de patrones en imágenes satelitales para la detección de objetos* [Trabajo de Fin de Máster, Universidad de Salamanca].

Filgueira, E. (2013). *Silo bolsa*. C3T-UTN. https://c3t-utn.ar/wp-content/uploads/2013/07/Silo-Bolsa.pdf

Frénay, B., & Verleysen, M. (2014). Classification in the presence of label noise: A survey. *IEEE Transactions on Neural Networks and Learning Systems, 25*(5), 845-869. https://doi.org/10.1109/TNNLS.2013.2292894

Girshick, R. (2015). Fast R-CNN. *Proceedings of the IEEE International Conference on Computer Vision (ICCV)*, 1440-1448.

GISGeography. (s.f.). *Sentinel-2 bands and combinations*. https://gisgeography.com/sentinel-2-bands-combinations/

Gobierno de Argentina. (2025a). *Más del 40 % de la producción nacional se conserva en silobolsas*. Argentina.gob.ar. https://www.argentina.gob.ar/noticias/mas-del-40-de-la-produccion-nacional-se-conserva-en-silobolsas

Gobierno de Argentina. (2025b). *Monitoreo inteligente para preservar la calidad de los granos*. Argentina.gob.ar. https://www.argentina.gob.ar/noticias/monitoreo-inteligente-para-preservar-la-calidad-de-los-granos

He, K., Zhang, X., Ren, S., & Sun, J. (2016). Deep residual learning for image recognition. *Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition (CVPR)*, 770-778.

Helber, P., Bischke, B., Dengel, A., & Borth, D. (2019). EuroSAT: A novel dataset and deep learning benchmark for land use and land cover classification. *IEEE Journal of Selected Topics in Applied Earth Observations and Remote Sensing, 12*(7), 2217-2226. https://doi.org/10.1109/JSTARS.2019.2918242

Hu, F., Xia, G.-S., Hu, J., & Zhang, L. (2015). Transferring deep convolutional neural networks for the scene classification of high-resolution remote sensing imagery. *Remote Sensing, 7*(11), 14680-14707. https://doi.org/10.3390/rs71114680

Iglovikov, V., Mushinskiy, S., & Osin, V. (2017). *Satellite imagery feature detection using deep convolutional neural network: A Kaggle competition*. arXiv. https://arxiv.org/abs/1706.06169

Infraestructura de Datos Espaciales de la Provincia de Córdoba [IDECOR]. (2021). *Cobertura y uso del suelo 2020-2021 de la Provincia de Córdoba* [capa vectorial]. MapasCordoba. https://www.mapascordoba.gob.ar/#/descargas

International Society of Precision Agriculture. (2018). *Precision Agriculture Definition*. https://www.ispag.org/resources/definition

LeCun, Y., Bengio, Y., & Hinton, G. (2015). Deep learning. *Nature, 521*(7553), 436-444. https://doi.org/10.1038/nature14539

Lin, T.-Y., Dollár, P., Girshick, R., He, K., Hariharan, B., & Belongie, S. (2017). Feature pyramid networks for object detection. *Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition (CVPR)*, 2117-2125.

Lin, T.-Y., Maire, M., Belongie, S., Hays, J., Perona, P., Ramanan, D., Dollár, P., & Zitnick, C. L. (2014). Microsoft COCO: Common objects in context. *European Conference on Computer Vision (ECCV)*, 740-755. https://doi.org/10.1007/978-3-319-10602-1_48

McFeeters, S. K. (1996). The use of the Normalized Difference Water Index (NDWI) in the delineation of open water features. *International Journal of Remote Sensing, 17*(7), 1425-1432. https://doi.org/10.1080/01431169608948714

Muñoz, C., Acevedo, P., Salvo, S., Fagalde, G., & Vargas, F. (2007). Detección de incendios forestales utilizando imágenes NOAA/16-LAC en la Región de La Araucanía, Chile. *BOSQUE, 28*(2), 119-128. http://dx.doi.org/10.4067/S0717-92002007000200003

Muzlera, J. (2024). Silo bolsa (Argentina, 1991-2023). En J. Muzlera & A. Salomón (Eds.), *Diccionario del agro iberoamericano* (5.ª ed. ampliada). https://www.teseopress.com/diccionarioagro/chapter/silo-bolsa-argentina-1991-2023/

Northcutt, C. G., Athalye, A., & Mueller, J. (2021). Pervasive label errors in test sets destabilize machine learning benchmarks. *Proceedings of the Neural Information Processing Systems Track on Datasets and Benchmarks (NeurIPS)*.

Otsu, N. (1979). A threshold selection method from gray-level histograms. *IEEE Transactions on Systems, Man, and Cybernetics, 9*(1), 62-66. https://doi.org/10.1109/TSMC.1979.4310076

Padilla, R., Netto, S. L., & da Silva, E. A. B. (2020). A survey on performance metrics for object-detection algorithms. *International Conference on Systems, Signals and Image Processing (IWSSIP)*.

Paszke, A., Gross, S., Massa, F., Lerer, A., Bradbury, J., Chanan, G., Killeen, T., Lin, Z., Gimelshein, N., Antiga, L., Desmaison, A., Köpf, A., Yang, E., DeVito, Z., Raison, M., Tejani, A., Chilamkurthy, S., Steiner, B., Fang, L., . . . Chintala, S. (2019). PyTorch: An imperative style, high-performance deep learning library. Advances in Neural Information Processing Systems, 32.

QGIS Development Team. (2025). *QGIS Geographic Information System* (versión 3.40). Open Source Geospatial Foundation Project. https://qgis.org

Ren, S., He, K., Girshick, R., & Sun, J. (2015). Faster R-CNN: Towards real-time object detection with region proposal networks. *Advances in Neural Information Processing Systems, 28*.

Rolnick, D., Veit, A., Belongie, S., & Shavit, N. (2017). *Deep learning is robust to massive label noise*. arXiv. https://arxiv.org/abs/1705.10694

Rouse, J. W., Haas, R. H., Schell, J. A., & Deering, D. W. (1974). Monitoring vegetation systems in the Great Plains with ERTS. *Third Earth Resources Technology Satellite-1 Symposium, NASA SP-351*, 309-317.

Russakovsky, O., Deng, J., Su, H., Krause, J., Satheesh, S., Ma, S., Huang, Z., Karpathy, A., Khosla, A., Bernstein, M., Berg, A. C., & Fei-Fei, L. (2015). ImageNet Large Scale Visual Recognition Challenge. International Journal of Computer Vision, 115(3), 211-252. https://doi.org/10.1007/s11263-015-0816-y

Tapia Catacora, P. C. (2023). *Detección de deforestación de bosques en imágenes satelitales con redes neuronales convolucionales* [Tesis Doctoral, Universidad Nacional del Altiplano].

Victor, B., He, Z., & Nibali, A. (2024). *A systematic review of the use of deep learning in satellite imagery for agriculture*. IEEE Journal of Selected Topics in Applied Earth Observations and Remote Sensing, 18, 2297-2316. https://doi.org/10.1109/JSTARS.2024.3501216

Xia, G.-S., Bai, X., Ding, J., Zhu, Z., Belongie, S., Luo, J., Datcu, M., Pelillo, M., & Zhang, L. (2018). DOTA: A large-scale dataset for object detection in aerial images. *Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition (CVPR)*, 3974-3983.

Yang, D., Chen, J., Zhou, Y., Chen, X., Chen, X., & Cao, X. (2017). Mapping plastic greenhouse with medium spatial resolution satellite data: Development of a new spectral index. *ISPRS Journal of Photogrammetry and Remote Sensing, 128*, 47-60. https://doi.org/10.1016/j.isprsjprs.2017.03.002

Yosinski, J., Clune, J., Bengio, Y., & Lipson, H. (2014). How transferable are features in deep neural networks? *Advances in Neural Information Processing Systems (NeurIPS), 27*, 3320-3328.

Zeiler, M. D., & Fergus, R. (2014). Visualizing and understanding convolutional networks. *European Conference on Computer Vision (ECCV)*, 818-833. https://doi.org/10.1007/978-3-319-10590-1_53

Zhang, L., Zhang, L., & Du, B. (2016). Deep learning for remote sensing data: A technical tutorial on the state of the art. *IEEE Geoscience and Remote Sensing Magazine, 4*(2), 22-40. https://doi.org/10.1109/MGRS.2016.2540798

Zhang, P., Du, P., Guo, S., Zhang, W., Tang, P., Chen, J., & Zheng, H. (2022). A novel index for robust and large-scale mapping of plastic greenhouse from Sentinel-2 images. *Remote Sensing of Environment, 276*, 113042.

Apéndices

Apéndice A. Estructura del pipeline de procesamiento

El procesamiento se organizó como una secuencia de notebooks numerados, modulares y reanudables, detallados en el Cuadro A.1. Los notebooks 01 a 06 cubren la adquisición y el preprocesamiento de las imágenes (descarga, composición de bandas, mosaico, recorte a la zona agrícola, teselado y cálculo del índice INBNV con generación de polígonos candidatos); los notebooks subsiguientes abarcan el entrenamiento de las versiones del modelo y la evaluación comparativa. La numeración refleja el orden de creación de cada notebook y no necesariamente el de su ejecución: el notebook 08, por ejemplo, se reejecutó a medida que se incorporaban nuevas versiones del modelo, hasta ser reemplazado por el notebook 11 para la evaluación final.

Los datos de origen nunca se modifican. Cada etapa escribe sus resultados en una carpeta propia, sin sobrescribir los insumos de la etapa anterior, y los conjuntos de datos de cada versión del modelo se conservan en directorios separados. La asignación de cada tesela a entrenamiento, reserva o prueba se registra en archivos de seguimiento (CSV), sin mover ni alterar las imágenes.

Cuadro A.1. Notebooks del pipeline: nombre, etapa y función

#	Notebook	Etapa	Función
01	01_descarga_mensual_sentinel2_tiff	Adquisición	Descarga desde AWS S3 (bucket sentinel-s2-l2a) de las bandas B02, B03, B04, B08 (10 m) y SCL (20 m) para las teselas MGRS y el período indicados.
02	02_CompositeBands	Preprocesamiento	Composición RGB-NIR y enmascaramiento de nubes a partir de la capa SCL.
03	03_Merge_Escenes	Preprocesamiento	Mosaico de las escenas correspondientes a una misma fecha.
04	04_Clip_ZonaAgricola	Preprocesamiento	Recorte de los mosaicos a la zona rural mediante la capa vectorial de IDECOR.
05	05_Tile_Mosaics	Preprocesamiento	Teselado en parches de 1024 × 1024 px con solapamiento del 20 % y descarte de parches con escasa información útil.
06	06_Calculate_index	Etiquetado	Cálculo del índice INBNV, umbralización por percentil y vectorización de los polígonos candidatos.
07	07_FAST_CNN	Entrenamiento	Prueba de concepto inicial (V1), no incluida en la comparación.
07	07_FAST_CNNv2_dataagumentation	Entrenamiento	Entrenamiento de la versión V2 (500 imágenes, volteo horizontal).
07	07_FAST_CNNv2_dataagumentation(v2)	Entrenamiento	Entrenamiento de la versión V3 (600 imágenes, aumentación geométrica y radiométrica).
08	08_mAP	Evaluación	Evaluación comparativa preliminar de las versiones disponibles en cada momento, sin deduplicación.
09	09_CLEAN_DATASET / 09_generar_v5_balanced	Preparación de datos	Selección de las teselas a curar, generación de la planilla de seguimiento y muestreo balanceado que conforma el conjunto V5.
10	10_TRAIN_V4_10k	Entrenamiento	Entrenamiento de la versión V4 (10.000 imágenes, etiquetas ruidosas)
10b	10b_TRAIN_V5_FINAL	Entrenamiento	Entrenamiento de la versión V5 (216 imágenes curadas).
11	11_mAP_FINAL	Evaluación	-Evaluación final de V2-V5 con deduplicación (NMS), curvas de umbral y AP, y pruebas de significancia.
-	PIPELINE_2026_all_in_one	Validación temporal	Replica el pipeline 01-06 sobre 2026 y evalúa las cuatro versiones sobre el año no visto.
	PIPELINE_2026_HNK_junjul	Validación temporal	Corrida complementaria del pipeline de 2026, restringida a la tesela 20HNK en junio y julio, para cubrir la franja norte del área de estudio (Sección 4.6).

Repositorio: https://github.com/federico-syngenta/Silos_FR_MCDtf

Los pesos de los modelos entrenados y la totalidad de las imágenes se encuentran almacenados en un repositorio externo; su acceso puede solicitarse al autor.

Apéndice B. Configuración de entrenamiento

B.1 Configuración común a todas las versiones.

Las versiones V2 a V5 comparten la misma arquitectura y los siguientes parámetros base:

- Arquitectura: Faster R-CNN con backbone ResNet50-FPN. El backbone se inicializa con pesos de ImageNet y los componentes de detección se entrenan desde cero (sin pesos de COCO); las capas conv1 y el primer bloque residual permanecen congelados y se ajustan los tres bloques residuales más profundos (Sección 3.8).
- Anclas: escalas de 16, 32, 64, 128 y 256 px; relaciones de aspecto de 0,2; 0,5; 1,0; 2,0 y 5,0 (Sección 3.7).
- Entrada: RGB (3 canales).
- Optimizador: SGD (momentum 0,9; weight decay 0,0005). Tamaño de lote: 2.
- Función de pérdida: la pérdida multitarea estándar de Faster R-CNN (clasificación y regresión de la red de propuestas de regiones, y clasificación y regresión de las cabezas de detección), sumada en un único término.
- Reanudación desde checkpoint: se guarda un checkpoint por época con el estado necesario para reanudar tras una interrupción (época, pesos del modelo y estado del optimizador), empleado sobre todo en los entrenamientos prolongados, como el de V4.

B.2 Régimen de entrenamiento por versión

Las versiones difieren en los parámetros que se detallan en el Cuadro B.1.

Versión	Tasa de aprendizaje	Épocas	Scheduler	Recorte de gradiente	Aumento de datos
V2	0,002	5	No	No	Geométrico (solo volteo horizontal)
V3	0,002	5	No	No	Geométrico y radiométrico
V4	0,0005	5	No	5,0	Geométrico y radiométrico
V5	0,005	40	StepLR (×0,1 cada 15)	1,0	No

Cuadro B.1. Régimen de entrenamiento por versión. La aumentación geométrica corresponde a volteo aleatorio horizontal y vertical, cada uno con probabilidad del 50 %; la radiométrica, a una variación aleatoria de brillo y contraste de ±0,2. Fuente: elaboración propia.

B.3 Composición de los conjuntos

Cada conjunto se particionó aleatoriamente en entrenamiento y validación con semilla fija: V2, 400 y 100 imágenes (partición 80/20, semillas 99 para el muestreo y 42 para el entrenamiento); V3, 480 y 120 (80/20, semilla 77); V4, 8.500 y 1.500 (85/15, semilla 456); y V5, 183 y 33 (85/15, semilla 456). El detalle del muestreo de cada conjunto se describe en la Sección 3.6 y en el Apéndice C.

B.4 Entorno de software

El desarrollo se realizó en Python 3.13.3, con PyTorch 2.8.0 y torchvision 0.23.0 (compilaciones para CPU) para el modelado; rasterio 1.4.3 y GDAL 3.9.3 para el procesamiento ráster; GeoPandas 1.1.1 para los datos vectoriales; y QGIS 3.40.7 para la curación manual, si bien el procedimiento puede replicarse con versiones posteriores. El entrenamiento se ejecutó íntegramente en CPU, sin GPU

Apéndice C. Detalle del muestreo estratificado

El muestreo de los conjuntos V4 y V5 se organizó en 18 estratos, definidos por la combinación de mes (junio, julio y agosto) y año (2020 a 2025) de las imágenes procesadas. Los conjuntos de V2 y V3, en cambio, se obtuvieron por muestreo aleatorio simple sobre el universo de teselas (Sección 3.6.1).

Para V5, sobre el universo de 25.749 teselas procesadas se construyó primero el conjunto de candidatas a curar mediante muestreo estratificado, con un objetivo de 1.000 teselas distribuidas en proporción al tamaño de cada estrato y un filtro de distancia mínima de dos teselas en la grilla de teselado entre muestras de un mismo estrato, para reducir la autocorrelación espacial; el filtro limitó la selección a 615 teselas (Sección 3.5.2). A partir de ese conjunto, la versión V5 se construyó de forma balanceada seleccionando 12 imágenes curadas por estrato (18 × 12 = 216), con semilla aleatoria fija (456). Las 216 imágenes conforman el conjunto V5, que luego se particionó en entrenamiento y validación (183 y 33 imágenes, respectivamente; véase el Apéndice B). El excedente de los estratos con más de 12 imágenes curadas disponibles, correspondientes al año 2020, sumó 54 teselas y se reservó como conjunto de prueba con verdad de terreno curada (la Reserva; Sección 3.6.2).

Para V4, el conjunto de 10.000 teselas se muestreó también de forma estratificada por año y mes, con la misma asignación proporcional al tamaño de cada estrato y semilla fija (456), pero sin filtro de distancia mínima entre teselas, según se indicó en la Sección 3.6.1.

Apéndice D. Escala radiométrica y análisis de sensibilidad

Para verificar la presencia del desplazamiento radiométrico descripto en la Sección 3.4 se analizó la distribución de valores digitales de la banda B04 sobre la totalidad de las escenas de julio de la tesela 20HNJ, para cada año del período de estudio y para 2026. El Cuadro D.1 reporta los percentiles bajos, correspondientes a los píxeles más oscuros de la escena (cuerpos de agua y sombras), que son los más sensibles al desplazamiento.

Cuadro D.1. Percentiles de la banda B04 (valores digitales) por año, escenas de julio de la tesela 20HNJ.

Año	Escenas	p1	p5	p50	Mínimo
2020	22	404	747	1728	1
2021	24	303	651	1738	1
2022	12	1456	1752	2340	1085
2023	13	1338	1545	2114	778
2024	12	1385	1692	2288	907
2025	15	1352	1593	2146	595
2026	13	1360	1603	2236	961

Los percentiles bajos se desplazan de valores del orden de 300 a 400 a valores del orden de 1.350 a 1.450 exactamente en 2022, y se mantienen estables en adelante, lo que confirma la presencia del desplazamiento y su magnitud.

Para cuantificar su incidencia se evaluaron V4 y V5 sobre las 29 teselas de 2026 en dos condiciones: con el preprocesamiento original y restando 1.000 a los valores digitales antes de la conversión. El Cuadro D.2 reporta los resultados.

Modelo	Escala	Precisión	Recall	F1	AP@0,15
V4	Original	0,782	0,722	0,751	0,687
V4	Corregida	0,746	0,788	0,767	0,699
V5	Original	0,809	0,793	0,801	0,705
V5	Corregida	0,801	0,839	0,820	0,786

Cuadro D.2. Sensibilidad de V4 y V5 al desplazamiento radiométrico sobre el conjunto de prueba de 2026 (29 teselas, 802 cajas de verdad de terreno). La corrección mejora el desempeño de ambas versiones, principalmente por un aumento del recall (de 0,722 a 0,788 en V4 y de 0,793 a 0,839 en V5); la diferencia de AP sobre la curva completa resulta significativa en ambos casos mediante bootstrap pareado (+0,058 en V4 y +0,038 en V5, con intervalos de confianza que excluyen el cero). El orden entre versiones se mantiene en las dos escalas. Corresponde acotar el alcance de este análisis: mide la sensibilidad de modelos ya entrenados a un desplazamiento de la escala de entrada, y no el efecto de corregir el desplazamiento en todo el flujo, entrenamiento incluido, cuestión que se plantea como trabajo futuro (Sección 5.2).

Apéndice E. Validación temporal: conjunto completo de teselas

La Figura E.1 presenta las 29 teselas del conjunto de validación temporal de 2026 (Sección 4.6), con la verdad de terreno curada y las detecciones de V5.



Figura E.1. Conjunto de validación temporal sobre imágenes de 2026. Las 29 teselas con la verdad de terreno curada (en verde) y las detecciones de V5 (en rojo), con el puntaje de confianza de cada detección. Composición RGB Sentinel-2 con realce de contraste por percentiles 2 y 98. Fuente: elaboración propia.